

风电功率预测关键技术及应用综述

孙荣富¹, 张 涛², 和 青³, 徐海翔¹

(1. 国网冀北电力有限公司, 北京 100054; 2. 国家电网有限公司华北分部, 北京 100053;
3. 国家电网有限公司, 北京 100031)

摘 要: 随着风电装机规模的不断增长, 其并网后带来的安全运行和消纳利用问题日益突出, 高比例风电接入的功率预测准确性愈发重要。现阶段, 风电功率预测在平衡系统电力供应和负荷需求之间发挥了至关重要的作用; 未来, 风电短期和超短期功率预测在备用市场、现货市场及辅助服务市场中将发挥更大的作用, 是风电参与市场交易的重要支撑手段。论文对风电功率预测的技术路线和关键应用进行了全环节综述和阶段性总结, 介绍了适用于风电功率预测的数值天气预报关键技术环节, 分析了面向不同预测对象的风功率转换模型及技术路线, 探讨了不同预测模型的应用场景及性能评价方法。最后从未来应用发展需求的角度, 提出了我国风电功率预测精度提升的相关建议。

关键词: 风电功率预测; 数值天气预报; 集合预报; 组合预测; 概率预测; 集群预测

Review on Key Technologies and Applications in Wind Power Forecasting

SUN Rongfu¹, ZHANG Tao², HE Qing³, XU Haixiang¹

(1. State Grid Jibei Electric Power Company Limited, Beijing 100054, China;
2. North China Branch of State Grid Corporation of China, Beijing 100053, China;
3. State Grid Corporation of China, Beijing 100031, China)

Abstract: With the fast development of wind power installation in China, wind power integration capacity constrained by load regulation capability becomes the key problem in power system, and accurate wind power forecasting of high proportion wind power becomes more and more important. At present, wind power forecasting plays a key role in dealing with the challenges of balancing supply and demand in any electricity system. In the future, short-term and ultra-short-term wind power forecasting will play a greater role in standby market, spot market and auxiliary service market, which is an important support means for wind power to participate in market transactions. In this paper, research and periodic summary are illustrated on the roadmaps and applications of wind power forecasting, including the whole process of numeric weather prediction, wind power conversion model, wind power forecasting system applications and evaluation indices of forecasting performance, and the prospects in future technical route are provided.

Key words: wind power forecasting; numeric weather prediction; ensemble prediction; combined forecasting; probabilistic forecasting; cluster forecasting

0 引言

过去十年, 以风电为代表的可再生能源经历了跨越式发展, 截至 2020 年底, 全国风电装机容量达到 2.8 亿 kW, 装机占比高达 12.8%, 风电逐步由“辅助电源”向“主力电源”转变。然而, 受风资源时变特性的影响, 风电具有较强的随机性、间歇性和不确定性^[1], 随着风电装机占比的逐年上升, 电力系统运行不确定性增加, 电网安全运行与新能源高

效消纳矛盾日益凸显^[2-3]。

为了应对这一挑战, 世界各国陆续开展风电功率预测技术研究, Prediktor、WPPT、eWind、WPMS、ANEMO 等成熟预测系统已在国内外得到广泛应用。特别是随着高比例风电优化调度、市场交易、高效消纳以及发电能力提升等应用领域的不断深化, 近年来风电功率预测技术的支撑能力和应用水平取得了长足的进步^[4-6]。在预测精度方面, 通过对数值天气预报核心技术的完善和风功率转换模型的优化, 控制预测误差(国际上区域级短期风电功率预测均方根误差低至 5%~6%^[7])使其具备纳入电力

基金资助项目: 国家重点研发计划(2018YFB0904003)。

Project supported by National Key R&D Program of China (2018YFB0904003).

电量平衡的条件;在预测产品方面,结合大风、低温、冻雨及雾霾等极端气象条件,衍生出事件预测、概率预测、集群预测等多类型预测模式,预测产品丰富程度越来越趋多样化;在预测应用及评价方面,考虑均方根误差的局限性,结合调度与市场实用化需求,完善了预测评价指标体系,促进了预测性能的整体提升。

结合近些年风电功率预测技术的发展和实用化应用情况,本文对风电功率预测的最新进展进行了调研和阶段性总结,从数值天气预报、风功率转换模型、预测功能应用以及预测性能评价的全过程环节进行了综述,探讨了当前研究存在的问题及后续的研究方向,以期为我国风电功率预测持续发展提供参考。

1 风电功率预测技术体系

经过国内外多年研究与实践,风电功率预测已经构建了包含数值天气预报(numeric weather prediction, NWP)、风功率转换模型、预测结果应用、预测结果评价的关键技术及应用体系,以及物理、统计 2 大类方法^[8]。一般来讲, NWP 主要应用于物理方法中,统计方法主要涉及 NWP 以外的 3 项技术,但并不绝对,二者间也互相渗透^[9]。风电功率预测技术体系如图 1 所示。

首先,利用气象中尺度模式将全球模式背景场生成 NWP 产品;随后将 NWP 中风资源相关气象要素输入到风功率转换模型中,得到预测的风电功率时间序列;然后将风电功率预测结果应用于日前机组组合安排、日内发电计划调整等应用中;最后对风电功率预测结果进行评价,并针对预测模型缺陷进行优化提升。

2 数值天气预报

数值天气预报是在给定大气初始和边界条件的情况下,通过大型计算机数值求解描述大气运动变化规律的运行方程组,进而预测未来时段大气运动状态及天气现象的方法^[10-11]。NWP 主要分为 2 种模式:一种是全球模式,其目标是求解全球的天气状况,可为区域模式预报提供必须的背景场数据;另一种是区域模式,该模式能够更为准确地模拟风电场的微地形、微气象,且能高频地同化局地卫星、雷达等资料,预报结果更为准确。区域中尺度数值模式的一般运行流程如图 2 所示,包括背景场数据




图1 风电功率预测关键技术环节

Fig.1 Key technical links of wind power forecasting




图2 区域中尺度数值模式的运行流程图

Fig.2 Operation flow chart of regional mesoscale numerical model

处理、资料同化、物理过程参数化等关键环节。

2.1 背景场

物理学家 Bjerknes 曾把 NWP 归结为初值问题,背景场初始边界条件的精确性会直接影响 NWP 的成败。尽管全球模式难以满足风电场的 0.1 km 量级气象要素预报需求,但 72 h 以上的气象变化仍脱离了全球模式背景场的变化。

全球模式是一个复杂的系统工程,背景场精度的提升需要在动力框架、同化方法、参数化方案、计算机技术等多个方面取的突破。此外,还需推动全球各国气象观测水平的提升,包括增加观测站点数量,提高数据观测质量,以及促进数据共享等。除了全球各大气象中心机构,一般的机构或人员很难提升全球模式背景场的预报精度。图 3 展示了欧洲中期数值天气预报中心(european centre for medium-range weather forecasts, ECMWF)全球数值预报技巧演变趋势。可以看到,全球模式背景场精度的提升是一个缓慢的过程,目前预报有效性大致延伸至 1 周左右,但预报效果随预报时长的增加而显著递减,超过 10 d 时间的预报结果已不具备参考和应用价值^[12]。

随着计算机计算速度的提升, 全球模式背景场的分辨率越来越高。表 1 为目前主要全球模式的背景场信息情况, 空间分辨率整体水平可达到了 $0.25^{\circ} \times 0.25^{\circ}$ 左右(对于我国, 1° 约为 100 km), 其中 ECMWF 空间分辨率已达到 $0.1^{\circ} \times 0.1^{\circ}$ 。

2.2 观测资料同化

在为 NWP 提供准确的初始和边界条件方面, 资料同化是一种公认有效的方法^[13], 即采用一定的优化标准, 将所有可用的观测信息与预测模型有机融合, 从而尽可能准确地估计大气运动状态^[14]。资料同化技术经历了主/客观分析方法、统计估计方法、3/4 维变分方法、集合同化方法多种方法的演变。

2.2.1 主/客观分析方法

在 NWP 发展初期, Richadson 首次将同化技术应用用于 NWP 中, 由于通过人工干预的方式进行观测资料的插值和填图, 分析结果会因人而异, 因此该方法称为主观分析方法。

20 世纪 50 年代随着计算机的发展, 客观分析方法应运而生, 该方法克服了主观分析方法人为为主观、计算耗时等缺陷。如 1949 年 Panofsky 提出的多项式拟合方法, 通过某类函数自动拟合分析区域内所有观测点的初始条件^[15]; 但由于分析被限定在相对小的区域内, 因此该方法往往会出现各拟合区域之间不连续的问题。

2.2.2 统计估计方法

为克服局地多项式拟合方法的缺陷, 1959 年 Cressman 引入了背景场的概念, 提出逐步订正法^[16]。其原理是通过分析每个观测值与背景场的观测偏差, 以某观测点影响半径内各观测点观测偏差的加权值作为分析增量对背景场进行修订, 然后经过不断缩小影响半径, 逐次订正至观测偏差小于确定值。但权重系数仅依赖于各观测点距离, 未考虑观测点的分布关系, 因此无法实现最优订正。

直到 1963 年, Gandin 结合统计估计理论, 提出了最优插值法^[17], 该方法考虑了观测偏差的统计特征, 以分析场误差方差最小来确定观测偏差的最优权重。该方法利用了线性回归技术, 导致分析场结果过度平滑, 因此不太适用于中尺度的数值模式。

2.2.3 3/4 维变分方法

随着观测技术的发展, 观测资料类型、数目不断增多, 对同化技术也提出了更高的要求。20 世纪 60 年代后期, Sasaki 将变分方法引入客观分析过程中, 将资料同化转化为一个求解分析场和背景场及




图3 ECMWF 风电预报技巧演变图

Fig.3 Development tendency of wind power prediction technique for ECMWF(www.ecmwf.int)

表 1 主要的全球模式背景场信息

Table 1 Main background information of global model				
背景场	来源	空间分辨率	时间分辨率/h	预报时长/d
GFS	美国	$0.25^{\circ} \times 0.25^{\circ}$	1	16
ECMWF	欧洲	$0.1^{\circ} \times 0.1^{\circ}$	1	10
GEM	加拿大	$0.24^{\circ} \times 0.24^{\circ}$	3	10
GSM	日本	$0.25^{\circ} \times 0.25^{\circ}$	3	11
GRAPES	中国	$0.25^{\circ} \times 0.25^{\circ}$	3	10
T639	中国	$0.28^{\circ} \times 0.28^{\circ}$	3	10

观测场偏差极小化的问题^[18]。该方法避免了分析量与观测量存在线性关系的约束限制, 可直接同化非常规的观测资料, 包括 3 维变分(3DVar)和 4 维变分(4DVar)。3DVar 方法避免了不同区域之间的跳跃现象, 但由于无法通过后序资料修正前面的结果, 导致同化结果在时序上不连续。而 4DVar 方法在时间维度上做了拓展, 通过调整初始场使预报在一定时间区间内与观测场误差最小, 但是其计算量更大。

2.2.4 集合同化方法

20 世纪 60 年代, Jones 把卡尔曼滤波技术引入到气象学中, 提出了卡尔曼滤波同化方法。随着集合预报研究的推进, 1994 年 Evensen 提出集合预报与卡尔曼滤波方法结合的同化应用^[19], 利用循环集合预报来估计预测误差的协方差, 绕开了标准卡尔曼滤波非线性近似和 4DVar 伴随模式的问题。但在实际中, 往往难以满足该方法假设的背景误差服从高斯分布的前提, 导致应用结果存在一定的偏差, 同时也会存在不平衡和滤波发散的问题^[20]。近些年, 将变分和集合相结合的混合同化方法也得到了越来越多的关注^[21], 该方法可利用变分静态协方差优化滤波协方差不满秩的问题。

2.3 物理过程参数化

大气包含着不同尺度的大气运动,即使背景场分辨率达到 1 km 级别,大气中也仍存在很多重要过程是模式无法解析的。物理过程参数化是通过统计方法将模式中无法直接表达的物理过程所产生的效应与模式变量联系起来,利用数值计算方式求解,该方法是提高 NWP 精度的重要手段^[22]。其中,与风电功率预测密切相关的包括积云、边界层和辐射过程参数化。

2.3.1 积云对流参数化

积云常常受大尺度环流控制而产生运动,也会通过其潜热等反馈作用影响区域乃至全球大尺度的环流状态。积云对流参数化操作简单,但因其求解的未知量多于方程个数,故需适当添加新假设及约束关系才能使方程组闭合求解。按照闭合假设条件可分为 3 类^[23]:第 1 类是瞬时平衡假设,假设积云对流起着使条件不稳定大气向某一定递减率平衡状态调整的作用;第 2 类是准平衡假设,假设在对流云的建立和环境的稳定化过程之间存在着近似的平衡;第 3 类是质量、水汽辐合型假设,直接把积云活动和大尺度的垂直速度或水汽辐合等联系起来。

2.3.2 边界层参数化

边界层位于对流层的下边界,由于受到下垫面热力状况和湍流摩擦的直接影响,边界层内的空气具有明显的湍流运动特征,会导致热量、动量及水汽等在垂直方向强烈运动。局地 K 方法是传统的垂直扩散方案,该方案建立在风场和位温的局地梯度基础上,但仅适用于稳定的大气层结。为了克服这种缺点,提出了不同的优化方法:一种是高阶闭合方法^[24],该方法可以很好地描述混合边界层的结构,但计算量会随湍流动能的增加而加大;另一种是非局地 K 方法^[25],该方法以其简单性且能表示混合边界层中涡旋的优势而在不同模式中得到了广泛应用。

2.3.3 辐射传输模型参数化

太阳辐射在大气中传输时会经历云、气溶胶微粒及地面的吸收、散射及反射,从而造成辐射强度和相位等特性的变化,不同大气对辐射的影响不同,即使同一大气,对不同频率的辐射也不尽相同^[26]。辐射参数化是通过合理的参数化方案来解析各时间步长辐射传输值的方法^[27],一般对长波辐射和短波辐射分别进行参数化。晴空天气下长波辐射主要通过大气比辐射率进行参数化,多云天气则会增加云

参数相关附加项;而短波辐射则一般采用基于太阳天顶角等简单方案进行参数化。

3 风功率转换模型

商业应用的风功率转换模型已形成了较为成熟的技术体系,根据预测形式及应用场景可分为确定性预测、事件预测、概率预测、集群预测等模型。图 4 展示了各类风功率转换模型所对应的数据流情况,输入数据主要包括风电场物理信息(包括地形、风机分布等)、历史功率数据、历史气象数据(包括风速、风向等)及 NWP 数据。

3.1 确定性预测

确定性预测是指对未来风速或者风功率的具体点值进行预测^[28]。按照不同的时间尺度,确定性预测分为超短期预测、短期预测及中长期预测。其中,超短期预测用于优化旋转备用容量及电力系统实时调度;短期预测用于安排常规电源机组组合及制定日发电计划;中长期预测则用于制定年度检修计划及电量计划。根据预测原理不同,确定性预测可分为物理方法和统计方法,以及物理统计相结合的组合方法^[29]。

3.1.1 物理预测方法

物理预测方法是风电功率预测中最先采用的方法,如丹麦 Risø 国家可再生能源实验室采用类似欧洲风图集的推理方法开发了第一套较为完整的风电功率预测系统 Prediktor。经过近几十年的发展,物理预测方法主要包括 NWP 数据引入、风电机组轮毂高度处风速风向获取和风速-功率转化 3 个技术环节^[30],即考虑风电场地形地貌等信息,将 NWP




图4 风功率转换数据流

Fig.4 Data flow of wind power conversion

数据转化为实际环境条件下的风资源信息, 根据风电机组性能参数计算风电机组的预测功率, 再累加得到整个场站的理论预测功率。该方法计算较为复杂, 需通过求解多维偏微分方程组进行预测, 但对风电场的技术条件要求较低, 无需历史运行数据, 只需引入风电场位置、地形、地貌和风电机组信息等, 可适用于新建风电场。

然而, 一方面由于 NWP 数据更新频率较低(一般在 1~3 h), 难以满足 15 min 超短期预测的要求, 因此物理方法通常仅适用于短期及中长期预测; 另一方面, 物理方法的预测精度不高, 因此直接使用 NWP 的物理预测模型时精度常常不满足应用需求。结合学习方法和数据分析优化 NWP 数据来提高预测精度是目前物理预测方法的主要研究方向。Federico Cassola 采用卡尔曼滤波算法对 NWP 输出进行滤波后, 有效降低了气象预报的系统误差, 显著提升了 NWP 模型的精度^[31]。Men Z 采用 Gauss 混合模型构建实测风速和 NWP 数据之间的映射关系, 并以此来修正 NWP 风速, 校正后的 NWP 数据及功率预测精度得到了大幅提升^[32]。

3.1.2 统计预测方法

统计预测方法不考虑风速的物理变化过程, 该方法通过统计算法来学习风电场历史气象、电力数据所表现出来的特征规律, 然后结合实测功率数据或 NWP 数据预测风电场未来的发电功率^[33], 避免了复杂的物理建模过程, 但需要大量数据进行学习建模, 适用于已运行风电场。

1) 基于时序外推的预测方法

时序外推预测方法不需要引入风速、风向等气象信息, 可直接根据风电场发电功率的历史序列特征(如自相关性、标准偏差等统计特征)外推预测未来时刻风电场的输出功率, 包括持续法、自回归移动平均(auto-regressive and moving average, ARMA)法和卡尔曼滤波算法等。

持续法是最简单的时序外推预测方法, 以当前时刻实测功率值作为未来时刻的预测功率^[34]。该方法操作简单, 在较短的时间尺度下, 其预测精度甚至可能会超过其他复杂学习方法, 但随着时间尺度的增加, 其预测精度会急剧下降, 因此只适合超短期风电功率的预测。

20 世纪 80 年代有学者开始尝试用 ARMA 等经典时间序列模型进行功率预测。Ergin Erdem 按照风向将风速分解为横向和纵向分量, 并分别构建

ARMA 模型进行预测, 改善了预测结果^[35]。该方法建模简单, 但适应性差, 难以应对阵风、突变风等非平稳突变状况, 同时其预测精度会随着时间的增加而下降^[36], 因此适用于超短期及短期功率预测。

为应对以上不足, 一些学者将卡尔曼滤波法、混沌理论等其他数学方法与时间序列相结合, 不断优化提高预测模型的精确性和适应性, 弥补了时间序列预测方法的不足。潘迪夫结合时序分析法和卡尔曼滤波, 动态修正了预测模型系统, 提高了下一时刻的预测精度^[37]。冬雷则结合混沌时间序列的相空间理论, 构建了风电功率神经网络预测模型^[38], 该模型在不需要风速数据的情况下也可得到较高的预测精度。

2) 基于人工智能(artificial intelligence, AI)算法的预测方法

仅仅利用历史功率数据的时序外推预测方法时, 预测精度会随着时间的增加而显著下降, 也难以适应突变情况。综合考虑气象和电力等相关影响因素, 采用一种或多种 AI 算法对历史功率数据进行训练, 提取 NWP 历史数据与风电场历史发电功率之间的联系, 再根据该关系由 NWP 数据对风电场发电功率进行预测是风电功率预测的重要研究方向, 主要包括人工神经网络法(artificial neuro network, ANN)、支持向量机(support vector machine, SVM)、深度学习算法等。

ANN 具有非线性映射、分布并行处理、鲁棒容错自适应学习和泛化能力等特性^[39-40], 已成为风电功率预测中应用最广泛的统计方法。Kariniotakis G N 于 1996 年就提出利用 ANN 开展超短期风电功率预测, 并对比分析了 ANN 模型与持续法的性能^[41]。常用的神经网络模型有反向传播(back propagation, BP)网络、径向基函数(radial basis function, RBF)网络、广义回归(general regression, GR)网络等^[42]。

SVM 建立在 VC(Vapnik-Chervonenkis)维理论及结构风险最小化的基础上, 能够有效克服训练结果局部极小值的问题, 将其用于风电功率预测时能有效地解决过学习问题。Qinghua Hua 采用 Bayes 理论优化传统 SVM 损失函数, 建立了 v-SVM 模型, 提高了短期风速预测的精度^[43]。但 SVM 参数的选取依赖经验判断, 因此存在一定的随意性。

K 近邻算法(k-nearest neighbor, kNN)^[44]、模糊逻辑算法^[45]、随机森林算法^[46]等数据挖掘算法也常被用于风电功率预测。此外, 为解决 SVM 等以上

算法参数难以优化求解的问题,常采用遗传算法、粒子群算法、蚁群算法、果蝇算法等^[47],借鉴仿生学原理,将生物的行为特征融入到风功率预测算法中进行参数寻优。

随着大数据技术发展,AI 预测方法由机器学习算法逐步向深度学习算法发展^[48]。文献[49]利用长短期记忆网络(long short term memory, LSTM)对多变量的时间序列进行动态建模,以实现风电功率的预测。文献[50]利用小波变换对数据序列进行分解,然后采用卷积神经网络针对性进行学习。深度学习算法相对于机器学习算法能够更全面地提取和保留数据特征,其预测模型适应性更好。

AI 预测方法不需要建立预测功率和气象数据之间具体的解析关系,通过大量数据训练即可获得很好的预测结果,适用于超短期、短期和中长期功率预测。

3.1.3 组合预测方法

风电功率受很多因素的影响,单一的预测模型不能完全包含各种因素,尤其是在极端天气情况下,单一模型没有充分的学习,可能会导致预测出现较大偏差。组合预测方法同时考虑了不同模型各自的优点,最优化组合多种单一模型,发挥各个模型的优势,可以明显提高预测的精度^[51]。组合预测方法主要包括加权组合预测和融合组合预测 2 类,组合预测流程图如图 5 所示。

加权组合预测是利用多种预测模型进行预测,然后以权重形式组合各模型结果形成预测结果,1969 年由 Bates 和 Granger 首次提出。按照组合权系数的不同,加权组合预测可分为定权系数组合和变权系数组合。定权系数组合法通过实现目标函数极小化确定权重系数,比如考虑使预测误差百分比、平方和等指标达到最小^[52-53];变权系数组合法的权重系数是随时间变化的,每一时刻可优化修正得到预测最优的模型^[54-55],变权系数组合法是增强预测模型适应性、提升预测模型准确率的有效方法。

融合组合预测属于一种广义的组合预测,其本质上还是单一的预测模型,只是采用其他优化方法对模型的输入、输出、模型自身进行了融合改进。针对模型输入,可通过小波分解(wavelet transform, WT)^[56]或者经验模态分解(empirical mode decomposition, EMD)^[57]将风速或功率等不平稳信号序列进行分解和平稳化处理得到子序列,然后针对各序列自身的特点,较准确地建立预测模型,预测精度可




图5 风电功率组合预测方法

Fig.5 Wind power combination forecasting methods

提升 5%~10%,但该方法计算量相对较大;同时,可使用粗糙集^[58]、主成分分析^[59]等数据挖掘方法对预测模型的输入进行特征提取,在减少输入的情况下达到较高的预测精度。针对模型自身,可采用遗传算法^[60]、萤火虫算法^[61]、鱼群算法^[62]等优化方法对预测模型参数进行优化,从而克服常规 AI 预测模型易陷入局部最优解及模型参数难以确定等问题,具有更优的学习能力和泛化能力。针对模型输出,可建立误差校正模型^[63],将传统方法的预测结果代入到误差模型中,将误差值与传统的预测值对应叠加作为预测修正结果,该方法具有较强的通用性,不局限于具体预测过程。近年来,“输入优化+模型优化+误差修正”的多环节组合预测方法也成为研究热点^[64],该方法从各环节组合优化来提升预测的精度。

3.2 事件预测

风电功率在短时间内出现大幅的波动称为风电爬坡事件,风电爬坡会破坏电力系统的发用电平衡,从而威胁电网的安全运行。其中,强对流、低空急流等极端气象极易引发风速激增,触发上爬坡事件;而气压梯度急速下降或风速高过切出风速会使得机组停运,导致风电功率陡降,触发下爬坡事件^[65]。目前爬坡事件在国内外还没有统一的定义,但大体可以分成 3 类:(1)某时段内功率波动幅度超过给定阈值;(2)某时段内功率变化率超过给定阈值;(3)某时段内功率滤波信号超过给定阈值。其中,功率波动幅度计算可采用首末时刻功率之差,也可采用最大和最小功率之差;可采用绝对值,也可采用相对值。不同统计方式各有利弊及适应范围,可根据爬坡事件的预测需求来优化选择。

通过对风电爬坡事件量化分析及准确预警,可辅助调度机构优化开机方式和备用配置,缓解风电

大幅波动对电网的冲击, 从而增强电力系统的稳定性。事件预测按照预测模型可分为间接预测和直接预测。

直接预测法通过挖掘历史数据中气象信息与爬坡事件特征量之间的映射关系, 进而可通过气象预测信息直接预测爬坡事件的特征量, 而无需预先预测风电功率。Zareipour H 基于 SVM 挖掘历史数据中爬坡事件的特征量, 并结合风速实际数据仿真验证了该方法的有效性^[66]。该方法直观简单且精度高, 但其训练模型依赖于大量的历史观测样本, 样本数据的完整性和正确性将直接影响预测水平。此外, 风电爬坡事件是典型的小概率事件, 其观测样本固有的稀缺性制约了该类方法的应用与发展。

间接预测法是当前爬坡事件预测的主流方法, 该方法先采用确定性预测方法预测未来时间的风电功率序列, 再结合爬坡事件定义从预测序列中挖掘爬坡事件, 并提取相应的特征量信息。Cui M 从不同时间尺度对风电爬坡事件爬坡幅度、爬坡率等爬坡特征量进行了分析^[67]。叶林采用最优旋转门算法对爬坡事件进行识别, 并通过元组向量时间扭曲法在风电功率预测结果中寻找与历史相似的爬坡事件^[68]。除常规统计分析法以外, 概率分析^[69-70]、场景划分^[71]等方法也常被应用于爬坡事件的预测模型中。然而, 间接预测法过多依赖于风电功率的预测结果, 可能会忽略极端气象样本而导致爬坡事件漏报。一般可借鉴组合预测理论来提高事件的预测精度: 一种是在模型输入环节, 将原始风电功率序列分解成多个分量, 提取爬坡事件主成分, 依据分量特性进行差异性预测^[72-73]; 另一种是在模型输出环节考虑相同气象条件下发生爬坡事件的概率特征, 利用相关性修正预测风电爬坡功率^[74]。

3.3 概率预测

由于风资源具有强的随机波动性, 因此以上确定性预测、事件预测等单点预测结果中不可避免地会包含由于数据不完整与模型不准确而造成的不确定性^[75]。为此, 需在单点预测的基础上发展概率预测, 以揭示预测误差的概率分布, 从而定量描述预测中的不确定性, 为电力系统经济调度、检修计划、市场交易等优化决策提供更为全面的信息。概率预测按照预测模型可分为基于历史数据的概率统计方法和基于集合 NWP 的集合预测方法。

概率统计方法是结合大量历史数据, 通过对风电功率自身或预测误差建模形成风电功率的概率密

度函数, 一般称为统计方法。根据是否假设建模对象服从已知分布, 可将概率预测模型划分为参数化模型和非参数化模型 2 类。其中, 参数化模型是用已知概率分布(如高斯分布、指数分布等)或分段耦合描述概率密度函数。王彩霞假设风电功率的预测误差服从经验分布, 通过参数回归方法构建了预测误差的概率密度函数, 并嵌套在单点预测结果上得到了概率预测区间^[76]。该类方法计算简单, 但固有的建模误差会影响预测分布的精度^[77]。非参数化模型不事先假设建模对象的分布特性, 而是通过分位点回归、核密度估计等数据分析方法直接计算出概率密度函数。甘迪在 1 维核密度估计的基础上扩展为考虑风电爬坡特性的 2 维核密度估计, 改进提升了小时级风电功率概率预测的精度^[78]。该类方法避免了不恰当模型假设引入的误差, 不会出现分布不合理的情况。近些年, 机器学习方法也被广泛应用于风电功率概率预测中。YANG M 采用稀疏贝叶斯学习方法构建了概率预测模型, 实现了对风电功率及趋势分量、扰动分量的概率预测^[79]。黎静华考虑风电混沌特性, 利用蚁群聚类算法强搜索能力及支持向量机强预测能力优化传统概率预测模型, 有效改善了预测模型的适应性^[80]。

另外一种应用较广泛的概率预测方法是集合预测方法, 该方法结合多个 NWP 预测结果构建风电功率的概率密度函数, 一般称为物理方法^[81]。与单值 NWP 相比, 该方法可提供更丰富的气象预报信息, 包括过滤法、降维法、直接法这 3 类。过滤法先将集合 NWP 数据转化为单点功率预测结果集合, 再经过后处理得到分布预测结果; 降维法先在集合 NWP 数据中提取趋势类及散布类信息, 再将其输入到概率预测模型中; 直接法是将集合 NWP 数据全部输入到概率预测模型中, 进行直接预测。样本复杂度的增加会导致集合预测方法的预测效率降低并消耗大量计算资源, 但该方法在一定程度上解决了单个模型输入数据的准确性、完整性以及预测模型对各影响因素刻画不精细的问题。

3.4 集群预测

当前风电分布规模已由发展初期的小规模、分散式转变为大规模、集群式, 集群预测对电力系统安全运行与经济调度的必要性日益凸显^[82]。该方法是通过关联分析区域内风电功率的特征信息, 对大空间范围内多个风电场组成的风电集群出力进行整体预测, 主要包括累加法、统计升尺度法以及空间

资源匹配法。

累加法是经典的风电功率集群预测方法^[83],是将区域内所有风电场的功率预测结果加和得到区域的风电功率预测值。该方法简单,但预测精度较低,适用于规模较小、稀疏分布的风电集群,对输入数据正确性有较高要求,若个别风电场的预测精度较差,则会拖累整个区域的预测水平。

统计升尺度法则利用各风电场功率与区域总功率的相关性,以区域内预测水平较好的风电场为基准,通过倍增或权重系数方式升尺度来预测整个区域的风电功率^[84]。首先选择数据完整性好、预测精度高且与集群总出力有较高相关性的风电场作为基准风电场,并预测基准风电场的功率;然后通过机器学习等方法建立以基准风电场出力为输入、集群总体出力为输出的统计升尺度模型;最后计算得到集群预测功率^[85-86]。丹麦科技大学开发的风电功率预测工具(wind power prediction tool, WPPT)是统计升尺度法的典型案例。该方法具有较好的预测精度,且其对数据的依赖性不高,但是基准风电场的选择难度较大。

空间资源匹配法是近些年比较热门的集群预测方法,该方法是将区域内所有风电场看作为整体的空间资源集合,通过空间资源相似度高的历史数据集合加权获得风电集群功率,最早由 Lobo M G 提出^[87]。首先构建包含历史风速、待预测风速的空间资源风速矩阵;然后计算历史时刻风速矩阵与预测时刻风速矩阵之间的欧式距离,得到欧式距离空间集合;进一步根据欧式距离设置距离门槛值,并根据空间距离计算权重系数,提取与风速对应的历史功率数据;最后根据权重系数对历史功率进行加权求和,从而得到风电集群功率预测结果^[88]。该方法需要的计算资源少且精度较高,但模型参数优化难度较大,适用于规模较大的风电集群。

4 功率预测系统及应用场景

4.1 风电功率预测厂家

国外风电功率预测技术研发工作起步较早,其预测方法及系统已比较成熟;而国内研究起步较晚,但发展较快,预测精度与国外先进水平相当。国内外风电功率预测在技术上没有太大差异,但在预测对象方面,中国的风电发展规划与并网运行特点给国内风电功率预测带来了独特的挑战。

1) 中国幅员辽阔,气候条件复杂,风电场大

多位于三北复杂地形区域。一方面,国内数值天气预报服务机构难以提供大尺度高精度的气象预测信息;另一方面,复杂气象、地形条件下,极端天气事件日益频繁,常规风电功率预测模型难以应对。

2) 中国风电装机规模大、场站接入分散,通过高电压长距离接入负荷中心。数量庞大、种类繁杂的风电机组间运行特性差异大,弱端电网接入、长距离电力传输运行方式下设备故障及限电弃风现象频发,这给风电功率预测建模带来了较大难度。

根据风电功率预测系统发展的时间先后顺序和成熟度,可将其发展历程分为3个阶段:1990年之前是起步阶段;1990—2000年是快速发展阶段;2000年至今是各类技术集中涌现阶段。表2总结了目前应用比较成熟的风电功率预测系统。近些年,随着功率预测系统市场的不断成熟,预测厂家结构未出现革新变化,但预测服务已逐步向定制化转变,以目标为导向提供了多样化技术支持和解决方案。

4.2 预测系统应用场景

建立高精度的风电功率预测系统,并根据预测结果科学制定调度运行方式,是保障电力系统安全和提升新能源消纳能力的重要手段。随着高比例新能源优化调度、市场化交易的不断深化,风电功率预测应用场景越来越趋于多样化,风电功率预测主要的应用场景如图6所示。

中长期预测主要关注风电年度、月度发电量情况。电网可结合中长期风电和负荷预测结果,制定风电年度电量计划及电网输变电设备检修计划等^[89];风电场可根据中长期资源评估情况优化场站选址及风电机组分布等。由于时间尺度长,精度相对较低,因此需要逐月根据预测结果滚动调整及更新。




图6 风电功率预测应用场景

Fig.6 Application scene of wind power forecasting

表 2 风电功率预测系统
Table 2 Wind power forecasting system

年份	预测系统	特点	采用方法	开发者	应用范围
1994	Prediktor	采用高分辨率有限区域模型, 预测时间为 3~36 h	物理方法	丹麦 Risø 国家可再生能源实验室	西班牙、丹麦、德国等
1994	WPPT	采用自适应回归最小平方根法与指数遗忘算法相结合	统计方法	丹麦科技大学	丹麦、澳大利亚、加拿大等
1998	eWind	采用中尺度 NWP 模式, 利用多种统计学模型预测风电功率	组合方法	美国 AWS Truewind	美国
2001	WPMS	利用 NWP 提供的气象数据作为输入量, 采用 ANN 建立预测模型	统计方法	德国太阳能研究所 ISET	德国
2001	Sipreólico	自适应风电场运行或 NWP 预测模型的变化, 不需要预校准	统计方法	西班牙马德里卡洛三世大学	葡萄牙、希娜
2002	ANEMOS	使用多个 NWP 模式, 适用内陆和海上的风能预报	组合方法	欧盟	英国、丹麦、法国、德国
2002	Previento	结合风电场具体条件对 NWP 结果进行空间细化	组合方法	德国奥尔登堡大学	德国
2003	Zephyr	综合 Prediktor 和 WPPT, 预测时间超过 6 h 采用 Prediktor, 低于 6 h 采用 WPPT	组合方法	丹麦 Risø 国家可再生能源实验室与丹麦科技大学	丹麦、澳大利亚
2003	LocalPred-RegioPred	基于自回归模型, 采用 CFD 对 NWP 的风速和风向进行微观计算	组合方法	西班牙国家可再生能源中心与西班牙能源、环境和技术研究中心	西班牙、爱尔兰
2005	WEPROG MSEPS	包括 2 个主要模型: 每 6 h 运行一次的天气预报系统和使用 SCADA 测量数据的功率预测系统	组合方法	爱尔兰科克大学	爱尔兰、丹麦、德国
2008	ANEMOS.plus and SafeWind	SafeWind 重点对极端天气预报, ANEMOS.plus 侧重更强的示范性	组合方法	欧盟	爱尔兰、丹麦、英国等
2008	WPFS	采用 B/S 结构, 可以跨平台运行; 最长预测未来 144 h 的风电功率	组合方法	中国电力科学研究院有限公司	吉林、江苏等 23 个省区
2010	FR3000F	采用基于中尺度 NWP 的物理方法和统计方法相结合的预测方法	组合方法	北京中科伏瑞电气技术有限公司	新疆、宁夏等省区
2011	NSF 3100	包括数据监测、功能预测、软件平台展示 3 个部分	组合模型	国网电力科学研究院	内蒙、江苏、甘肃等省区
2011	WINPOP	系统采用 SVM、ANN、自适应最小二乘法等算法进行风电功率预报	组合方法	中国气象局公共服务中心	北京、南京等地
2017	高精度风电功率预测系统	采用模块化设计风电功率预测系统, 支持多气象源接入和数据治理	组合模型	国能日新科技股份有限公司	甘肃、陕西、山西等省区

相比于中长期预测, 短期预测对精度有更高的要求。电网可根据短期预测结果调整机组组合方案、合理预留备用容量、优化机组发电计划^[90], 在保证发用电实时平衡的同时, 可提高电网对风电的消纳能力。考虑预测功率的不确定性, 可结合概率预测

信息差异化来描述不确定性带来的影响, 从而为电力系统经济调度提供更好的辅助决策。

相比于短期预测, 超短期预测乃至分钟级预测具有更高的精度和可信度。为满足电力系统发用电的实时平衡, 电网可根据超短期预测结果实时调整

电源发电计划及功率控制策略^[91], 从而实现“源-网-荷”协调控制。此外, 为应对极端天气影响, 可根据预测结果动态评估系统薄弱环节和潜在风险, 实现系统安全风险预警, 并制定相应的调频调峰支撑方案。

在电力市场环境下, 风电功率预测是发电企业(风电场)参与电力市场的基础条件。在中长期市场中, 中长期预测是保障风电场交易电量科学分解的前提, 预测结果的准确性将直接影响风电场的消纳水平和经济效益; 在日前市场中, 风电场可根据短期预测结果参与电力市场竞价, 预测结果的好坏将直接影响次日每时刻的竞价与电量; 在日内市场中, 根据超短期预测结果不断修正短期预测结果并调整日前市场中的每小时计划电量, 预测精度越高则在日内市场中需要买进或卖出的差额电量越少, 风电场发电经济性越高。

5 预测性能评价

风电功率预测评价可以全方位掌握预测系统的运行情况, 深度挖掘缺陷环节, 是风电功率预测模型优化、性能提升、预测系统选择的关键。

5.1 确定性预测评价

确定性预测误差在形式上表现为横向误差和纵向误差^[92]。其中, 纵向误差描述了给定时段内预测结果在垂直功率轴上与实测结果的偏差, 可用于预测数值偏大或偏小的情况; 横向误差描述了给定时段内预测结果在水平时间轴上与实测结果的偏差, 可用于预测序列超前或滞后的情况。

5.1.1 纵向误差评价

已有研究中常用的纵向误差评价指标^[93]包括绝对误差均值(mean error, ME)、平均绝对误差(mean absolute error, MAE)、均方根误差(root mean squared error, RMSE)、最大预测误差、分位数偏差率等。部分指标已纳入到风电功率预测相关标准和规范中。

平均绝对误差表达式为

$$e_{\text{MAE}} = \frac{\sum_{i=1}^N |x_i - y_i|}{N} \quad (1)$$

均方根误差表达式为

$$e_{\text{RMSE}} = \sqrt{\frac{\sum_{i=1}^N (x_i - y_i)^2}{NC_i}} \quad (2)$$

式中: x_i 为 i 时刻的实际功率; y_i 为 i 时刻的预测功

率; C_i 是 i 时刻的开机容量; N 为时刻总数。 $r=1-e_{\text{RMSE}}$, 即为预测准确率。

分位数偏差率包括分位数正偏差率和分位数负偏差率 2 种。其中, α 分位数正偏差率指将各点预测正偏差率从小到大排列, 选取 α 位置处单点预测的正偏差率; α 分位数负偏差率指将各点预测负偏差率从大到小排列, 选取 α 位置处单点预测的负偏差率。

5.1.2 横向误差评价

相关系数(correlation coefficient, CC)可以对比实测序列和预测序列之间的相似程度, 判断预测误差主要来源是横向误差还是纵向误差, 是衡量横向误差的常用指标。

相关系数 ρ_{CC} 表达式为

$$\rho_{\text{CC}} = \frac{\sum_{i=1}^N ((x_i - \bar{x}_i)(y_i - \bar{y}_i))}{\sqrt{\sum_{i=1}^N (x_i - \bar{x}_i)^2} \sqrt{\sum_{i=1}^N (y_i - \bar{y}_i)^2}} \quad (3)$$

式中: $\bar{x}_i$ 为所有实测功率数据样本的平均值; $\bar{y}_i$ 为所有预测功率数据样本的平均值。

但是相关系数无法量化横向误差, 因此本文提出采用横向偏差度(transverse deviation degree, TDD)来量化实测序列和预测序列之间的横向偏差程度。横向偏差度可根据式(4)求得。

$$\rho_{\text{CC}}(l) = \frac{\sum_{i=l+1}^N ((x_i - \bar{x}_i)(y_i - \bar{y}_i))}{\sqrt{\sum_{i=l+1}^N (x_i - \bar{x}_i)^2} \sqrt{\sum_{i=l+1}^N (y_i - \bar{y}_i)^2}} \quad (4)$$

式中, $\rho_{\text{CC}}(l)$ 为延时 l 的实际功率序列与预测功率序列之间的相关系数。最大时延相关系数对应的延时 l 即为横向偏差度。

5.2 事件预测评价

事件预测方法按建模对象可分针对事件状态预测和事件特征预测, 2 类预测方法在预测结果的呈现形式上存在很大差异, 故其相应的预测结果评价方法也有所不同。

5.2.1 状态预测评价

爬坡事件预测状态共有 4 类结果, 如表 3 所示。根据 4 种结果所表达的不同含义, 可建立描述事件预测全面性或准确性的指标^[94]。

命中率(hit rate, HR) σ_{HR} 描述了事件预测的全面性, 表示对实际发生的事件准确预测的概率, 其计算式为

表 3 事件状态预测的结果

Table 3 Prediction results of event states

预测结果	预测结果	
	观测结果发生	不发生
发生	TP(正确预测发生)	FP(误报)
不发生	FN(漏报)	TN(正确预测不发生)

$$\sigma_{HR} = \frac{N_{TP}}{N_{TP} + N_{FN}} \quad (5)$$

准确率(accuracy rate, AR) σ_{AR} 描述了事件预测的准确性,表示预测结果为发生且实际也发生的概率,与之对应的有误报率 $\sigma_{FAR}=1-\sigma_{AR}$ 。准确率的计算式为

$$\sigma_{AR} = \frac{N_{TP}}{N_{TP} + N_{FP}} \quad (6)$$

式中: N_{TP} 、 N_{FN} 和 N_{FP} 分别为正确预测发生、漏报和误报的次数。

除了以上2种关键指标外,频率偏差评分、关键成功指数、Peirce评分等指标也可用于评价事件状态预测结果的精度^[95]。

5.2.2 特征预测评价

爬坡事件特征量的预测与确定性预测具有相似性,多数确定性预测的评价指标(如平均绝对误差、均方根误差)可用于事件特征预测结果的评价中,但不能准确描述爬坡事件具备的部分特征,如时间滞后程度和爬坡捕获程度^[96]。

1) 爬坡时刻

识别出的爬坡事件时间滞后(或超前)现象时有发生,有学者提出利用时间扭曲指数(temporal distortion index, TDI)来评估爬坡时刻的预测误差,即时间校准偏差导致的误差。时间扭曲指数 T_{DI} 表达式为

$$T_{DI} = \frac{1}{n^2} \sum_{i=1}^{n-1} |(x_{i+1} - y_i)(x_{i+1} + x_i - y_{i+1} - y_i)| \quad (7)$$

式中: $X=\{x_1, x_2, \dots, x_n\}$,为实际功率序列; $Y=\{y_1, y_2, \dots, y_n\}$,为预测功率序列; n 为样本数量。时间扭曲指数越小,则表示爬坡时刻预测越准确。

2) 爬坡得分

基于旋转门(swinging door, SD)算法,通过设定开度取值来调整对爬坡事件的敏感程度,以爬坡得分 ramp score 指标来评价爬坡幅值的预测精度,可体现预测结果的爬坡捕获程度。爬坡得分 $S_{rampscore}$

表达式为

$$S_{rampscore} = \frac{1}{t_{\max} - t_{\min}} \int_{t_{\min}}^{t_{\max}} |S_D(x_t) - S_D(y_t)| dt \quad (8)$$

式中: $t_{\min}$ 和 $t_{\max}$ 分别为事件发生的起、止时间; $S_D(\cdot)$ 为经SD算法处理后该时刻的爬坡斜率; x_t 与 y_t 分别为 t 时刻的实际功率值与预测功率值。

5.3 概率预测评价

不同于确定性预测评价指标,概率预测的结果并不能通过传统的统计量(如相对偏差)来反映预测性能的优劣,一般通过可靠性和敏锐性指标进行评价^[97]。可靠性指预测变量的分布和观测变量的分布在统计上的一致性,反映了预测结果匹配观测值的能力。敏锐性反映了预测分布的集中度,分布越紧凑,包含的有效信息就越丰富。

5.3.1 区间覆盖概率(prediction intervals coverage probability, PICP)

区间覆盖概率描述了概率预测模型的可靠性,若预测模型于置信度 $1-\alpha$ 下获得的概率预测区间表示为 $[L^\alpha, U^\alpha]$,假设共有 N 个实际功率点 $x_i(i=1, 2, \dots, N)$,与之对应的 N 个预测区间为 $[L_i^\alpha, U_i^\alpha]$,则模型预测结果的覆盖概率^[98] p_{ICP} 可表示为

$$p_{ICP} = \frac{1}{N} \sum_{i=1}^N f(x \in [L_i^\alpha, U_i^\alpha]) \quad (9)$$

式中, $f(\cdot)$ 为示性函数,当 $x_i \in [L_i^\alpha, U_i^\alpha]$ 时取值为1,否则取值为0。

5.3.2 预测区间相对宽度(prediction intervals relative width, PIRW)

预测区间相对宽度越大,提供的信息就越少,概率预测效果也会受到影响。模型的敏锐性可由预测区间相对宽度指标^[99]来评价,定义为

$$P_{IRW} = \frac{1}{nR} \sum_{i=1}^n (U_i^\alpha - L_i^\alpha) \quad (10)$$

式中: P_{IRW} 为区间相对宽度指标; R 为目标值的最大值与最小值之差,采用 R 的目的是对平均区间宽度进行归一化处理。更小的 P_{IRW} 指标表征了预测模型更强的敏锐性。

5.3.3 Pinball 损失分数

对于分位数形式的概率预测结果,则可采用Pinball损失分数^[100]来评价,该指标可同时评价模型的可靠性与敏锐性。Pinball损失分数对距离指定分位数较远的实际值进行惩罚,得分越小,预测效果就越好。其计分方式为

$$p_{\text{inball}} = \begin{cases} (1-\alpha)(y_{i,\alpha} - x_i), & x_i < y_{i,\alpha} \\ \alpha(x_i - y_{i,\alpha}), & x_i \geq y_{i,\alpha} \end{cases} \quad (11)$$

式中: p_{inball} 为得分值; $y_{i,\alpha}$ 为 i 时刻概率预测结果 α 分位数对应的功率值。

此外, 概率预测评价指标还包括覆盖带宽准则、边际校准、连续排名概率得分等^[10]。

6 结论与展望

风电功率预测技术涵盖气象学、电气工程学和统计学等交叉应用学科, 是保障电网安全运行和风电高效接纳的重要技术手段。本文从业务流程角度综述了风电功率预测关键环节和技术体系, 虽然风电功率预测技术取得了长足发展, 但距离解决风电功率的不确定性影响仍存在较大的空间。目前, NWP 水平是制约风电功率预测精度提升的关键环节, 但 NWP 水平提升缓慢, 短期可通过以下技术提高预测水平:

1) 快速循环更新技术。模式定期更新的背景场中不包含云及水汽信息, 在启动一段时间后云及水汽才由参数化方案渐渐生成, 不利于初始条件预报。可采用快速循环更新的方法, 即令模式的背景场更新频率降低, 比如每 3 d 更新一次, 而其间的常规启动不再使用背景场, 改为使用上一次预报的预报场, 这样就在初始场中保留了上一次预报的云和水汽信息, 有利于提升区域模式初始条件预报精度及节省计算时间。

2) 定制参数化预报技术。不同地区的地形、地貌及天气类型差别很大, 应考虑有地区针对性的物理过程参数化方案组合, 而非对所有地区都使用同一套方案。对于地形、地貌复杂的风电场区域, 应在考虑计算资源的情况下, 尽可能地加密水平和垂直方向上的网格, 并对边界层和陆面过程等影响近地面风速的参数化方案进行细调。同时, 应考虑使用云分析手段同化局地的卫星、雷达、地基云图等观测资料, 以改进辐照度预报效果。

3) 人工智能建模技术。对于预测模型本身, 随着人工智能、大数据等前沿新兴技术的发展和成熟, 有望突破风电功率预测的技术瓶颈, 实现预测精度的显著提升。由于人工智能模型具有自学习能力, 包括深信度网络(deep belief network, DBN)、深度神经网络(deep neural network, DNN)以及循环神经网络(recurrent neural network, RNN)等, 与物理、

统计模型相比, 人工智能模型具有更高精度的预测结果, 如“机器学习+数据库”的数据挖掘技术将提高短期功率预测精度。

4) 在线互动预测技术。目前风电功率预测普遍采用“离线建模、模型封装、模型嵌入”的运行模式, 存在预测模型更新不及时、不能实时响应风电场运行状态等问题, 在一定程度上影响了预测精度。建立“在线建模、实时调整、集中分布”的在线互动预测方法, 对于提升预测模型的响应能力、提高预测精度意义重大。

参考文献 References

- [1] 张亚超, 刘开培, 廖小兵, 等. 含大规模风电的电力系统多时间尺度源荷协调调度模型研究[J]. 高电压技术, 2019, 45(2): 600-608. ZHANG Yachao, LIU Kaipei, LIAO Xiaobing, et al. Multi-time scale source-load coordination dispatch model for power system with large-scale wind power[J]. High Voltage Engineering, 2019, 45(2): 600-608.
- [2] 路朋, 叶林, 汤涌, 等. 基于模型预测控制的风电集群多时间尺度有功功率优化调度策略研究[J]. 中国电机工程学报, 2019, 39(22): 6572-6583. LU Peng, YE Lin, TANG Yong, et al. Multi-time scale active power optimal dispatch in wind power cluster based on model predictive control[J]. Proceedings of the CSEE, 2019, 39(22): 6572-6583.
- [3] 李薇, 龚旻彰, 时利香, 等. 基于区域气候模式的内蒙古地区风能资源预测评估[J]. 电网技术, 2020, 44(11): 4318-4327. LI Wei, GONG Huanzhang, SHI Lixiang, et al. Prediction and evaluation of wind energy resource in inner mongolia based on regional climate models[J]. Power System Technology, 2020, 44(11): 4318-4327.
- [4] LUJANO-ROJAS J M, OSÓRIO G J, MATIAS J C O, et al. A heuristic methodology to economic dispatch problem incorporating renewable power forecasting error and system reliability[J]. Renewable Energy, 2016, 87: 731-743.
- [5] KOU P, GAO F, GUAN X. Stochastic predictive control of battery energy storage for wind farm dispatching: using probabilistic wind power forecasts[J]. Renewable Energy, 2015, 80: 286-300.
- [6] 沈小军, 付雪姣. 基于改进光滑样条的风电机功率曲线建模方法[J]. 高电压技术, 2020, 46(7): 2418-2424. SHEN Xiaojun, FU Xuejiao. Modeling of wind turbine power curve based on improved smoothing spline[J]. High Voltage Engineering, 2020, 46(7): 2418-2424.
- [7] ERNST B, OAKLEAF B, AHLSTROM M L, et al. Predicting the wind[J]. IEEE Power and Energy Magazine, 2007, 5(6): 78-89.
- [8] 乔颖, 鲁宗相, 闵勇. 提高风电功率预测精度的方法[J]. 电网技术, 2017, 41(10): 3261-3268. QIAO Ying, LU Zongxiang, MIN Yong. Research & application of raising wind power prediction accuracy[J]. Power System Technology, 2017, 41(10): 3261-3268.
- [9] BAUER P, THORPE A, BRUNET G. The quiet revolution of numerical weather prediction[J]. Nature, 2015(525): 47-55.
- [10] 陈德辉, 薛纪善. 数值天气预报业务模式现状与展望[J]. 气象学报, 2004, 62(5): 623-633. CHEN Dehui, XUE Jishan. An overview on recent progresses of the operational numerical weather prediction models[J]. Acta Meteorologica Sinica, 2004, 62(5): 623-633.
- [11] 李泽椿, 毕宝贵, 金荣花, 等. 近 10 年中国现代天气预报的发展与应用[J]. 气象学报, 2014, 72(6): 1069-1078.

- LI Zechun, BI Baogui, JIN Ronghua, et al. The development and application of the modern weather forecast in China for the recent 10 years[J]. *Acta Meteorologica Sinica*, 2014, 72(6): 1069-1078.
- [12] 许小峰. 从物理模型到智能分析——降低天气预报不确定性的新探索[J]. *气象*, 2018, 44(3): 341-350.
- XU Xiaofeng. From physical model to intelligent analysis: a new exploration to reduce the uncertainty of weather forecast[J]. *Meteorological Monthly*, 2018, 44(3): 341-350.
- [13] BOUTTIER F, COURTIER P. Data assimilation concepts and methods[M]. *Meteorological Training Course Lecture Series*, 2002.
- [14] 官元红, 周广庆, 陆维松, 等. 资料同化方法的理论发展及应用综述[J]. *气象与减灾研究*, 2007, 30(4): 1-8.
- GUAN Yuanhong, ZHOU Guangqing, LU Weisong, et al. Theory development and application of data assimilation methods[J]. *Meteorology and Disaster Reduction Research*, 2007, 30(4): 1-8.
- [15] PANOFSKY H A. Objective weather-map analysis[J]. *J Meteor*, 1949, 5(6): 386-392.
- [16] GILCHRIST B, CRESSMAN G P. An experiment in objective analysis[J]. *Tellus*, 1954, 6(4): 309-318.
- [17] CRESSMAN G P. An operational objective analysis system[J]. *Monthly Weather Review*, 1959, 87(10): 367-374.
- [18] SASAKI Y. Some basic formalisms in numerical variational analysis[J]. *Monthly Weather Review*, 1970, 98(12): 875-883.
- [19] EVENSEN G. Sequential data assimilation with a nonlinear quasi-geotropic model using Monte Carlo methods to forecast error statistics[J]. *Journal of Geophysical Research*, 1994, 99(C5): 10143-10162.
- [20] THOMPSON T E, WICKER L J, WANG X, et al. A comparison between the local ensemble transform Kalman filter and the ensemble square root filter for the assimilation of radar data in convective scale models[J]. *Quarterly Journal of the Royal Meteorological Society*, 2015, 141(4): 1163-1176.
- [21] 张云济, 张福青. 集合资料同化方法在强雷暴天气预报中的应用[J]. *气象科学进展*, 2018, 8(3): 38-52.
- ZHANG Yunji, ZHANG Fuqing. A review on the ensemble-based data assimilations for severe convective storms[J]. *Advances in Meteorological Science and Technology*, 2018, 8(3): 38-52.
- [22] 马雷鸣, 鲍旭炜. 数值天气预报模式物理过程参数化方案的研究进展[J]. *地球科学进展*, 2019, 32(7): 679-687.
- MA Leiming, BAO Xuwei. Research progress on physical parameterization schemes in numerical weather prediction models[J]. *Advances in Earth Science*, 2019, 32(7): 679-687.
- [23] AKRADZIJA M, SEIFERT A, HEUS T. Fluctuations in a quasi-stationary shallow cumulus cloud ensemble[J]. *Nonlinear Processes in Geophysics*, 2015, 22(1): 65-85.
- [24] 朱 蓉, 徐大海. 中尺度数值模拟中的边界层多尺度湍流参数化方案[J]. *应用气象学报*, 2004, 15(5): 543-555.
- ZHU Rong, XU Dahai. Multi-scale turbulent planetary boundary layer parameterization in mesoscale numerical simulation[J]. *Journal of Applied Meteorological Sciences*, 2004, 15(5): 543-555.
- [25] HIN H H, DUDHIA J. Evaluation of PBL parameterizations in WRF at sub-kilometer grid spacings: turbulence statistics in the dry convective boundary layer[J]. *Monthly Weather Review*, 2016, 144(3): 1161-1177.
- [26] TAO W K, CHEN J P, LI Z, et al. Impact of aerosols on convective clouds and precipitation[J]. *Reviews of Geophysics*, 2012, 50(2): 1-62.
- [27] MORRISON H, TESSENDORF S A, IKEDA K, et al. Sensitivity of a simulated midlatitude squall line to parameterization of raindrop breakup[J]. *Monthly Weather Review*, 2012, 140(8): 2437-2460.
- [28] 薛禹胜, 郁 琛, 赵俊华, 等. 关于短期及超短期风电功率预测的评述[J]. *电力系统自动化*, 2015, 39(6): 141-151.
- XUE Yusheng, YU Chen, ZHAO Junhua, et al. A review on short-term and ultra-short-term wind power prediction[J]. *Automation of Electric Power Systems*, 2015, 39(6): 141-151.
- [29] 杨锡运, 张艳峰, 叶天泽, 等. 基于朴素贝叶斯的风电功率组合概率区间预测[J]. *高电压技术*, 2020, 46(3): 1099-1108.
- YANG Xiyun, ZHANG Yanfeng, YE Tianze, et al. Prediction of combination probability interval of wind power based on naive Bayes[J]. *High Voltage Engineering*, 2020, 46(3): 1099-1108.
- [30] 冯双磊, 王伟胜, 刘 纯, 等. 风电场功率预测物理方法研究[J]. *中国电机工程学报*, 2010, 30(2): 1-6.
- FENG Shuanglei, WANG Weisheng, LIU Chun, et al. Study on the physical approach to wind power prediction[J]. *Proceedings of the CSEE*, 2010, 30(2): 1-6.
- [31] CASSOLA F, BURLANDO M. Wind speed and wind energy forecast through Kalman filtering of numerical weather prediction model output[J]. *Applied Energy*, 2012, 99(6): 154-166.
- [32] MEN Z, YEE E, LIEN F S, et al. Short-term wind speed and power forecasting using an ensemble of mixture density neural networks[J]. *Renewable Energy*, 2016, 87(3): 129-135.
- [33] 谷兴凯, 范高峰, 王晓蓉, 等. 风电功率预测技术综述[J]. *电网技术*, 2007, 31(增刊 2): 335-338.
- GU Xing kai, FAN Gaofeng, WANG Xiaorong, et al. Summarization of wind power prediction technology[J]. *Power System Technology*, 2007, 31(Supplement 2): 335-338.
- [34] ALEXIADIS M C, DOKOPOULOS P S, SAHSAMNOGLOU H S, et al. Short term forecasting of wind speed and related electrical power[J]. *Solar Energy*, 1998, 63(1): 61-68.
- [35] ERDEM E, SHI J. ARMA based approaches for forecasting the tuple of wind speed and direction[J]. *Applied Energy*, 2011, 88(4): 1405-1414.
- [36] ROONENBROECK C, DAHL C M. Accurate medium-term wind power forecasting in a censored classification framework[J]. *Energy*, 2014, 73(7): 221-232.
- [37] 潘迪夫, 刘 辉, 李燕飞. 基于时间序列分析和卡尔曼滤波算法的风电场风速预测优化模型[J]. *电网技术*, 2008, 32(7): 82-86.
- PAN Difu, LIU Hui, LI Yanfei. A wind speed forecasting optimization model for wind farms based on time series analysis and Kalman filter algorithm[J]. *Power System Technology*, 2008, 32(7): 82-86.
- [38] 冬 雷, 王丽婕, 高 爽, 等. 基于混沌时间序列的大型风电场发电功率预测建模与研究[J]. *电工技术学报*, 2008, 23(12): 125-129.
- DONG Lei, WANG Lijie, GAO Shuang, et al. Modeling and analysis of prediction of wind power generation in the large wind farm based on chaotic time series[J]. *Transactions of China Electrotechnical Society*, 2008, 23(12): 125-129.
- [39] HU Q, ZHANG R, ZHOU Y. Transfer learning for short-term wind speed prediction with deep neural networks[J]. *Renewable Energy*, 2016, 87(3): 85-95.
- [40] 范高峰, 王伟胜, 刘 纯. 基于人工神经网络的风电功率短期预测系统[J]. *电网技术*, 2008, 32(22): 72-76.
- FAN Gaofeng, WANG Weisheng, LIU Chun. Artificial neural network based wind power short term prediction system[J]. *Power System Technology*, 2008, 32(22): 72-76.
- [41] KARINIOTAKIS G N, STAVRAKAKIS G S, NOGARET E F. Wind power forecasting using advanced neural networks models[J]. *IEEE Transactions on Energy Conversion*, 1996, 11(4): 762-767.
- [42] KUSIAK A, ZHANG Z. Short-horizon prediction of wind power: a data-driven approach[J]. *IEEE Transactions on Energy Conversion*, 2010, 25(4): 1112-1122.
- [43] HU Q, ZHANG S, Z XIE, et al. Noise model based vv-support vector regression with its application to short-term wind speed forecasting[J]. *Neural Networks*, 2014, 57(9): 1-11.
- [44] WU W, PENG M. A data mining approach combining k-means clustering with bagging neural network for short-term wind power forecasting[J]. *IEEE Internet of Things Journal*, 2017, 4(4): 979-986.
- [45] ZHENG D, ESEYE A T, ZHANG J, et al. Short-term wind power forecasting using a double-stage hierarchical ANFIS approach for energy management in microgrids[J]. *Protection and Control of Modern Power Systems*, 2017, 2(2): 136-145.

- [46] FENG C, CUI M, HODGE B M, et al. A data-driven multi-model methodology with deep feature selection for short-term wind forecasting[J]. *Applied Energy*, 2017, 190(15): 1245-1257.
- [47] 刘爱国, 薛云涛, 胡江鹭, 等. 基于 GA 优化 SVM 的风电功率的超短期预测[J]. *电力系统保护与控制*, 2015, 43(2): 90-95.
LIU Aiguo, XUE Yuntao, HU Jianglu, et al. Ultra-short term wind power forecasting based on SVM optimized by GA[J]. *Power System Protection and Control*, 2015, 43(2): 90-95.
- [48] 杨 茂, 张罗宾. 基于数据驱动的超短期风电功率预测综述[J]. *电力系统保护与控制*, 2019, 47(13): 171-186.
YANG Mao, ZHANG Luobin. Review on ultra-short term wind power forecasting based on data-driven approach[J]. *Power System Protection and Control*, 2019, 47(13): 171-186.
- [49] 朱乔木, 李弘毅, 王子琪, 等. 基于长短期记忆网络的风电场发电功率超短期预测[J]. *电网技术*, 2017, 41(12): 3797-3802.
ZHU Qiaomu, LI Hongyi, WANG Ziqi, et al. Short-term wind power forecasting based on LSTM[J]. *Power System Technology*, 2017, 41(12): 3797-3802.
- [50] WANG H Z, LI G Q, WANG G B, et al. Deep learning based ensemble approach for probabilistic wind power forecasting[J]. *Applied Energy*, 2017, 188: 56-70.
- [51] TASICARAOGU A, UZUNOGLU M. A review of combined approaches for prediction of short-term wind speed and power[J]. *Renewable & Sustainable Energy Reviews*, 2014, 34(6): 243-254.
- [52] WANG J, HU J, MA K, et al. A self-adaptive hybrid approach for wind speed forecasting[J]. *Renewable Energy*, 2015, 78: 374-385.
- [53] SHI J, GUO J, ZHENG S. Evaluation of hybrid forecasting approaches for wind speed and power generation time series[J]. *Renewable & Sustainable Energy Reviews*, 2012, 16(5): 3471-3480.
- [54] 王 铮, RUI Pestana, 冯双磊, 等. 基于加权系数动态修正的短期风电功率组合预测方法[J]. *电网技术*, 2017, 41(2): 500-707.
WANG Zheng, RUI Pestana, FENG Shuanglei, et al. Short-term wind power combination forecasting method based on dynamic coefficient updating[J]. *Power System Technology*, 2017, 41(2): 500-707.
- [55] 牛晨光, 游晓科, 赵震云, 等. 风电场发电功率短期预测组合模型研究[J]. *华北电力大学学报*, 2012, 39(3): 29-34.
NIU Chenguang, YOU Xiaoke, ZHAO Zhenyun, et al. Study on the combination model of short-term wind power generation prediction[J]. *Journal of North China Electric Power University*, 2012, 39(3): 29-34.
- [56] 叶瑞丽, 郭志忠, 刘瑞叶, 等. 基于小波包分解和改进 Elman 神经网络的风电场风速和风电功率预测[J]. *电工技术学报*, 2017, 32(21): 103-111.
YE Ruili, GUO Zhizhong, LIU Ruiye, et al. Wind speed and wind power forecasting method based on wavelet packet decomposition and improved elman neural network[J]. *Transactions of China Electrotechnical Society*, 2017, 32(21): 103-111.
- [57] 叶 林, 刘 鹏. 基于经验模态分解和支持向量机的短期风电功率组合预测模型[J]. *中国电机工程学报*, 2011, 31(31): 102-108.
YE Lin, LIU Peng. Combined model based on EMD-SVM for short-term wind power prediction[J]. *Proceedings of the CSEE*, 2011, 31(31): 102-108.
- [58] 刘兴杰, 岑添云, 郑文书, 等. 基于模糊粗糙集与改进聚类的神经网络风速预测[J]. *中国电机工程学报*, 2014, 34(19): 3162-3169.
LIU Xingjie, CEN Tianyun, ZHENG Wenshu, et al. Neural network wind speed prediction based on fuzzy rough set and improved clustering[J]. *Proceedings of the CSEE*, 2014, 34(19): 3162-3169.
- [59] 周松林, 茆美琴, 苏建徽. 基于主成分分析与人工神经网络的风电功率预测[J]. *电网技术*, 2011, 35(9): 128-132.
ZHOU Songlin, MAO Meiqin, SU Jianhui. Principal component analysis and artificial neural network[J]. *Power System Technology*, 2011, 35(9): 128-132.
- [60] 张颖超, 王雅晨, 邓 华, 等. 基于 IAFSA-BPNN 的短期风电功率预测[J]. *电力系统保护与控制*, 2017, 45(7): 58-63.
ZHANG Yingchao, WANG Yachen, DENG Hua, et al. IAFSA-BPNN for wind power probabilistic forecasting[J]. *Power System Protection and Control*, 2017, 45(7): 58-63.
- [61] GAO Y, QU C, ZHANG K. A hybrid method based on singular spectrum analysis, firefly algorithm, and BP neural network for short-term wind speed forecasting[J]. *Energies*, 2016, 9(10): 750-757.
- [62] 刘爱国, 薛云涛, 胡江鹭, 等. 基于 GA 优化 SVM 的风电功率的超短期预测[J]. *电力系统保护与控制*, 2015, 43(2): 90-95.
LIU Aiguo, XUE Yuntao, HU Jianglu, et al. Ultra-short-term wind power forecasting based on SVM optimized by GA[J]. *Power System Protection and Control*, 2015, 43(2): 90-95.
- [63] 茆美琴, 曹 雨, 周松林. 基于误差叠加修正的改进短期风电功率预测方法[J]. *电力系统自动化*, 2013, 37(23): 34-38.
MAO Meiqin, CAO Yu, ZHOU Songlin. Improved short-term wind power forecasting method based on accumulative error correction[J]. *Automation of Electric Power Systems*, 2013, 37(23): 34-38.
- [64] WANG Y, WANG J, WEI X. A hybrid wind speed forecasting model based on phase space reconstruction theory and Markov model: a case study of wind farms in northwest China[J]. *Energy*, 2015, 91(11): 556-572.
- [65] 张东英, 代 悦, 张 旭, 等. 风电爬坡事件研究综述及展望[J]. *电网技术*, 2018, 42(6): 1783-1792.
ZHANG Dongying, DAI Yue, ZHANG Xu, et al. Review and prospect of research on wind power ramp events frequency deviation[J]. *Power System Technology*, 2018, 42(6): 1783-1792.
- [66] ZAREIPOUR H, HUANG D, ROSEHART W. Wind power ramp events classification and forecasting: a data mining approach[C]//2011 IEEE Power & Energy Society General Meeting. Detroit, USA: IEEE, 2011: 12303644.
- [67] CUI M J, ZHANG J, FLORITA A R, et al. An optimized swinging door algorithm for identifying wind ramping events[J]. *IEEE Transactions on Sustainable Energy*, 2015, 7(1): 150-162.
- [68] 叶 林, 路 朋, 滕景竹, 等. 考虑风电功率爬坡的功率预测-校正模型[J]. *电力系统自动化*, 2019, 43(6): 49-56.
YE Lin, LU Peng, TENG Jingzhu, et al. Power prediction and correction model considering wind power ramping events[J]. *Automation of Electric Power Systems*, 2019, 43(6): 49-56.
- [69] CUI M J, ZHANG J, WANG Q, et al. A data-driven methodology for probabilistic wind power ramp forecasting[J]. *IEEE Transactions on Smart Grid*, 2019, 10(2): 1326-1338.
- [70] CUI M, VENKAT K, BRI-MATHIAS H, et al. A copula-based conditional probabilistic forecast model for wind power ramps[J]. *IEEE Transactions on Smart Grid*, 2019, 10(4): 3870-3882.
- [71] CUI M J, KE D P, SUN Y Z, et al. Probabilistic wind power ramp forecasting based on a scenario generation method[C]//2017 IEEE Power & Energy Society General Meeting. Chicago, USA: IEEE, 2017: 17543769.
- [72] 崔明建, 孙元章, 柯德平. 基于原子稀疏分解和 BP 神经网络的风电功率爬坡事件预测[J]. *电力系统自动化*, 2014, 38(12): 6-11.
CUI Mingjian, SUN Yunzhang, KE Deping. Prediction of wind power ramp based on sparse decomposition of atoms and BP neural network[J]. *Automation of Electric Power Systems*, 2014, 38(12): 6-11.
- [73] 匡洪海, 王建辉, 张瀚超, 等. 一种新型的风电功率爬坡段识别方法[J]. *电网技术*, 2019, 43(5): 1752-1759.
KUANG Honghai, WANG Jianhui, ZHANG Hanchao, et al. A novel wind power climbing section identification method[J]. *Power System Technology*, 2019, 43(5): 1752-1759.
- [74] 欧阳庭辉, 查晓明, 秦 亮, 等. 基于相似性修正的风电功率爬坡事件预测方法[J]. *中国电机工程学报*, 2017, 37(2): 572-580.
OUYANG Tinghui, ZHA Xiaoming, QIN Liang, et al. Wind power ramp events forecast method based on similarity correction[J]. *Proceedings of the CSEE*, 2017, 37(2): 572-580.
- [75] SIDERATOS G, HATZIARGYRIOU N D. An advanced statistical method for wind power forecasting[J]. *IEEE Transactions on Power Systems*, 2007, 22(1): 258-265.

- [76] 王彩霞, 鲁宗相, 乔颖, 等. 基于非参数回归模型的短期风电功率预测[J]. 电力系统自动化, 2010, 34(16): 78-82.
WANG Caixia, LU Zongxiang, QIAO Ying, et al. Short term wind power forecasting based on non-parametric regression model[J]. Automation of Electric Power Systems, 2010, 34(16): 78-82.
- [77] SIDERATOS G, HATZIGARGYRIOU N D. Probabilistic wind power forecasting using radial basis function neural networks[J]. IEEE Transactions on Power Systems, 2012, 27(4): 1788-1796.
- [78] 甘迪, 柯德平, 孙元章, 等. 考虑爬坡特性的短期风电功率概率预测[J]. 电力自动化设备, 2016, 36(4): 145-150.
GAN Di, KE Deping, SUN Yuanzhang, et al. Short-term probabilistic wind power forecast considering ramp characteristics[J]. Electric Power Automation Equipment, 2016, 36(4): 145-150.
- [79] YANG M, FAN S, LEE W. Probabilistic short-term wind power forecast using componential sparse Bayesian learning[J]. IEEE Transactions on Industry Application, 2013, 49(6): 2783-2793.
- [80] 黎静华, 黄玉金, 黄乾. 基于改进混沌时间序列的风电功率区间预测方法[J]. 电力自动化设备, 2019, 39(5): 53-58.
LI Jinghua, HUANG Yujin, HUANG Qian. Interval prediction method of wind power based on improved chaotic time series[J]. Electric Power Automation Equipment, 2019, 39(5): 53-58.
- [81] ZHAO J, GUO Z H, SU Z Y, et al. An improved multi-step forecasting model based on WRF ensembles and creative fuzzy systems for wind speed[J]. Applied Energy, 2016, 162: 808-826.
- [82] 刘燕华, 刘冲, 李伟花, 等. 基于出力模式匹配的风电集群点多时间尺度功率预测[J]. 中国电机工程学报, 2014, 34(25): 4350-4358.
LIU Yanhua, LIU Chong, LI Weihua, et al. Multi-time scale power prediction of wind farm cluster based on profile pattern matching[J]. Proceedings of the CSEE, 2014, 34(25): 4350-4358.
- [83] 叶林, 赵永宁. 基于空间相关性的风电功率预测研究综述[J]. 电力系统自动化, 2014, 38(14): 126-135.
YE Ning, ZHAO Yongning. A review on wind power prediction based on spatial correlation approach[J]. Automation of Electric Power Systems, 2014, 38(14): 126-135.
- [84] 彭小圣, 熊磊, 文劭宇, 等. 风电集群短期及超短期功率预测精度改进方法综述[J]. 中国电机工程学报, 2016, 36(23): 6315-6326.
PENG Xiaosheng, XIONG Lei, WEN Jinyu, et al. A summary of the state of the art for short-term and ultra-short-term wind power prediction of regions[J]. Proceedings of the CSEE, 2016, 36(23): 6315-6326.
- [85] 陈颖, 孙荣富, 吴志坚, 等. 基于统计升尺度方法的区域风电场群功率预测[J]. 电力系统自动化, 2013, 37(7): 1-5.
CHEN Ying, SUN Rongfu, WU Zhijian, et al. A regional wind power forecasting method based on statistical upscaling approach[J]. Automation of Electric Power Systems, 2013, 37(7): 1-5.
- [86] 王尤嘉, 鲁宗相, 乔颖, 等. 基于特征聚类的区域风电短期功率统计升尺度预测[J]. 电网技术, 2017, 41(5): 1383-1389.
WANG Youjia, LU Zongxiang, QIAO Ying, et al. Short-term regional wind power statistical upscaling forecasting based on feature clustering[J]. Power System Technology, 2017, 41(5): 1383-1389.
- [87] LOBO M G, SANCHEZ I. Regional wind power forecasting based on smoothing techniques with application to the Spanish peninsular system[J]. IEEE Transactions on Power Systems, 2012, 27(4): 1990-1997.
- [88] 彭小圣, 樊闻翰, 王勃, 等. 基于改进空间资源匹配法的风电集群功率预测技术[J]. 电力建设, 2017, 38(7): 10-17.
PENG Xiaosheng, FAN Wenhan, WANG Bo, et al. A lifting spatial resources matching approach based wind power prediction of regions[J]. Electric Power Construction, 2017, 38(7): 10-17.
- [89] 周明, 夏澍, 李琰, 等. 含风电的电力系统月度机组组合和检修计划联合优化调度[J]. 中国电机工程学报, 2015, 35(7): 1587-1595.
ZHOU Ming, XIA Shu, LI Yan, et al. A joint optimization approach on monthly unit commitment and maintenance scheduling for wind power integrated power systems[J]. Proceedings of the CSEE, 2015, 35(7): 1587-1595.
- [90] 蒋宇, 陈星莺, 余昆, 等. 考虑风电功率预测不确定性的日前发电计划鲁棒优化方法[J]. 电力系统自动化, 2018, 42(19): 57-63.
JIANG Yu, CHEN Xinying, YU Kun, et al. Robust optimization method for day-ahead generation scheduling considering prediction uncertainty of wind power[J]. Automation of Electric Power Systems, 2018, 42(19): 57-63.
- [91] 叶林, 陈超宇, 张慈杭, 等. 基于分布式模型预测控制的风电场参与 AGC 控制方法[J]. 电网技术, 2019, 43(9): 3261-3270.
YE Lin, CHEN Chaoyu, ZHANG Cihang, et al. Wind farm participating in AGC based on distributed model predictive control[J]. Power System Technology, 2019, 43(9): 3261-3270.
- [92] 徐曼, 乔颖, 鲁宗相. 短期风电功率预测误差综合评价方法[J]. 电力系统自动化, 2011, 35(12): 20-26.
XU Man, QIAO Ying, LU Zongxiang. A comprehensive error evaluation method for short-term wind power prediction[J]. Automation of Electric Power Systems, 2011, 35(12): 20-26.
- [93] FOLEY A M, LEAHY P G, MARVUGLIA A, et al. Current methods and advances in forecasting of wind power generation[J]. Renewable Energy, 2012, 37(1): 1-8.
- [94] GALLEGO-CASTILLO C, CUERVA-TEIER A, LOPEZ-GARCIA O. A review on the recent history of wind power ramp forecasting[J]. Renewable & Sustainable Energy Reviews, 2015, 52(12): 1148-1157.
- [95] MILLIGAN M, PORTER K, DEMEO E, et al. Wind power myths debunked[J]. IEEE Power & Energy Magazine, 2009, 7(6): 89-99.
- [96] JOLLIFFE I T, STEPHENSON D B. Forecast verification: a practitioner's guide in atmospheric science[M]. USA: Wiley, 2012.
- [97] PINSON P, NIELSEN H A, MOLLER J K, et al. Nonparametric probabilistic forecasts of wind power: required properties and evaluation[J]. Wind Energy, 2007, 10(6): 497-516.
- [98] PINSON P, JUBAN J, KARINIOTAKIS G N. On the quality and value of probabilistic forecasts of wind generation. in probabilistic methods applied to power systems[C]//2006 International Conference on Probabilistic Methods Applied to Power Systems. Stockholm, Sweden: IEEE, 2006: 9464127.
- [99] GNEITING T, BALABDAOUI F, RAFTERY A E. Probabilistic forecasts, calibration and sharpness[J]. Journal of the Royal Statistical Society, 2007, 69(2): 243-268.
- [100] BIAU G, PATRA B. Sequential quantile prediction of time series[J]. IEEE Transactions on Information Theory, 2011, 57(3): 1664-1674.
- [101] 吴问足, 乔颖, 鲁宗相, 等. 风电功率概率预测方法及展望[J]. 电力系统自动化, 2017, 41(18): 167-175.
WU Wenzu, QIAO Ying, LU Zongxiang, et al. Methods and prospects for probabilistic forecasting of wind power[J]. Automation of Electric Power Systems, 2017, 41(18): 167-175.



SUN Rongfu
Ph.D., Professor



XU Haixiang
Senior engineer
Corresponding author

孙荣富

1982—, 男, 博士, 教授级高工
主要从事风电调度、风电功率预测和电力系统运行可靠性分析方面的研究工作
E-mail: hcxsrf@163.com

徐海翔(通信作者)

1988—, 男, 硕士, 高工
主要从事新能源功率预测、新能源优化调度方面的研究工作
E-mail: xhx0617@foxmail.com