

人工智能技术在新能源功率预测的应用及展望

朱琼锋¹, 李家腾^{1*}, 乔骥¹, 史梦洁¹, 王朝亮²

(1. 中国电力科学研究院有限公司, 北京市 海淀区 100192;

2. 国网浙江省电力有限公司营销服务中心, 浙江省 杭州市 310000)

Application and Prospect of Artificial Intelligence Technology in Renewable Energy Forecasting

ZHU Qiongfeng¹, LI Jiateng^{1*}, QIAO Ji¹, SHI Mengjie¹, WANG Chaoliang²

(1. China Electric Power Research Institute, Haidian District, Beijing 100192, China;

2. State Grid Zhejiang Marketing Service Centre, Hangzhou 310000, Zhejiang Province, China)

ABSTRACT: Building a new power system is one of the main measures to achieve the "carbon peak and carbon neutrality" strategic goal. Wind power and photovoltaic power generation are the most representative renewable energy, and their volatility and randomness have brought major challenges to grid security and renewable energy consumption; while renewable energy power prediction is the key technology to reduce its random impact. In recent years, with the successful application of big data technology and the latest artificial intelligence (AI) technology represented by deep learning and reinforcement learning in many fields, its application in renewable energy power forecasting is still in the ascendant. This paper first briefly discusses the theoretical basis of AI technology in the application of renewable energy power forecasting, and systematically summarizes the application of AI technology in wind power and photovoltaic power forecasting, including the application of various data processing technologies such as data enhancement and feature construction, application of traditional machine learning, deep learning, combined algorithms in model construction, the application of evolutionary algorithm, swarm intelligence optimization, reinforcement learning, and other intelligent optimization algorithms in model training and hyperparameter optimization. Then, the current related literature is statistically analyzed. Based on the results of the renewable energy forecasting contest as well as the actual forecasting system research situation, the current academic research hotspots and trends, and the application of industrial models are compared and analyzed. Finally, some problems existing in the current renewable energy power forecasting in scene adaptation,

few-shot learning, numerical weather prediction (NWP) data spatio-temporal resolution, distributed renewable energy prediction, etc. are analyzed, and the prospects of a variety of AI technologies such as reinforcement learning, meta-learning, graph neural network(GNN), to solve related problems are prospected.

KEY WORDS: wind power generation; photovoltaic power generation; power prediction; artificial intelligence (AI) technology

摘要: 构建新型电力系统是实现我国“双碳”战略目标的主要举措之一, 风力发电和光伏发电作为两种最具代表性的新能源, 其波动性和随机性给电网安全和新能源消纳带来了重大挑战, 新能源功率预测是降低其随机性影响的核心关键技术。近年来, 随着大数据技术和以深度学习、强化学习为代表的新一代人工智能(artificial intelligence, AI)技术在诸多领域的成功应用, 其在新能源功率预测方面的应用仍有方兴未艾之势。首先该文论述 AI 技术在新能源功率预测应用的理论基础, 并对 AI 技术在风电和光伏功率预测方面的应用进行系统总结, 包括数据增强和特征构建等多种数据处理技术的应用, 传统机器学习算法、深度学习算法以及组合算法在模型构建方面的应用, 以及进化算法、群智能优化算法、强化学习等多种智能优化算法在模型训练和超参数优化方面的应用。然后, 对当前相关文献进行统计分析, 并基于新能源预测大赛结果和实际预测系统调研情况, 对当前学术界研究热点和趋势、产业界模型应用情况进行对比和分析。最后, 对当前新能源功率预测在场景自适应、小样本学习、数值天气预报系统(numerical weather prediction, NWP)数据时空分辨率、分布式新能源预测等方面存在的一些问题进行剖析, 并对采用强化学习、元学习、图神经网络(graph neural network, GNN)等多种 AI 技术解决相关问题的前景进行展望。

关键词: 风力发电; 光伏发电; 功率预测; 人工智能技术

基金项目: 国家重点研发计划项目(2020YFB0905900)。

National Key R&D Program of China (2020YFB0905900)。

0 引言

为落实“碳达峰碳中和”的能源战略目标,预计到2060年,全社会用电量将超过16万亿kW·h,新能源发电装机达到50亿kW,新能源发电量占比将由目前的8%提高到60%以上^[1]。

风力发电和光伏发电是当前最主流的两种新能源发电形式,截至2020年底,我国风电光伏装机总量分别达2.81亿kW、2.53亿kW,同比增长34.6%、24.1%。然而,由于风力发电和光伏发电受气象因素、日夜周期等因素影响较大,具有强波动性和间歇性。高比例的新能源接入电力系统后给电网安全稳定造成了较大风险,也增加了调度运行的难度。

新能源功率预测是降低新能源出力随机性不利影响的一项关键技术,一般基于气象预报数据、新能源功率数据和气象观测数据等动态数据,结合新能源场站位置和设备参数等信息进行建模,预测未来一段时间内新能源的出力变化趋势,能够有力

支撑电网调度、检修计划、安稳分析、新能源消纳分析等多项业务开展^[2-5]。未来,随着电力交易市场的成熟以及整县式光伏的大力推进,大量分布式新能源接入配电网,新能源功率预测有望进一步支撑绿电交易、综合能源服务、需求响应等多项新型电力业务的开展^[6-9]。

新能源功率预测可按照不同维度进行分类,按照时间尺度可分为超短期、短期、中长期预测;按照空间尺度可分为单机预测、单场站预测、区域预测;按预测结果可分为点预测、概率预测以及事件预测;按照建模方法可分为物理建模方法、时间序列建模方法、基于机器学习和深度学习等人工智能(artificial intelligence, AI)技术的建模方法,本文聚焦于AI技术建模方法,图1为新能源功率预测技术框架。

早期的物理建模方法过程复杂,要求建模人员具有很强的专业领域知识并且模型参数获取难,而



图1 基于AI的新能源功率预测技术框架

Fig. 1 Renewable energy power prediction technology framework based on AI technology

时间序列预测模型非线性拟合能力和高维数据处理能力差,因此这两类传统方法现在已较少研究。近年来,以数据驱动为核心的 AI 技术得到了快速发展,从浅层的传统机器学习算法逐步演化为以深度学习为代表的新一代 AI 技术,有效提高了新能源功率预测的准确性和高效性^[10-12]。

相比物理建模方法、时间序列建模方法等传统非 AI 方法,基于 AI 的预测模型具有诸多优点,其对高维非线性样本空间具有良好的拟合能力,同时模型参数基于数据训练得到,容易获取,模型的输入特征亦可灵活构建,结合智能优化算法还可进行参数自动寻优,进一步省去了人工调参的工作量。尤其在新能源功率预测,区域预测,复杂时空特性关联性挖掘等特殊场景下更是具有传统非 AI 方法不可比拟的优势。

首先,本文对 AI 技术在新能源功率预测应用的理论基础进行论述,并基于该理论框架对新能源功率物理建模方法和数据驱动方法进行论述和对比。

然后,对 AI 技术在新能源功率预测的应用进行总结,主要包括模型输入、模型构建和参数优化 3 个方面,其中模型输入包括数据预处理、数据增强和特征构建方面的应用。模型构建主要涉及传统机器学习算法,代表性算法包括支持向量机(support vector machine, SVM)、梯度提升决策树(gradient boosting decision tree, GBDT)以及各种传统的浅层神经网络^[13-15];基于深度学习的新一代 AI 技术,代表性算法包括多层卷积神经网络和循环神经网络;以及组合多种 AI 算法的组合预测技术^[16-18]。模型参数优化包括模型训练和模型超参数优化,典型算法包括遗传算法等静态优化算法和强化学习等动态优化算法。

其次,通过选取当前新能源功率预测领域主流学术期刊近年来的相关文献进行统计分析,得出当前该领域在学术界的研究热点和趋势。由于参考文献中所用方法的预测结果往往基于不同的预测场景,所用数据也差别很大,难以通过对文献中结果的复现来比较各方法优缺点,因此本文选取全球能源预测大赛这一较有影响力的赛事,根据比赛结果排名对各方法在实际应用中的预测水平进行了对比分析,由于排除了预测场景和数据差异性,所得结论更具有客观性,具有一定参考价值,并结合实际预测系统中模型应用情况,对产业界模型应用情况进行了分析。

最后,对新能源功率预测当前存在的问题与不足进行剖析,并结合当前新兴 AI 技术的特点和优势分析,对每类问题可能的解决方案进行了展望。

1 AI 技术新能源功率预测应用的理论基础

新能源功率预测问题在数学意义上的本质可从机器学习中回归任务的通用范式来理解。其目的是构建一个最佳映射模型 h , 根据从输入空间中 $\mathcal{X}$ 采样得到的样本 $\mathbf{x}$, 去预测输出空间 $\mathcal{Y}$ 中对应的 $\mathbf{y}$ 。模型的输入空间 $\mathcal{X}$ 对应预测模型的输入,对于新能源功率预测而言,一般包括历史功率数据、历史气象观测数据和气象预测数据 3 种类型。模型输出空间 $\mathcal{Y}$ 对应预测功率,为一维空间时对应单步预测,为多维空间时对应多步预测。预测模型 h 一般具有参数 Φ , 可表示为 $h(\mathbf{x}, \Phi)$ 。

为了评价预测效果好坏,需构建一个损失函数 L , 其实质是一个度量 $h(\mathbf{x}, \Phi)$ 和 $\mathbf{y}$ 接近程度的度量函数, L 取值和 $h(\mathbf{x}, \Phi)$ 与 $\mathbf{y}$ 之间距离成正相关,当 $h(\mathbf{x}, \Phi) = \mathbf{y}$ 时, L 取最小。

由于损失函数只针对单个样本点的预测效果进行评价,因此定义期望风险为损失函数值在输入输出空间上的期望值:

$$E(h) = \int L[h(\mathbf{x}, \Phi), \mathbf{y}] dP(\mathbf{x}, \mathbf{y}) \quad (1)$$

目的是找到使式(1)期望风险最小的预测模型,即最优预测模型满足:

$$h^* = \arg \min_h E(h) \quad (2)$$

求式(2)最优模型有 2 种思路,一种是基于从输入空间 $\mathcal{X}$ 到输出空间 $\mathcal{Y}$ 映射的先验知识直接构建模型,此时模型的构建不需要任何数据,其精度完全依赖于知识的准确程度,该方法对应于新能源功率预测的物理建模方法,物理模型中参数 Φ 往往都具有明确的物理含义,一般根据试验和测试手段或者厂家产品手册取得。本文主要侧重 AI 技术在新能源功率预测的应用,因此针对物理建模方法,仅以光伏功率预测为例进行简要论述。

图 2 为光伏发电功率短期预测的物理方法技术路线。基本思路是利用辐照度、温度等数值天气预报数据,结合光伏电站的地理信息,采用太阳位置模型得到光伏电池板接受到的有效辐照度,然后利用构建的光伏电池板光电转换模型和逆变器效率模型,得到单逆变器最终的输出功率,最后考虑线路损耗得到光伏电站全场的发电功率。




图 2 光伏发电功率短期预测的物理方法技术路线

Fig. 2 Physical method and technical route of photo-voltaic power prediction

求解式(2)的另一种思路是基于数据驱动的方式,即依据从原始输入输出空间中采样的给定样本集 $\{(x_1, y_1), (x_2, y_2), \dots, (x_m, y_m)\}$,求使得以下经验风险最小的模型 h :

$$\hat{E}(h) = \frac{1}{m} \sum_{i=1}^m L(h(x_i; \Phi), y_i) \tag{3}$$

此时对应的最优模型为

$$\hat{h}^* = \arg \min_h \hat{E}(h) \tag{4}$$

由于 $x_i \in \mathcal{X}$, $y_i \in \mathcal{Y}$, 根据大数定理,当训练样本足够多时,经验风险收敛于期望风险,如下:

$$E(h) = \lim_{m \rightarrow +\infty} \hat{E}(h) = \lim_{m \rightarrow +\infty} \frac{1}{m} \sum_{i=1}^m L(h(x_i; \Phi), y_i) \tag{5}$$

因此在样本量足够时,通过求式(4)来逼近式(2)是可行的,然而当模型复杂度过高而样本量又不足时,此时可能发生拟合,一般通过在经验风险的基础上增加正则项 $J(h)$ 来限制模型复杂度,此时对应模型的结构风险:

$$E_s(h) = \hat{E}(h) + J(h) \tag{6}$$

而优化目标变为

$$\hat{h}^* = \arg \min_h \hat{E}_s(h) \tag{7}$$

正则项 $J(h)$ 为跟模型复杂度正相关的函数,因此求式(7)在使得经验风险最小的同时也会限制模型复杂度,从而避免过拟合发生。

新能源功率预测中数据驱动模型主要包括时间序列建模方法、基于机器学习和深度学习等 AI 技术的建模方法。对于大部分数据驱动模型而言,模型参数可分为 2 个部分,即 $\Phi = \{\theta, \Theta\}$, 其中 θ 对应模型的训练参数(一般机器学习算法中简称为模型参数),而 Θ 对应模型的超参数,前者主要采用特定机器学习算法训练得到,后者一般根据经验人为设定。

表 1 为采用物理机理建模和采用 AI 方法建模的主要区别,可知, AI 方法在建模难度、数据输入处理能力、预测的时空尺度适用性等方面均优于物理模型,但是其也存在可解释性弱,同时建模对历史数据要求较高的问题。

表 1 物理模型和 AI 模型对比

Table 1 Comparison of physical model and AI model

预测方法	物理模型	AI 模型
建模难度	综合气象、电气、电子、机械等多个学科知识,专业性要求高	具备多种通用模型,并配套成熟工具包,建模简单
模型参数获取难度	基于试验测试或产品手册,参数获取难度高	通过模型训练得到,较为容易
数据输入	NWP 数据	历史功率和历史气象观测数据、NWP 数据
预测空间尺度适用性	适用于单机建模,应用于场站和区域预测时需进行二次建模	可直接用于单机、单场站以及区域预测
预测时间尺度适用性	受限于 NWP 精度,一般用于短期预测	可用于分钟级、超短期预测,也可用于短期预测
可解释性	强	弱
建模数据要求	仅需要场站信息、设备参数等静态信息,不需要功率气象等历史数据	需要大量历史气象和功率数据,数据量少时

综上所述,使经验风险最小化的 $\hat{h}^*$ 由模型结构 h 和模型参数 Φ 决定,这 2 个因素对预测精度有重要影响,而模型输入 x 也是另一个重要影响因素。因此,本文后续第 2、3、4 节分别从模型数据输入、模型构建、模型参数优化这 3 个方面对现有文献中相关 AI 技术的应用进行了总结和论述。其中模型输入包括数据预处理、数据增强和特征构建方面的应用。模型构建主要涉及传统机器学习算法和基于深度学习的新一代 AI 技术。模型参数优化包括遗传算法等静态优化算法和强化学习等动态优化算法在模型训练和模型超参数优化方面的应用。

2 数据处理及特征构建

新能源功率预测数据主要包含从地理信息系统(geographic information system, GIS)、数据采集与监控系统(supervisory control and data acquisition,

SCADA)、NWP^[19]等采集到的海量信息和数据,具体包括装机容量配置、风电机组的风速-功率曲线、光伏组件的光电转换效率等静态信息,以及新能源发电功率数据、风速、风向、辐照度、气温、湿度等微气象实测数据和NWP数据等动态数据,对于光伏功率预测常用的还有地基云图和卫星云图数据^[20]等。以上数据在获取方式、物理含义、计量单位、数据类型、数据量级、采样频率等方面均有较大差异,因此进行数据预处理、特征工程构建等必不可少。

2.1 数据预处理

由于环境因素、电站设备故障、通信网络异常、人为因素等诸多随机性原因,原始数据中不可避免的存在大量异常和缺失数据,在新能源功率预测之前需要对原始数据进行预处理,主要包括数据异常值处理和缺失值补全。

2.1.1 异常值处理

新能源出力受多种气象因素影响,但对于风电功率,其最大影响因素为风速,而光伏功率受辐照度的影响最大。对于不能正常反应风速-风电功率和辐照度-光伏功率的数据,将其称为异常数据。异常数据的产生主要来自2个方面,一是数据测量、通讯等环节出现故障或干扰,导致数据的异常和缺失^[21];二是因电网接纳能力有限而造成的弃风弃光现象,形成由人为因素造成的异常。图3为典型风电功率异常数据。




图3 典型风电功率异常数据

Fig. 3 Typical abnormal wind power data

目前,许多学者已经对新能源异常数据处理进行研究^[22-27],常用的异常值识别方法主要有四分位法、聚类分析、最优熵、内方差算法^[22]等,还可以利用新能源基本运行特性建立置信等效区间进行识别^[23]。

文献[24]将风电场异常数据分为分散型和堆积型,提出一种基于四分位法和聚类分析的异常数据组合筛选模型。利用2次四分位法剔除常规的分散型异常数据,利用聚类法剔除堆积型异常数。文

献[25]提出一种用于识别风电机组发电异常数据的云分段最优熵算法,该算法基于风电机组的风速-功率曲线,采用云模型的熵对机组发电数据集进行分离,从而识别异常数据。

2.1.2 数据插值

在异常数据识别的基础上,需要对异常数据和缺失数据进行补全,尽可能保证历史数据的时序完整性。缺失数据重构的重点在于构建数据填补模型,现有研究主要从空间相关性和时间相关性2个维度,利用数据插值的方法对缺失数据进行重构,其中Hermite插值法、四点插值、三次样条插值等常见算法主要是基于数据的时间相关性进行插值,但是由于插值模型拟合能力较差,在缺失序列数据较长时往往效果不佳。文献[28]基于空间插值方法得到水平总辐照度,再依据水平总辐照度,采用神经网络对光伏方阵面辐照度数据进行重构,进而计算出光伏历史出力数据,由于该方法需要其他具有空间相关性的辅助量测值作为输入,实际应用时存在一定局限性。文献[29]设计了一种适于处理一维时间序列的GAN结构,用于对电压、电流、有功和无功功率等电力系统量测缺失数据进行重构。由于其内部的生成器和对抗器结构采用深度神经网络等拟合能力较强的模型,在大量量测值出现缺失的情况下仍具有较高的重建精度,并且由于其基于时间相关性进行插值,不依赖于其他辅助量测值,因此具有较大的研究价值。

2.2 数据增强

基于数据驱动的新能源发电功率预测方法,高度依赖大量历史数据对模型进行训练,现有文献中针对新能源预测采用的数据增强方法主要有迁移学习^[30-32]、深度学习^[33]、生成对抗网络^[34]。

对于新建的新能源场站,历史运行功率数据积累不足,难以支撑模型的训练。文献[30]基于辐照度和功率数据的相关性分析,采用辐照度数据作为源数据,而功率数据作为目标数据,提出一种基于长短期记忆(long short-term memory, LSTM)网络的迁移学习方法,该方法如图4所示。

除了新建场站缺少功率数据以外,对于多数分布式新能源场站由于数据获取成本较高等原因,也存在NWP数据样本不足的问题。文献[33]利用少数完备站点及中尺度数值天气预报,引入三维卷积神经网络,同时对气象数据的空间相关性和时间相关性进行拟合,基于完备站点的NWP信息,得到信




图4 基于迁移学习的模型训练

Fig. 4 Model training based on transfer learning

息全黑站点的NWP数据。

此外,也有其他应用场景面临预测模型训练样本不足的问题,比如常用的基于天气类型分型的新能源功率预测方法通过提高模型的场景适应性,从而提高预测精度,但是该类方法的一个缺点是天气分型之后的数据样本量明显变少,这又容易导致模型的过拟合,文献[34]提出一种采用生成对抗网络对各种类型天气情况下辐照度数据进行数据增强的方法,基于少量样本学习生成对抗网络,再在样本空间中采样生成新数据,从而有效弥补了天气分型后样本量不足的问题。采用GAN网络生成新能源气象观测样本数据方法如图5所示。




图5 采用GAN网络生成新能源样本数据

Fig. 5 Renewable energy sample enhancement technology based on generative adversarial networks

2.3 特征构建

利用机器学习模型对新能源功率预测,其中重要环节就是利用收集到的历史数据对模型进行训练。而原始数据往往包含多重冗余信息,直接利用所有特征进行训练会导致模型训练困难。因此,在模型训练之前需要进行特征构建,主要包括特征选择和特征降维。

2.3.1 特征选择

特征选择是从原始输入变量中选择对输出变量影响大的因素,目的在于尽可能包含原始变量所

含重要信息的同时,避免输入冗余信息,压缩模型训练时间,提高模型的泛化能力和预测精度。当前机器学习领域常用的特征选择方法可分为过滤式、包裹式、嵌入式3类在新能源功率预测领域均有应用^[35-38]。

过滤式算法通过直接计算特征和输出关系进行筛选,特征筛选过程跟具体模型无关,因此最为简单,具体包括Pearson相关系数、熵相关系数、Granger因果检验等。Pearson相关系数只能对线性关系进行筛选,因此只有在待筛选特征和输出之间线性关系比较明确的场合使用。文献[36]提出了以最大相关-最小冗余原则提取输入变量的预测方法,采用特征和功率之间平均熵相关系数最大,各项特征之间平均熵相关系数最小的准则筛选特征,该方法能对特征和输出之间的非线性关系进行筛选,但是无法确定因果关系,因此有文献采用Granger因果检验^[37]进行特征筛选,由于该方法引入了时间序列滞后项进行分析,因此能给出变量之间的因果关系,使得特征筛选结果具有更强的可解释性。

包裹式算法以实际使用模型的性能作为评价准则,在待筛选的特征集合中采用一定的搜索算法找到一个最优子集。比如文献[38]提出的神经网络平均影响值(neural network-mean impact value, NN-MIV)的变量选择方法,综合考虑了各输入变量对风电功率之间的外部和内部贡献率,并按照排序选择贡献率大的输入变量。该方法属于“量身定做”的算法,因此理论上效果最优,但是缺点是计算量大,算法构建较为复杂。

嵌入式算法的计算复杂度介于过滤式和包裹式之间,其并不存在显式的特征筛选环节,而是跟算法训练过程融合为一体,常见的如加正则项、采用随机森林等特征选择算法。

2.3.2 特征降维

特征降维是将高维的输入变量映射到低维空间中,通常利用特征变量之间的相似性实现。常用的特征降维的方法有主成分分析法^[39-41]、t分布随机邻域嵌入(t-distributed stochastic neighbor embedding, t-SEN)降维^[42-43]等。

主成分分析方法(principal component analysis, PCA),其主要思想是通过正交变换将一组可能存在相关性的变量转换为一组线性不相关的变量,即主成分变量。PCA是一种使用最广泛的数据降维算

法，在新能源功率预测领域也使用较多，主要用于模型各种输入数据的降维，文献[41]采用 PCA 对 NWP 数据进行降维处理，后采用聚类分析的方法对天气类型进行分类，针对不同的天气类型分别建立预测模型，从而降低了模型输入的复杂度。

相比 PCA 降维，t-SNE 除了能够实现非线性降维以外，还能够实现很好的高维数据可视化^[42]。

t-SNE 是由 Laurens van der Maaten 和 Geoffrey Hinton 在 2008 年提出的一种非线性流形学习方法，由邻域嵌入算法 SNE 改进而来。文献[43]采用 t 分布邻域嵌入的非线性降维方法对相关气象指标进行降维处理，然后采用基于改进绝对距离、增速距离、波动距离组合指标的面板数据层次聚类方法对历史天气进行动态划分，有效提高了不同天气类型下风电功率的预测精度。

2.4 小结

当前常用的新能源功率预测异常数据识别主要有四分位法、聚类法、最优熵等算法，主要依据风速-风电功率和辐照度-光伏功率关系曲线进行辨识。数据插值算法主要从空间相关性和时间相关性 2 个维度对缺失数据进行重构，其中采用 GAN 结构的插值方式在大量量测值出现缺失的情况下仍具有较高的重建精度，而又不依赖于其他辅助量测值，是一种颇具研究价值的前沿算法。数据增强一般用于样本量不足情况下，针对新能源功率预测常用的功率数据、气象观测数据、NWP 数据进行扩充，主要有迁移学习、深度学习、生成对抗网络等方法。机器学习领域常用的 3 类特征选择方法，过滤式、包裹式、嵌入式在新能源功率预测中均有应用，其中过滤式计算最为简单，包裹式效果最优，但是计算量大，算法也较为复杂，嵌入式算法计算复杂度较为折中。降维技术中，t-SEN 相比 PCA 方法优势在于能够实现非线性降维，还能够实现很好的高维数据可视化。

3 基于 AI 技术的新能源功率预测模型

本节具体阐述 AI 技术在当前新能源功率预测模型构建中的应用，主要包括 3 大类算法：传统机器学习算法、以深度学习为代表的新型 AI 算法，以及融合多种模型的组合预测方法。

3.1 传统机器学习算法

根据训练数据是否有标签，传统机器学习算法可以分为有监督学习、无监督学习和半监督学习。

其中，监督学习和无监督学习在新能源功率预测领域已有广泛应用，典型算法总结如表 2 所示。

表 2 传统机器学习算法

Table 2 Traditional machine learning algorithms	
类型	常见算法
无监督学习	K 均值聚类、层次聚类、高斯混合模型、自组织映射网络
有监督学习	人工神经网络、支持向量机、决策树、k-近邻算法、马尔科夫链、随机森林、GBDT

3.1.1 无监督机器学习算法

无监督学习是在无标签样本数据集的情况下进行训练学习，用于揭示数据中内在的一些性质和规律。聚类是无监督学习中最常见的一种任务，其核心思想是将全体样本按照一定的相似性进行分类。目前在新能源预测中，应用较多的聚类方法主要包括 K 均值聚类、层次聚类、自组织映射网络聚类等，常用于对预测场景进行模式识别，再结合各种有监督算法有针对性地进行预测，从而提高模型预测的准确度。

K 均值聚类是一种简单的经典聚类算法，文献[44]将基于历史功率和气象数据建立的向量空间距离作为相似性度量指标，用 K 均值聚类进行历史相似日的聚类。但是由于 K 均值建立在距离度量基础上，其在较高维数据上的有效性有限，并且 K 均值聚类的子类个数选取具有一定的主观性，相比之下，层次聚类更为灵活，其最终得到一个聚类树，因此不需要指定初始的类型个数。文献[45]基于经验正交函数分解(empirical orthogonal function, EOF)分解得到的空间向量矩阵，采用层次聚类法对风电场子区域进行聚类，从而可更灵活地决定子区域个数。图 6 为基于层次聚类的风电功率波动类型聚类，由于层次聚类使用的是贪心算法，其计算量也比较大。




图 6 基于层次聚类的风电场日功率聚类
Fig. 6 Wind farm clustering based on hierarchical clustering

此外，进行天气类型分型是新能源功率预测领

域常用的前置处理手段,一般也是通过聚类算法实现,文献[46]基于云量预报信息采用自组织映射网络对天气类型进行聚类,然后再根据不同的天气类型分别预测,从而提升预测精度。自组织映射网络用于聚类时类别数量根据算法结果自动确定,且能给出聚类簇之间的相似程度。

3.1.2 有监督机器学习算法

监督学习是从具有标签的样本数据集中,抽象出某种映射关系的机器学习算法,常用于解决分类和回归问题。目前,新能源功率预测领域中应用较多的有支持向量机^[47-49]、人工神经网络(artificial neural network, ANN)^[50-54]、基于决策树的GBDT^[55]和随机森林以及常用于概率预测的贝叶斯方法^[56-59]等有监督学习方法。

如图7所示,SVM的基本模型是定义在特征空间上间隔最大的线性分类器,结合核技巧即可实现非线性分类器的功能,其学习策略就是间隔最大化,优点是在样本量较少的情况下,相比其他机器学习算法,依然能获得比较好的泛化能力。SVM算法在新能源功率预测领域可用于分类,如使用SVM对天气类型进行分类^[47],其对应的回归算法(support vector regression, SVR)一般用于建立预测回归模型^[48-49]。




图7 支持向量机和核技巧映射原理

Fig. 7 Support vector machine and kernel skill mapping principle

ANN是模拟人脑的神经系统对复杂信息的处理机制的一种数学模型,由大量简单元件相互连接而成的网络,由于其良好的非线性拟合能力、参数和结构灵活可调,在新能源功率预测领域得到了广泛应用,其中最为经典的结构是多层感知机(multilayer perceptron, MLP),文献[50]采用光伏阵列的发电量序列、日类型指数和气温作为输入,针对4个季节分别建立多层感知机神经网络预测模型对输出功率进行预测。但是MLP学习过程收敛慢且不能保证收敛到全局最小点,因此文献[52]采用径向基函数神经网络(radial basis function, RBF)对地表辐照度进行预测,RBF神经网络的隐节点采用输入模式与中心向量的距离(如欧式距离)作为函数

的自变量,并使用径向基函数(如Gaussian函数)作为激活函数。神经元的输入离径向基函数中心越远,神经元的激活程度就越低。具有训练速度快,唯一最佳逼近的特性,并且无局部极小问题存在。

此外,也有学者采用小波神经网络或者其改进版脊波神经网络^[53]进行新能源功率预测,小波神经网络将小波函数作为神经网络隐结点的激活函数,相应的输入层到隐含层的权值及隐含层的阈值分别由小波函数的尺度伸缩因子和时间平移因子所代替,从而使神经网络获得时频局部分析的能力。

以上神经网络的参数训练均采用迭代求解的方式,从而逐步逼近最优值,模型训练效率较低,而文献[54]采用单隐层神经网络的极限学习机进行风电功率区间预测,由于极限学习机网络参数基于伪逆矩阵的方式进行计算求解,因而大大提高了模型的训练速度。

大部分机器学习回归算法都只能直接给出确定性的预测结果,针对新能源概率预测场景,一般在确定性预测基础上对误差分布采用核密度估计等二次建模方法给出概率预测结果。除此以外,基于贝叶斯定理的机器学习算法也常用于概率预测,文献[56]首先得到功率的先验概率分布以及光伏功率和温度的copula函数,然后基于贝叶斯方法得到给定温度下功率的条件概率分布,实验结果表明比直接使用温度作为特征值输入的方法更优。文献[59]采用了基于改进贝叶斯神经网络的光伏出力概率预测方法,由于网络权重参数是随机变量,而非确定的值,因此能够给出预测结果的置信度,提高了模型预测应对光伏出力随机性的能力。

3.2 基于深度学习的AI算法

深度学习算法由浅层的ANN演化而来,通过组合多个非线性表征层构建深层网络模型,利用逐层抽象、逐层迭代的机制,实现对数据特征更高阶的提取。主要包括深度残差网络^[60]、深度信念网络^[61-62]、深度玻尔兹曼机^[63]、深度循环神经网络^[64-65]、深度卷积神经网络^[66-67]等。

循环神经网络(recurrent neural network, RNN)是一类具有短期记忆能力的神经网络,适合用于处理视频、语音、文本以及时间序列预测等与时序相关的问题,主要有RNN、LSTM、门控循环单元(gate recurrent unit, GRU)这3种结构,其中RNN在输入序列比较长时,会产生梯度爆炸或梯度消失问题,因此使用较少,LSTM和GRU在RNN网络基

础上引入门控机制,用特殊记忆神经元模块替代普通神经元模块,能够有效弥补 RNN 难以保持长时间记忆的问题,是较常用的 2 种结构。循环神经网络对具有前后关联的时间序列数据处理具有天然的优势,输入和输出都支持多时间步长,因此应用于新能源功率预测时一般用多个时间点的历史功率和气象数据作为输入,预测未来功率输出或者辐照度、风速等关键气象因素,如图 8 所示。




图 8 基于 LSTM 的新能源功率预测

Fig. 8 Renewable energy power prediction based on LSTM

对于光伏功率预测而言,辐照度最重要的气象因素,云是影响地面辐照度的主要气象要素,云层的生消和运动是引起光伏功率波动的主要原因。因此,基于云图的预测方法成为精细化光伏预测的重要技术方向之一,常用的云图有地基云图和气象卫星云图。

对于云图特征的提取用到的核心关键技术是图像分割、图像去噪等图像处理技术。文献[68]采用基于图像灰度特征的阈值法进行云图图像分割和特征提取,该方法阈值选取较为困难,对噪声比较敏感,鲁棒性不高。近年来随着深度学习在图像识别领域的应用,基于卷积神经网络结构的端到端的图像处理技术已经成为主流。图 9 为基于卷积神经网络的辐照度预测技术图,文献[66]采用一种云图区域定位算法,在云图中实时定位云遮挡区域,并通过卷积神经网络获取云遮挡影响特征,但是该方法只能提取到云图的空间特性,而动态时间特征提取需结合其他模型获取,文献[67]采用 3D-卷积神经网络(3D-convolutional neural network, 3D-CNN)对地基摄像头拍摄的连续云图信息进行处理,从而提取云图特征,由于 3D-CNN 包含了时间维度,因此该方法除能提取出云图的实时纹理特征,也能直接预测出其动态变化趋势。由于云层不仅仅会发生位移变化,还会有生消变化,基于云图预测辐照度

比起一般的目标追踪任务难度更大,为了提高模型学习能力需加深模型的层数,过深的模型结构会加大训练难度。文献[60]使用深度残差网络 ResNet-18 基于地基云图对辐照度进行预测,由于引入了残差跳跃连接结构,大大降低了深度学习模型的训练难度。




图 9 基于 CNN 的辐照度预测技术

Fig. 9 Irradiance prediction technology based on CNN

3.3 组合预测

新能源功率预测受多种因素影响,采用单一的预测模型对新能源功率进行预测,可能在某些场景下出现较大误差。为了更好地利用不同模型的优势,综合利用多种预测模型构建组合预测模型,能够有效克服单一预测模型的固有局限,减少预测误差较大场景出现的概率。新能源功率预测模型按照机理可分为物理模型和基于数据驱动模型。按照组合方式的不同,组合预测模型可分为数据驱动组合模型和数据-物理驱动融合模型。

3.3.1 数据驱动组合模型

由于新能源功率预测属于回归问题,一般选择均方误差作为损失函数时,可将式(1)定义的期望风险分解为偏差、方差以及噪声之和^[69]:

$$E(h) = b_{ias}(h; \mathbf{x}) + v_{ar}(h; \mathbf{x}) + \varepsilon^2 \quad (8)$$

按照组合方式的不同,组合预测模型可大体分为串行组合^[70-73]和并行组合^[74-77]2 种。其中串行组合主要通过减少偏差 $b_{ias}(h; \mathbf{x})$ 来降低经验风险,而并行组合主要通过减少方差 $v_{ar}(h; \mathbf{x})$ 来降低经验风险。随着机器学习算法的不断发展,出现了集成学习的概念,可以将多个个体学习器进行组合来完成学习任务,其中 Bagging、Boosting 等常见的集成学习框架可用于构建新能源功率组合预测模型^[78-79]。

串行组合预测模型中各个预测模型或预测环节之间具有强依赖关系,主要包括集成学习中的 Boosting 框架,以及包含新能源功率预测多个环节的融合预测模型。Boosting 框架可以将一系列弱学习模型提升为强学习模型,其提升方法采用顺序过程,每个后续模型会在先前模型的基础上进行纠正和改进,通过减少弱学习器的偏差来减少总误差,

主要是同质集成,即基学习器均为同一类型模型。

而融合预测模型涉及新能源功率预测的全过程,包括模型输入优化、模型预测和误差修正等多个环节,主要是采用不同的模型进行组合,文献[71]以相似日的功率和气象数据作为输入,建立小波神经网络得到预测功率,以相邻日功率建立灰色系统模型,用灰色系统模型输出区间对小波神经网络的预测功率值进行校正。常用串行组合方式如图 10 所示。




图 10 常用串行组合框架

并行组合预测模型中各个模型之间不存在强依赖关系,可同时进行模型的构建和训练,主要包括集成学习中的 Bagging 框架和多模型加权预测方法。

与 Boosting 框架通过减少预测总误差中偏差不同的是, Bagging 框架通过减少弱学习器的方差来减少总误差,通过有放回的抽取构建多个训练样本集,进而同时构建多个子学习模型,对于回归问题采用平均值法对子模型的结果进行加和得到最终的预测结果。

多模型加权预测同样通过构建多种模型进行预测,与此不同的是各模型采用相同的训练集,且最终的预测结果以权重的方式对各模型进行加权求得,代替了 Bagging 框架中简单的平均值法。

除了直接将相同的原始序列输入预测模型进行预测外,也可以将原始序列先进行分解,然后针对不同的子序列单独建模预测后再加权。文献[76]将光伏功率序列分解为子序列,然后将子序列输入 4 个独立的 LSTM 网络,最后对 LSTM 网络输出进行线性加权得到最终的预测结果。并行组合的常用

方法如图 11 所示。




图 11 常用并行组合框架

Fig. 11 Commonly used parallel combination framework

3.3.2 数据-物理驱动组合模型

数据-物理驱动的组合模型同时利用物理模型和数据驱动模型对新能源功率预测,在现有研究中一般将物理模型的预测结果作为基于数据驱动模型的输入变量。文献[80]提出了一种基于 ANN 和光伏电站晴空曲线的物理混合人工神经网络(physical hybrid artificial neural network, PHANN)方法。首先利用光伏电站的经纬度、太阳能电池板的倾斜角、方位角等参数构建光伏电站晴空模型,得到无云情况下的太阳辐照度。然后将计算得到的辐照度和数值天气预报数据一同作为神经网络的输入变量,进而得到光伏功率的预测值。在新能源功率事件预测中,需要对一段时间窗口内的新能源功率进行预测,通过功率升降的变化率进而判断是否属于爬坡事件^[81]。考虑到仅利用历史数据的统计模型在较短的时间内预测精度高,但随着预测时间的增加,精度将明显下降,而引入 NWP 数据的物理方法,可以在相对较长的时间里具有较好的性能。因此,文献[82]利用物理模型预测得到长期的气象预报数据,在此基础上,利用统计模型完成对未来一段时间内风电功率爬坡事件的预测。

目前,关于数据-物理驱动组合预测模型的研究相对较少,大多数学者重点关注于数据驱动融合

模型。但数据-物理驱动模型可以同时兼顾物理模型对预测机理的可解释性，以及数据驱动模型预测的准确性和快速性，具有较好的研究价值。

3.4 小结

构建新能源功率预测模型采用的 AI 算法主要有传统机器学习、深度学习以及组合模型 3 大类，其中传统机器学习算法中无监督聚类算法常用于对预测场景进行模式识别，有监督学习算法中支持向量机相比其他机器学习算法，更适用于小样本情况。而小波神经网络由于具备时频局部分析的能力，因此适用于捕捉短时波动规律。此外，基于贝叶斯方法的机器学习算法适合于概率预测场景，且可嵌入先验假设知识。相比传统机器学习，深度学习模型在区域预测等数据输入维度高、时空特性复杂的场景更有优势。循环神经网络由于具备时间记忆功能，因此对于序列化的数据有很强的模型拟合能力，适用于挖掘超短期时间尺度内的序列相关性，基于卷积神经网络结构的端到端的图像处理技术已经较为成熟，有望应用于云图数据的处理，提高超短期时

间尺度内辐照度和光伏功率的预测精度。由于深度学习的黑箱特征，其模型结果的可解释性差是一大缺陷，当应用于新能源功率爬坡等事件预测时可能产生较大的误判成本。组合预测模型当前以数据驱动模型为主，可通过串行和并行 2 种方式分别减少模型的偏差和方差，从而提高预测精度，而数据-物理驱动模型当前研究较少，但通过有机融合可吸收 2 种模型优点，具备较好的研究潜在价值。

4 模型训练与超参数优化

新能源功率预测效果除了与选择的预测模型直接相关外，也在很大程度上取决于模型的训练好坏和超参数是否选取合适，而模型的训练与超参数调节本质上都是优化问题。实际应用当中，大部分机器学习模型的训练优化一般都是基于梯度下降等迭代算法进行优化，而模型的结构和超参数等往往根据专家经验进行人工选择和调优。当前新能源功率预测中常用机器学习算法的模型参数和超参数如表 3 所示。

表 3 机器学习算法模型参数和超参数
Table 3 Parameters and hyperparameters of ML model

预测模型算法	模型参数	模型参数训练方法	模型超参数
BP 神经网络	连接权值、节点阈值	基于梯度下降的误差反向传播算法	学习率、正则化参数、网络层数、每层神经元个数、激活函数等
SVM	支持向量	最小序列优化算法	惩罚系数、核函数等
随机森林	树拓扑结构、节点属性	随机采样+决策树训练算法(ID3、CART 和 C4.5 算法等)	树的棵数、树最大深度、分裂标准等
GBDT	树拓扑结构、节点属性	梯度提升+CART 算法	树的棵数、树最大深度、分裂标准、学习率等
CNN	卷积核的权值、偏置等	基于梯度下降的 误差反向传播算法	卷积核尺寸、卷积核数量、卷积的步长、池化核尺寸、池化步长、池化方式
循环神经网络	连接权值、节点阈值、偏置值	时间反向传播算法	时间步长、学习率、网络层数、激活函数等
深度信念网络	连接权值、节点阈值	逐层无监督预训练+误差反向传播算法微调	网络层数、每层神经元个数、激活函数等
贝叶斯神经网络	网络权重概率分布	变分推理、蒙特卡洛法等	网络层数、神经元个数、激活函数等
组合模型	各子模型参数	各子模型对应训练方法	各子模型超参数、组合权重系数等

随着 AI 技术的发展，也有相关学者采用 AI 优化算法进行新能源功率预测模型训练和超参数调优，主要包括进化类算法、群智能优化算法、模拟退火算法、禁忌搜索算法以及强化学习等^[83-89]。

4.1 模型训练

大部分机器学习算法采用的训练算法，如人工神经网络采用的梯度下降法、决策树的 ID3、C4.5 和 CART 算法等，都存在着容易陷入局部极小点等问题，并且优化的目标函数选择不够灵活。

进化类算法是一种成熟的具有高鲁棒性和广泛适用性的全局优化方法，其中最具代表性的是遗

传算法。遗传算法(genetic algorithm, GA)起源于对生物系统所进行的计算机模拟研究，它是模仿自然界生物进化机制发展起来的随机全局搜索和优化方法，其本质是一种高效、并行、全局搜索的方法，能在搜索过程中自动获取和积累有关搜索空间的知识，并自适应地控制搜索过程以求得最佳解。图 12 为基于遗传算法的新能源功率预测模型训练流程图。文献[83]采用模糊 RBF 神经网络预测进行日前光伏功率预测，采用遗传算法优化神经网络参数，其实验结果表明采用基于遗传算法的神经网络(genetic algorithm-radial basis function, GA-RBF)方

法比不采用GA优化的模糊RBF神经网络预测具有更高的预测精度。




图12 基于遗传算法的新能源功率预测模型训练流程

Fig. 12 Training flow of renewable energy power prediction model based on genetic algorithm

由于新能源功率预测的不同评价指标之间往往是此消彼长的关系,基于单目标优化的方法可能导致未优化指标出现极端不合理的情况发生。文献[84]采用一种双输出神经网络结构用于负荷和风电功率的区间预测,并将预测目标建模为一个带约束的单目标优化问题,最后采用粒子群单目标优化算法对其神经网络参数进行优化。文献[85]直接采用多目标人工蜂群算法,以可靠性和准确性2个评价指标作为目标函数,针对小波神经网络的伸缩因子、平移因子和权值进行了优化。结果表明相比一般的单目标优化提高了预测区间置信度,降低了预测区间带宽。

4.2 超参数优化

基于人工经验的超参数调优方法模型调优和建模工作量大,对专业人员的技巧和经验要求较高,同时模型很难具备场景自适应能力,当模型运行出现场景偏移时,一般需要线下优化重新线上部署。

文献[87]利用基于熵判别人工蜂群算法优化,确定各个风电功率预测模型的权重,文献[88]利用改进的多种群遗传算法,计算RBF神经网络法、相似日法和SVM这3种模型的最优权重值,提高风电功率的预测精度。以上遗传算法、群智能优化算法等静态类智能优化算法由于不能和环境实时交互,难以实现模型参数的动态学习,而强化学习是一类动态优化算法,其考虑的是智能体与环境的交

互问题,目的是使得智能体在与环境的交互过程中通过学习策略以达成回报最大化或实现特定目标的问题。文献[89]采用强化学习Q-learning算法对3种循环神经网络预测模型的组合权重进行优化,从而提高超短期光伏功率预测精度。图13为基于强化学习的新能源功率预测模型超参数优化流程图,一般先基于历史数据对智能体进行预训练,然后再接入实时数据进行线上应用。




图13 基于强化学习的新能源功率预测模型超参数优化

Fig. 13 Hyperparameter optimization of renewable energy power prediction model based on reinforcement learning

4.3 小结

模型参数和超参数对于模型的预测精度至关重要,当前新能源功率预测模型常采用进化算法、群智能优化算法、模拟退火算法、禁忌搜索算法等静态算法,以及强化学习等动态算法进行参数和超参数调优。静态算法可在某一特定分布的数据上取得较好的预测结果,但是不具备模型的自适应性,当新能源场站运行情况存在较大差异时,训练好的模型往往难以直接用于其他新能源场站中。动态算法可以实现模型参数和环境运行状态的实时交互,能够根据环境的反馈及时调整自身策略,对参数进行动态学习,是未来新的研究热点。需要指出的是,虽然上述AI优化算法具备优化目标灵活,全局优化能力强等多种优点,但是用于机器学习模型训练时,相比特定的训练算法往往效率较低,因此实际应用时一般只用于模型的超参数调优等参数较少的场合,用于模型训练其优化效率有待提高。

5 当前研究现状和预测水平分析

5.1 当前研究现状文献分析

本文对新能源功率预测领域发表文献较多，影响力较大的国内外 9 种主流学术期刊进行了文献统计分析，总共选取了 2011—2021 年近 700 篇风电和光伏功率预测的相关文献，文献来源和统计数量如表 4 所示。

表 4 统计文献来源及数量

Table 4 Source and quantity of statistical articles

期刊名	文献数量	
	风电	光伏
Solar Energy	1	194
IEEE Transactions on Smart Grid	11	4
IEEE Transactions on Sustainable Energy	69	36
IEEE Transactions on Power Systems	42	6
Applied Energy	103	44
中国电机工程学报	18	12
电力系统自动化	44	18
电网技术	48	22
电工技术学报	17	9

图 14 为 2012—2021 年风电功率预测和光伏功率预测的相关文献数量增长曲线图，整体上新能源功率预测的研究文献增长明显，且近几年呈加速趋势，说明这一课题仍然是研究热点，此外风电和光伏 2 种功率预测的研究文献数量增长规律基本相同，总体上和近十年这 2 种新能源在产业界的发展情况相一致。




图 14 2012—2021 年新能源功率预测文献数量

Fig. 14 Number of new energy power forecast literatures from 2012 to 2021

图 15 为 2012—2021 年不同新能源功率预测方法文献数量分布统计图，包括时间序列预测模型，ANN、SVM、决策树等主流的传统机器学习模型，深度学习模型，以及物理模型和使用较少的其他类模型。从图 15 中可以看出，SVM 凭借其优良的泛化性能，在早期应用较多，在传统机器学习方法中占据较为重要的地位，而近年来深度学习算法越来越

越成为主流的研究方法，且几乎占了大部分比例，毫无疑问已成为新的研究热点。




图 15 2012—2021 年不同 AI 方法文献数量分布

Fig. 15 Distribution of literature on different AI methods from 2012 to 2021

5.2 新能源功率预测水平分析

由于现有文献中的新能源功率预测算法所用数据集不同，且预测的时间尺度，空间尺度不一，以及评价指标的多样性，基于文献分析很难对比不同机器学习算法在实际应用中的优劣。因此本文选取全球能源预测大赛(GEFCOM)、美国气象学会 2013—2014 年光伏功率预测大赛、2021 年国家电网调控 AI 创新大赛赛道 3 这几项有影响力的新能源功率预测大赛比赛结果作为一个比较手段，以排除上述主观因素的影响。

全球能源预测大赛(GEFCOM)由美国电气电子工程师协会电力和能源学会发起，至今已经举办过 GEFCOM2012、GEFCOM2014、GEFCOM2017 共 3 届，有超过 60 个国家和地区的数百支队伍参赛。

本文对 2012，2014，2017 年 3 届全球能源预测大赛中排名较为靠前的优胜模型进行了统计^[90-92]，结果如表 5 所示，从表 5 可以看出，组合预测模型数量明显多于单一预测模型。

表 5 GEFCOM 使用的模型统计

Table 5 Statistics of models used by GEFCOM

年份	组合模型	单一模型
GEFCOM2012	6	3
GEFCOM2014	6	4
GEFCOM2017	10	3

图 16 为对 3 届全球能源预测大赛的优胜模型进行的统计饼图，主要统计了 ANN，SVM，基于决策树的 GBDT 和随机森林等树模型，时间序列回归模型，线性回归模型等 8 类模型。从图 16 中可以看出，线性回归模型和树模型在实际应用当中效果最好，其次是时间序列模型、神经网络、k-近邻

算法和 SVM。这与同时期学术文献中的研究热点不相一致,说明新能源功率预测领域在理论研究和实际应用之间存在差距,先进的研究理论转化成工业生产中较为实用的模型可能存在一定的时间滞后。




图 16 GEFcom 优胜算法统计

Fig. 16 GEFcom winning algorithm statistics chart

此外,美国气象学会主办的光伏功率预测大赛(2013-2014 Solar Energy Prediction Contest)以及近期 2021 年国家电网调控 AI 创新大赛中新能源发电预测比赛中,主流模型均使用了梯度提升机(gradient boosting machine, GBM)、梯度提升回归树(gradient boosting regression tree, GBRT)、随机森林、XGBoost、LightGBM 等模型,由此说明基于决策树的同质集成算法在实际应用中效果较好。相比前 2 个举办时间较早的竞赛,国家电网调控 AI 创新大赛中还有优胜队伍使用了 LSTM、时间卷积网络(temporal convolutional network, TCN)等深度学习模型,表明深度学习类的模型也已经逐渐在实际应用中崭露头角。

表 6^[93]和表 7^[94]分别为当前产业界应用较为成熟的光伏功率预测系统和风电功率预测系统,从中可以看出不管是光伏预测还是风电预测,国外欧美等发达国家在相关产业应用方面均早于我国大约 10 到 15 年的时间。实际预测系统采用的技术路线由早期的物理建模方法为主过渡到以数据驱动方法为主,且几乎全部为组合建模方法,这与能源预测大赛的分析结论一致。

表 6 光伏功率预测系统

Table 6 Photovoltaic power prediction systems

预测系统	时间	采用方法	开发者
SOLARFOR	1998 年	组合方法	丹麦能源预测与优化公司
光伏发电预测系统	1998 年	组合方法	美国清洁能源研究公司
MeteodynPV	2003 年	物理方法	法国美迪公司
SPFS	2010 年	组合方法	中国电力科学研究院有限公司
SPSF-3000	2011 年	组合方法	北京国能日新
NSF3200	2012 年	组合方法	国电南瑞科技
光伏发电功率预测 预报系统 V2.0	2013 年	组合方法	湖北省气象服务中心

表 7 风电功率预测系统

Table 7 Wind power prediction systems

预测系统	时间	采用方法	开发者
Prediktor	1994	物理方法	丹麦 Risø 国家 可再生能源实验室
WPPT	1994	统计方法	丹麦科技大学
eWind	1998	组合方法	美国 AWSTruewind
WPMS	2001	统计方法	德国太阳能 研究所 ISET
Sipreólico	2001	统计方法	西班牙马德里 卡洛三世大学
ANEMOS	2002	组合方法	欧盟
Previento	2002	组合方法	德国奥尔登堡大学
Zephyr	2003	组合方法	丹麦 Risø 国家可再生能源 实验室与丹麦科技大学
LocalPred- RegioPred	2003	组合方法	西班牙国家可再生 能源中心与西班牙能源、 环境和技术研究中心
WEPROG MSEPS	2005	组合方法	爱尔兰科克大学
ANEMOS.plus and SafeWind	2008	组合方法	欧盟
WPFS	2008	组合方法	中国电力科学研究院有限公司
FR3000F	2010	组合方法	北京中科伏瑞电气技术有限公司
NSF 3100	2011	组合模型	国网电力科学研究院
WINPOP	2011	组合方法	中国气象局公共服务中心
高精度风电 功率预测系统	2017	组合模型	国能日新科技股份有限公司

6 前沿展望

6.1 在线自适应学习

除了传统的陆地新能源和集中式新能源以外,未来我国沿海地区海上风电以及各种小型分布式新能源也将迎来爆发式增长,对于新能源功率预测而言,由于这些场景设备运行工况更为复杂,气象条件更加多变,模型的场景自适应能力尤为重要。

当前新能源功率预测一般采用“离线训练,在线预测”的方式,模型上线之后对环境缺乏动态自适应调整的能力,存在参数更新不及时、无法实时响应新能源电站运行状态等问题,因此当新能源电站环境参数和运行参数等发生较大变化时,模型预测精度可能出现明显下降。

此外,针对新能源功率预测虽然有大量模型和预测方法被提出,但是预测模型往往存在对数据和使用场景的强依赖性,模型泛化能力不强。而当前研究采用的组合预测方式往往是多个模型的静态组合方式,而针对不同的场景,当前预测方法在模型超参数优化、模型场景自适应方面缺少研究。

模型自适应技术通过感知自身和环境的变化,动态调整自己的行为与参数,能够在环境发生非预期变化的情况下继续保持高精度预测。以往的自适应技术往往对经验信息和先验知识依赖较大,预测泛化性能不足。随着大数据和 AI 的发展,基于自动机器学习、自动特征工程、神经网络结构搜索、增量样本学习等技术,实现模型参数、超参数与结构的自动调整,从而准确刻画、适应预测对象的变化趋势,全面反映预测对象不确定性特征,提升泛化性能。

6.2 小样本机器学习

近年来,随着海量数据的积累,在大数据技术的支撑下,机器学习和深度学习在许多领域中取得了成功。但是在现实世界中的很多应用场景,经常面临样本稀缺或者可用数据量少的问题。

根据国网能源院预测,截止 2060 年我国新能源装机量将约为 2020 年 10 倍,未来会有大量新建新能源场站并网,面临历史积累样本不足的问题,同时也将有大量分布式光伏接入,其小型化和运营主体多样化的特点也决定了其数据获取成本高昂。

小样本学习已经成为近几年 AI 研究领域的一个热点,一种较为直观的解决手段是采用数据增强的方法,即利用原始少量样本生成大量样本,具体来说又包括数据生成和特征增强。另外一种思路是从模型的角度来实现,即使用少量样本数据,也能快速学习新的概念或技能。其中元学习和数据知识融合是 2 种比较典型的解决范式。图 17 为基于数据-机理融合的新能源功率预测模型。




图 17 基于数据-机理融合的新能源功率预测模型

Fig. 17 New energy power prediction model based on data mechanism fusion

元学习具体指从大量的先验任务中学习到元知识,利用以往的先验知识来指导模型在新任务(即小样本任务)中更快地学习。而数据知识融合通过预先给模型融入一部分人类的经验知识或者物理机理,使得模型一开始就具备待学习领域的部分知识,从而解决了从数据中学习知识量不足的问题,也即提高了模型的整体泛化能力,同时提高了模型

的可解释性。具体到新能源功率预测,可考虑将晴空模型、光电转换模型、风功率转换模型等物理机理模型和 AI 模型进行融合,如采用 AI 模型代替物理模型子过程、优化或者辨识物理模型参数、用物理模型校正 AI 模型输出结果、基于物理模型对 AI 模型进行模型预训练等。

6.3 基于 AI 技术提升 NWP 数据分辨率

以新能源为主体的新型电力系统背景下,高比例的电力电子装置并网带来的暂态功角稳定问题、频率问题以及低惯量问题,使得电网对于实时调度和新能源的精细化管理要求更高,也就迫切需要进行进一步提高新能源的功率预测精度和时间分辨率。

新能源功率预测使用的 NWP 数据往往是在较大空间尺度范围内的一个平均值,在使用 NWP 数据来预测新能源输出功率时,一般直接将原始数据作为模型输入来进行预测,未考虑实际地形、地貌以及建筑物遮挡等因素对风速和光照等关键气象因素的影响,在某些情况下可能导致功率预测结果发生较大偏差。此外,由于当前 NWP 数据时间分辨率一般为数小时级别,导致功率预测结果的时间分辨率也较为粗糙,难以满足新能源实时调度等时间分辨率要求较高的场合。

为了减少以上 NWP 数据时空分辨率受限导致的新能源功率预测误差,可考虑采用深度学习等具备高维数据处理能力的机器学习模型对多站点的 NWP 数据进行统计降尺度处理,通过空间降尺度,可消除因地形位置差异导致的预测误差,通过时间降尺度,可提供更为及时的预报结果,满足更为精细化的新能源功率预测需求。其次,由于 NWP 受模式初始值影响较大,因此可考虑利用数据预处理相关的 AI 技术提高观测资料质量,同时结合地面新能源站点的微气象观测数据进行资料同化。再次,可探索采用基于贝叶斯方法等的 AI 概率预测技术辅助或者替代传统基于初值扰动的集合预报技术,有望提高新能源概率预测的精度。

对于光伏功率预测,还可结合地基云图和卫星云图等信息,采用深度卷积网络、图注意力机制等多种最新的图像处理技术和目标追踪技术提取云量特征和变化趋势等信息,通过对局部小尺度地区的云层和辐照度直接进行预测,从而提升超短期预测精度和光伏功率爬坡等突发事件的预测能力。

6.4 多源时空数据融合的分布式源荷集成预测

当前“双碳”背景下,一方面,大量分布式新

能源和电动汽车、储能设备等新型负荷并网,用户不再仅仅是电能的受端,而呈现出产消一体化的新形态。另一方面,随着电力市场改革进一步深化,需求侧响应、负荷聚合商、虚拟电厂等新技术与新角色的引入,也会使得负荷和分布式新能源出力呈现出更加复杂的新特性。

鉴于分布式源-荷呈现出上述多种新特性,传统的“源随荷动”运行模式已不再适用于配电网运行,而逐渐演变为更加主动的“源网荷储”全网协同的运行模式,统筹考虑分布式新能源与多种负荷的耦合互补关系,将其作为整体研究对象的源荷集成预测将成为新的研究趋势。一方面,可通过流形学习、表示学习等多种先进的 AI 技术,对多源异构的海量分布式源荷数据进行充分融合,从中提取出有用信息;另一方面,在一定的区域范围内,多个相邻分布式源荷站点数据之间具有时间和空间上的相关性,可结合注意力机制、图神经网络(graph neural network, GNN)等技术对其时空特性进行深入挖掘,从而有效提升分布式源荷集成预测性能。图 18 为基于 GNN 网络的分布式新能源预测模型。




图 18 基于 GNN 网络的分布式新能源预测

Fig. 18 Distributed new energy forecast based on GNN network

6.5 建立预测方法标准化验证方法

未来随着海上风力发电、分布式光伏发电等复杂场景的新能源大量装机并网,新能源功率预测在实际应用中将面临更大的技术难度和挑战,需要加速学术界先进的理论成果在产业界的推广。

当前,虽然针对新能源功率预测的新方法和新模型层出不穷,各种确定性和不确定性预测的评价指标也多种多样,但是由于目前文章中所用方法的预测数据集选取各有不同,预测场景和评价指标也不一致,模型性能可能存在过拟合问题,难以对预测方法的实际泛化效果进行比较。且迄今为止,国内外在新能源功率预测领域依然没有公开的标准数据集和较为科学的模型泛化性能检验方法,因此不利于学术界先进的模型和方法迅速在产业界推广,从而造成了学术界和产业界之间的鸿沟。未来可以借鉴图像识别领域的 ImageNet 标准数据集的

建立方法,建立新能源功率预测领域的标准数据集和模型测试方法,用于验证和对比各种预测方法的实际性能和泛化能力,从而实现对预测方法的规范化、标准化检验,助力产业界预测水平的提升。

7 结语

当前 AI 技术在新能源功率预测领域的应用主要包括模型输入、模型构建和参数优化 3 个方面。模型输入包括数据预处理、数据增强和特征构建方面的应用。模型构建主要有以 ANN、SVM、决策树模型为代表的传统机器学习算法,基于深度学习的新一代 AI 技术,以及组合多种 AI 算法的组合预测技术;模型参数优化算法包括进化算法、群智能优化算法等静态优化算法和强化学习等动态优化算法,主要用于模型训练和组合参数优化。

新能源功率预测近十年研究增长明显,且目前依然备受学者关注。相比传统机器学习算法,近年来随着大数据时代的到来,深度学习算法已成为新的研究热点。新能源功率预测大赛中实际应用效果较好的模型与学术文献中的研究热点并不完全一致,理论研究和产业应用之间存在差距。此外,国内外实际预测系统几乎全部采用组合建模方法,技术路线由早期的物理建模方法为主过渡到以数据驱动方法为主,而欧美发达国家的产业应用早于我国大约 10~15 年的时间。

最后,结合新型电力系统背景下我国未来新能源的发展态势,分析新能源功率预测可能将面临的一些新的挑战,具体对场景自适应、小样本学习、NWP 数据时空分辨率、分布式新能源预测、预测方法标准化验证这 5 个方面存在的问题进行了剖析,并针对每类问题的特点,结合强化学习、元学习、GNN 等多种 AI 技术的优势,对可能的解决方案进行了展望。

参考文献

- [1] 舒印彪. 发展新型电力系统助力实现“双碳”目标[J]. 中国电力企业管理, 2021(7): 8-9.
SHU Yinbiao. Development of a new power system to help achieve the “dual carbon” goal[J]. China Power Enterprise Management, 2021(7): 8-9(in Chinese).
- [2] GAN D, THOMAS R J, ZIMMERMAN R D. Stability-constrained optimal power flow[J]. IEEE Transactions on Power Systems, 2000, 15(2): 535-540.
- [3] 秦超, 余贻鑫. 基于安全域的含风电电力系统概率小扰动稳定分析[J]. 电力系统自动化, 2014, 38(10): 43-48.

- QIN Chao, YU Yixin. Security region based probabilistic small signal stability analysis for power systems with wind power integration[J]. Automation of Electric Power Systems, 2014, 38(10): 43-48(in Chinese).
- [4] XING Xuetao, LIN Jin, WAN Can, et al. Model predictive control of LPC-looped active distribution network with high penetration of distributed generation[J]. IEEE Transactions on Sustainable Energy, 2017, 8(3): 1051-1063.
- [5] CHEN Xiaoshuang, LIN Jin, WAN Can, et al. A unified frequency-domain model for automatic generation control assessment under wind power uncertainty[J]. IEEE Transactions on Smart Grid, 2019, 10(3): 2936-2947.
- [6] WAN Can, NIU Ming, SONG Yonghua, et al. Pareto optimal prediction intervals of electricity price[J]. IEEE Transactions on Power Systems, 2017, 32(1): 817-819.
- [7] ZHEN Zhao, LIU Jiaming, ZHANG Zhanyao, et al. Deep learning based surface irradiance mapping model for solar PV power forecasting using sky image[J]. IEEE Transactions on Industry Applications, 2020, 56(4): 3385-3396.
- [8] ZHANG Ning, KANG Chongqing, XIA Qing, et al. Modeling conditional forecast error for wind power in generation scheduling[J]. IEEE Transactions on Power Systems, 2014, 29(3): 1316-1324.
- [9] SHAO Chengcheng, SHAHIDEHPOUR M, WANG Xifan, et al. Integrated planning of electricity and natural gas transportation systems for enhancing the power grid resilience[J]. IEEE Transactions on Power Systems, 2017, 32(6): 4418-4429.
- [10] BHAVSAR S, PITCHUMANI R, ORTEGA-VAZQUEZ M A. Machine learning enabled reduced-order scenario generation for stochastic analysis of solar power forecasts[J]. Applied Energy, 2021, 293: 116964.
- [11] WANG Fei, MI Zengqiang, SU Shi, et al. Short-term solar irradiance forecasting model based on artificial neural network using statistical feature parameters[J]. Energies, 2012, 5(5): 1355-1370.
- [12] ZENG Jianwu, QIAO Wei. Short-term solar power prediction using a support vector machine[J]. Renewable Energy, 2013, 52: 118-127.
- [13] YU Chuanjin, LI Yongle, BAO Yulong, et al. A novel framework for wind speed prediction based on recurrent neural networks and support vector machine[J]. Energy Conversion and Management, 2018, 178: 137-145.
- [14] PAOLI C, VOYANT C, MUSELLI M, et al. Forecasting of preprocessed daily solar radiation time series using neural networks[J]. Solar Energy, 2010, 84(12): 2146-2160.
- [15] EKICI B B. A least squares support vector machine model for prediction of the next day solar insolation for effective use of PV systems[J]. Measurement, 2014, 50: 255-262.
- [16] HAN Li, ZHANG Rongchang, WANG Xuesong, et al. Multi-step wind power forecast based on VMD-LSTM[J]. IET Renewable Power Generation, 2019, 13(10): 1690-1700.
- [17] HUANG Yuansheng, LIU Shijian, YANG Lei. Wind speed forecasting method using EEMD and the combination forecasting method based on GPR and LSTM [J]. Sustainability, 2018, 10(10): 3693.
- [18] TONG Chao, LI Jun, LANG Chao, et al. An efficient deep model for day-ahead electricity load forecasting with stacked denoising auto-encoders[J]. Journal of Parallel and Distributed Computing, 2018, 117: 267-273.
- [19] ANDRADE J R, BESSA R J. Improving renewable energy forecasting with a grid of numerical weather predictions[J]. IEEE Transactions on Sustainable Energy, 2017, 8(4): 1571-1580.
- [20] HAMMER A, HEINEMANN D, LORENZ E, et al. Short-term forecasting of solar radiation: A statistical approach using satellite data[J]. Solar Energy, 1999, 67(1-3): 139-150.
- [21] 于若英, 陈宁, 苗淼, 等. 考虑天气和空间相关性的光伏电站输出功率修复方法[J]. 电网技术, 2017, 41(7): 2229-2236.
- YU Ruoying, CHEN Ning, MIAO Miao, et al. A repair method for PV power station output data considering weather and spatial correlations[J]. Power System Technology, 2017, 41(7): 2229-2236(in Chinese).
- [22] 娄建楼, 胥佳, 陆恒, 等. 基于功率曲线的风电机组数据清洗算法[J]. 电力系统自动化, 2016, 40(10): 116-121.
- LOU Jianlou, XU Jia, LU Heng, et al. Wind turbine data-cleaning algorithm based on power curve[J]. Automation of Electric Power Systems, 2016, 40(10): 116-121(in Chinese).
- [23] 胡阳, 乔依林. 基于置信等效边界模型的风功率数据清洗方法[J]. 电力系统自动化, 2018, 42(15): 18-23, 149.
- HU Yang, QIAO Yilin. Wind power data cleaning method based on confidence equivalent boundary model [J]. Automation of Electric Power Systems, 2018, 42(15): 18-23, 149(in Chinese).
- [24] 赵永宁, 叶林, 朱倩雯. 风电场弃风异常数据簇的特征及处理方法[J]. 电力系统自动化, 2014, 38(21): 39-46.
- ZHAO Yongning, YE Lin, ZHU Qianwen. Characteristics and processing method of abnormal data clusters caused by wind curtailments in wind farms[J]. Automation of Electric Power Systems, 2014, 38(21): 39-46(in Chinese).
- [25] 杨茂, 杨琼琼. 基于云分段最优熵算法的风电机组异常数据识别研究[J]. 中国电机工程学报, 2018, 38(8): 2294-2301.

- YANG Mao, YANG Qiongqiong. The identification research of the wind turbine abnormal data based on the cloud segment optimal entropy algorithm[J]. Proceedings of the CSEE, 2018, 38(8): 2294-2301(in Chinese).
- [26] 张东英, 李伟花, 刘燕华, 等. 风电场有功功率异常运行数据重构方法[J]. 电力系统自动化, 2014, 38(5): 14-18, 24.
- ZHANG Dongying, LI Weihua, LIU Yanhua, et al. Reconstruction method of active power historical operating data for wind farm[J]. Automation of Electric Power Systems, 2014, 38(5): 14-18, 24(in Chinese).
- [27] XU Qian Yao, HE Dawei, ZHANG Ning, et al. A short-term wind power forecasting approach with adjustment of numerical weather prediction input by data mining[J]. IEEE Transactions on Sustainable Energy, 2015, 6(4): 1283-1291.
- [28] KOU BLI E, PALMER D, BETTS T, et al. Inference of missing PV monitoring data using neural networks[C]// Proceedings of 2016 IEEE 43rd Photovoltaic Specialists Conference(PVSC). Portland: IEEE, 2016: 3436-3440.
- [29] 王守相, 陈海文, 潘志新, 等. 采用改进生成式对抗网络的电力系统量测缺失数据重建方法[J]. 中国电机工程学报, 2019, 39(1): 56-64.
- WANG Shouxiang, CHEN Haiwen, PAN Zhixin, et al. A reconstruction method for missing data in power system measurement using an improved generative adversarial network[J]. Proceedings of the CSEE, 2019, 39(1): 56-64(in Chinese).
- [30] ZHOU Siyu, ZHOU Lin, MAO Mingxuan, et al. Transfer learning for photovoltaic power forecasting with long short-term memory neural network[C]// Proceedings of 2020 IEEE International Conference on Big Data and Smart Computing. Busan: IEEE, 2020: 125-132.
- [31] HU Qinghua, ZHANG Rujia, ZHOU Yucan. Transfer learning for short-term wind speed prediction with deep neural networks[J]. Renewable Energy, 2016, 85: 83-95.
- [32] CAI Long, GU Jie, MA Jinghua, et al. Probabilistic wind power forecasting approach via instance-based transfer learning embedded gradient boosting decision trees [J]. Energies, 2019, 12(1): 159.
- [33] 乔颖, 孙荣富, 丁然, 等. 基于数据增强的分布式光伏电站群短期功率预测(一): 方法框架与数据增强[J]. 电网技术, 2021, 45(5): 1799-1808.
- QIAO Ying, SUN Rongfu, DING Ran, et al. Distributed photovoltaic station cluster gridding short-term power forecasting . Part I : methodology and data augmentation[J]. Power System Technology, 2021, 45(5): 1799-1808(in Chinese).
- [34] WANG Fei, ZHANG Zhanyao, LIU Chun, et al. Generative adversarial networks and convolutional neural networks based weather classification model for day ahead short-term photovoltaic power forecasting [J]. Energy Conversion and Management, 2019, 181: 443-462.
- [35] 朱乔木, 李弘毅, 王子琪, 等. 基于长短期记忆网络的风电场发电功率超短期预测[J]. 电网技术, 2017, 41(12): 3797-3802.
- ZHU Qiaomu, LI Hongyi, WANG Ziqi, et al. Short-term wind power forecasting based on LSTM[J]. Power System Technology, 2017, 41(12): 3797-3802(in Chinese).
- [36] 宋家康, 彭勇刚, 蔡宏达, 等. 考虑多位置 NWP 和非典型特征的短期风电功率预测研究[J]. 电网技术, 2018, 42(10): 3234-3240.
- SONG Jiakang, PENG Yonggang, CAI Hongda, et al. Research of short-term wind power forecasting considering multi-location NWP and uncanonical feature [J]. Power System Technology, 2018, 42(10): 3234-3240(in Chinese).
- [37] FENG Cong, CUI Mingjian, HODGE B M, et al. A data-driven multi-model methodology with deep feature selection for short-term wind forecasting[J]. Applied Energy, 2017, 190: 1245-1257.
- [38] 徐龙博, 王伟, 张滔, 等. 基于神经网络平均影响值的超短期风电功率预测[J]. 电力系统自动化, 2017, 41(21): 40-45.
- XU Longbo, WANG Wei, ZHANG Tao, et al. Ultra-short-term wind power prediction based on neural network and mean impact value[J]. Automation of Electric Power Systems, 2017, 41(21): 40-45(in Chinese).
- [39] ŞEN Z, CEBECİ S M. Solar irradiation estimation by monthly principal component analysis[J]. Energy Conversion and Management, 2008, 49(11): 3129-3134.
- [40] ZARZO M, MARTÍ P. Modeling the variability of solar radiation data among weather stations by means of principal components analysis[J]. Applied Energy, 2011, 88(8): 2775-2784.
- [41] 王勃, 冯双磊, 刘纯. 基于天气分型的风电功率预测方法[J]. 电网技术, 2014, 38(1): 3695-3700.
- WANG Bo, FENG Shuanglei, LIU Chun. Study on weather typing based wind power prediction[J]. Power System Technology, 2014, 38(1): 3695-3700(in Chinese).
- [42] VAN DER MAATEN L, HINTON G. Visualizing data using t-SNE[J]. Journal of Machine Learning Research, 2008, 9: 2579-2605.
- [43] 熊音笛, 刘开培, 秦亮, 等. 基于时序数据动态天气划分的短期风电功率预测方法[J]. 电网技术, 2019, 43(9): 3353-3359.
- XIONG Yindi, LIU Kaipei, QIN Liang, et al. Short-term wind power prediction method based on dynamic wind power weather division of time sequence data[J]. Power

- System Technology, 2019, 43(9): 3353-3359(in Chinese).
- [44] WU Wenbin, PENG Mugen. A data mining approach combining K-means clustering with bagging neural network for short-term wind power forecasting[J]. IEEE Internet of Things Journal, 2017, 4(4): 979-986.
- [45] 王尤嘉, 鲁宗相, 乔颖, 等. 基于特征聚类的区域风电短期功率统计升尺度预测[J]. 电网技术, 2017, 41(5): 1383-1389.
- WANG Youjia, LU Zongxiang, QIAO Ying, et al. Short-term regional wind power statistical upscaling forecasting based on feature clustering[J]. Power System Technology, 2017, 41(5): 1383-1389(in Chinese).
- [46] 代倩, 段善旭, 蔡涛, 等. 基于天气类型聚类识别的光伏系统短期无辐照度发电预测模型研究[J]. 中国电机工程学报, 2011, 31(34): 28-35.
- DAI Qian, DUAN Shanxu, CAI Tao, et al. Short-term PV generation system forecasting model without irradiation based on weather type clustering [J]. Proceedings of the CSEE, 2011, 31(34): 28-35(in Chinese).
- [47] 王飞, 米增强, 甄钊, 等. 基于天气状态模式识别的光伏电站发电功率分类预测方法[J]. 中国电机工程学报, 2013, 33(34): 75-82.
- WANG Fei, MI Zengqiang, ZHEN Zhao, et al. A classified forecasting approach of power generation for photovoltaic plants based on weather condition pattern recognition[J]. Proceedings of the CSEE, 2013, 33(34): 75-82(in Chinese).
- [48] LIU Yongqian, SUN Ying, INFELD D, et al. A hybrid forecasting method for wind power ramp based on orthogonal test and support vector machine(OT-SVM) [J]. IEEE Transactions on Sustainable Energy, 2017, 8(2): 451-457.
- [49] RAGNACCI A, PASTORELLI M, VALIGI P, et al. Exploiting dimensionality reduction techniques for photovoltaic power forecasting[C]//Proceedings of 2012 IEEE International Energy Conference and Exhibition (ENERGYCON). Florence: IEEE, 2012: 867-872.
- [50] 陈昌松, 段善旭, 殷进军. 基于神经网络的光伏阵列发电预测模型的设计[J]. 电工技术学报, 2009, 24(9): 153-158.
- CHEN Changsong, DUAN Shanxu, YIN Jinjun. Design of photovoltaic array power forecasting model based on neural network[J]. Transactions of China Electrotechnical Society, 2009, 24(9): 153-158(in Chinese).
- [51] ALMONACID F, PÉREZ-HIGUERAS P J, FERNÁNDEZ E F, et al. A methodology based on dynamic artificial neural network for short-term forecasting of the power output of a PV generator [J]. Energy Conversion and Management, 2014, 85: 389-398.
- [52] 陈志宝, 丁杰, 周海, 等. 地基云图结合径向基函数人工神经网络的光伏功率超短期预测模型[J]. 中国电机工程学报, 2015, 35(3): 561-567.
- CHEN Zhibao, DING Jie, ZHOU Hai, et al. A model of very short-term photovoltaic power forecasting based on ground-based cloud images and RBF neural network [J]. Proceedings of the CSEE, 2015, 35(3): 561-567(in Chinese).
- [53] 茆美琴, 周松林, 苏建徽. 基于脊波神经网络的短期风电功率预测[J]. 电力系统自动化, 2011, 35(7): 70-74.
- MAO Meiqin, ZHOU Songlin, SU Jianhui. Short-term wind power forecast based on ridgelet neural network[J]. Automation of Electric Power Systems, 2011, 35(7): 70-74(in Chinese).
- [54] WAN Can, XU Zhao, PINSON P, et al. Probabilistic forecasting of wind power generation using extreme learning machine[J]. IEEE Transactions on Power Systems, 2014, 29(3): 1033-1044.
- [55] PERSSON C, BACHER P, SHIGA T, et al. Multi-site solar power forecasting using gradient boosted regression trees[J]. Solar Energy, 2017, 150: 423-436.
- [56] PANAMTASH H, ZHOU Qun, HONG Tao, et al. A copula-based Bayesian method for probabilistic solar power forecasting[J]. Solar Energy, 2020, 196: 336-345.
- [57] AGUIAR L M, PEREIRA B, DAVID M, et al. Use of satellite data to improve solar radiation forecasting with Bayesian Artificial Neural Networks[J]. Solar Energy, 2015, 122: 1309-1324.
- [58] 范晓旭, 付果, 张艳峰, 等. 基于FCM和贝叶斯神经网络的风电功率短期预测研究[J]. 风能, 2020(6): 72-77.
- FAN Xiaoxu, FU Guo, ZHANG Yanfeng, et al. Research on short-term prediction of wind power based on FCM and Bayesian neural network[J]. Wind Energy, 2020(6): 72-77(in Chinese).
- [59] 赵康宁, 蒲天骄, 王新迎, 等. 基于改进贝叶斯神经网络的光伏出力概率预测[J]. 电网技术, 2019, 43(12): 4377-4386.
- ZHAO Kangning, PU Tianjiao, WANG Xinying, et al. Probabilistic forecasting for photovoltaic power based on improved Bayesian neural network[J]. Power System Technology, 2019, 43(12): 4377-4386(in Chinese).
- [60] WEN Haoran, DU Yang, CHEN Xiaoyang, et al. Deep learning based multistep solar forecasting for PV ramp-rate control using sky images[J]. IEEE Transactions on Industrial Informatics, 2021, 17(2): 1397-1406.
- [61] CHANG G W, LU Hengjiu. Integrating gray data preprocessor and deep belief network for day-ahead PV power output forecast[J]. IEEE Transactions on Sustainable Energy, 2020, 11(1): 185-194.
- [62] KHODAYAR M, WANG Jianhui, MANTHOURI M.

- Interval deep generative neural network for wind speed forecasting[J]. IEEE Transactions on Smart Grid, 2019, 10(4): 3974-3989.
- [63] ZHANG Chunyang, CHEN C L P, GAN Min, et al. Predictive deep Boltzmann machine for multiperiod wind speed forecasting[J]. IEEE Transactions on Sustainable Energy, 2015, 6(4): 1416-1425.
- [64] 张倩, 马愿, 李国丽, 等. 频域分解和深度学习算法在短期负荷及光伏功率预测中的应用[J]. 中国电机工程学报, 2019, 39(8): 2221-2230.
- ZHANG Qian, MA Yuan, LI Guoli, et al. Applications of frequency domain decomposition and deep learning algorithms in short-term load and photovoltaic power forecasting[J]. Proceedings of the CSEE, 2019, 39(8): 2221-2230(in Chinese).
- [65] 杨茂, 白玉莹. 基于多位置 NWP 和门控循环单元的风电功率超短期预测[J]. 电力系统自动化, 2021, 45(1): 177-183.
- YANG Mao, BAI Yuying. Ultra-short-term prediction of wind power based on multi-location numerical weather prediction and gated recurrent unit[J]. Automation of Electric Power Systems, 2021, 45(1): 177-183(in Chinese).
- [66] 司志远, 杨明, 于一潇, 等. 基于卫星云图特征区域定位的超短期光伏功率预测方法[J]. 高电压技术, 2021, 47(4): 1214-1223.
- SI Zhiyuan, YANG Ming, YU Yixiao, et al. Ultra-short-term photovoltaic power prediction method based on satellite image feature region positioning[J]. High Voltage Engineering, 2021, 47(4): 1214-1223(in Chinese).
- [67] ZHAO Xin, WEI Haikun, WANG Hai, et al. 3D-CNN-based feature extraction of ground-based cloud images for direct normal irradiance prediction[J]. Solar Energy, 2019, 181: 510-518.
- [68] 朱想, 居蓉蓉, 程宇, 等. 组合数值天气预报与地基云图的光伏超短期功率预测模型[J]. 电力系统自动化, 2015, 39(6): 4-10, 74.
- ZHU Xiang, JU Rongrong, CHENG Xu, et al. A very short-term prediction model for photovoltaic power based on numerical weather prediction and ground-based cloud images[J]. Automation of Electric Power Systems, 2015, 39(6): 4-10, 74(in Chinese).
- [69] 周志华. 机器学习[M]. 北京: 清华大学出版社, 2016.
- ZHOU Zhihua. Machine learning[M]. Beijing: Tsinghua University Press, 2016(in Chinese).
- [70] CHENG H Y. Hybrid solar irradiance now-casting by fusing Kalman filter and regressor[J]. Renewable Energy, 2016, 91: 434-441.
- [71] 丁明, 刘志, 毕锐, 等. 基于灰色系统校正-小波神经网络的光伏功率预测[J]. 电网技术, 2015, 39(9): 2438-2443.
- DING Ming, LIU Zhi, BI Rui, et al. Photovoltaic output prediction based on grey system correction-wavelet neural network[J]. Power System Technology, 2015, 39(9): 2438-2443(in Chinese).
- [72] 丁明, 张超, 王勃, 等. 基于功率波动过程的风电功率短期预测及误差修正[J]. 电力系统自动化, 2019, 43(3): 2-9.
- DING Ming, ZHANG Chao, WANG Bo, et al. Short-term forecasting and error correction of wind power based on power fluctuation process[J]. Automation of Electric Power Systems, 2019, 43(3): 2-9(in Chinese).
- [73] 余光正, 陆柳, 汤波, 等. 基于云图特征提取的改进混合神经网络超短期光伏功率预测方法[J]. 中国电机工程学报, 2021, 41(20): 6989-7002.
- YU Guangzheng, LU Liu, TANG Bo, et al. An improved hybrid neural network ultra-short-term photovoltaic power forecasting method based on cloud image feature extraction[J]. Proceedings of the CSEE, 2021, 41(20): 6989-7002(in Chinese).
- [74] 叶林, 裴铭, 路朋, 等. 基于天气分型的短期光伏功率组合预测方法[J]. 电力系统自动化, 2021, 45(1): 44-54.
- YE Lin, PEI Ming, LU Peng, et al. Combination forecasting method of short-term photovoltaic power based on weather classification[J]. Automation of Electric Power Systems, 2021, 45(1): 44-54(in Chinese).
- [75] WANG Huaizhi, LI Gangqiang, WANG Guibin, et al. Deep learning based ensemble approach for probabilistic wind power forecasting[J]. Applied Energy, 2017, 188: 56-70.
- [76] LI Pengtao, ZHOU Kaile, LU Xinhui, et al. A hybrid deep learning model for short-term PV power forecasting [J]. Applied Energy, 2020, 259: 114216.
- [77] YANG H T, HUANG Chaoming, HUANG Y C, et al. A weather-based hybrid method for 1-day ahead hourly forecasting of PV power output[J]. IEEE Transactions on Sustainable Energy, 2014, 5(3): 917-926.
- [78] 刘克文, 蒲天骄, 周海明, 等. 风电日前发电功率的集成学习预测模型[J]. 中国电机工程学报, 2013, 33(34): 130-135.
- LIU Kewen, PU Tianjiao, ZHOU Haiming, et al. A short term wind power forecasting model based on combination algorithms[J]. Proceedings of the CSEE, 2013, 33(34): 130-135(in Chinese).
- [79] 胡梦月, 胡志坚, 仇梦林, 等. 基于改进 AdaBoost.RT 和 KELM 的风功率预测方法研究[J]. 电网技术, 2017, 41(2): 536-542.
- HU Mengyue, HU Zhijian, ZHANG Menglin, et al. Research on wind power forecasting method based on improved AdaBoost.RT and KELM algorithm[J]. Power

- System Technology, 2017, 41(2): 536-542(in Chinese).
- [80] GANDELLI A, GRIMACCIA F, LEVA S, et al. Hybrid model analysis and validation for PV energy production forecasting[C]//Proceedings of 2014 International Joint Conference on Neural Networks. Beijing: IEEE, 2014: 1957-1962.
- [81] 张东英, 代悦, 张旭, 等. 风电爬坡事件研究综述及展望[J]. 电网技术, 2018, 42(6): 1783-1792.
ZHANG Dongying, DAI Yue, ZHANG Xu, et al. Review and prospect of research on wind power ramp events [J]. Power System Technology, 2018, 42(6): 1783-1792(in Chinese).
- [82] 欧阳庭辉, 查晓明, 秦亮, 等. 基于气象背景选取邻近点的风电功率爬坡事件预测方法[J]. 电网技术, 2015, 39(11): 3266-3272.
OUYANG Tinghui, ZHA Xiaoming, QIN Liang, et al. Prediction method of wind power ramp events by using meteorological conditions to select adjacent points [J]. Power System Technology, 2015, 39(11): 3266-3272(in Chinese).
- [83] 叶林, 陈政, 赵永宁, 等. 基于遗传算法-模糊径向基神经网络的光伏发电功率预测模型[J]. 电力系统自动化, 2015, 39(16): 16-22.
YE Lin, CHEN Zheng, ZHAO Yongning, et al. Photovoltaic power forecasting model based on genetic algorithm and fuzzy radial basis function neural network [J]. Automation of Electric Power Systems, 2015, 39(16): 16-22(in Chinese).
- [84] QUAN Hao, SRINIVASAN D, KHOSRAVI A. Short-term load and wind power forecasting using neural network-based prediction intervals[J]. IEEE Transactions on Neural Networks and Learning Systems, 2014, 25(2): 303-315.
- [85] 陈杰, 沈艳霞, 陆欣, 等. 一种风电功率概率区间多目标智能优化预测方法[J]. 电网技术, 2016, 40(8): 2281-2287.
CHEN Jie, SHEN Yanxia, LU Xin, et al. An intelligent multi-objective optimized method for wind power prediction intervals[J]. Power System Technology, 2016, 40(8): 2281-2287(in Chinese).
- [86] AMJADY N, KEYNIA F, ZAREIPOUR H. Wind power prediction by a new forecast engine composed of modified hybrid neural network and enhanced particle swarm optimization[J]. IEEE Transactions on Sustainable Energy, 2011, 2(3): 265-276.
- [87] 陈国初, 公维祥, 冯兆红. 熵判别人工蜂群算法优化的风电功率组合预测模型[J]. 电力系统及其自动化学报, 2017, 29(7): 41-45, 67.
CHEN Guochu, GONG Weixiang, FENG Zhaohong. Combined wind power prediction model optimized by entropy criterion artificial bee colony algorithm [J]. Proceedings of the CSU-EPSCA, 2017, 29(7): 41-45, 67(in Chinese).
- [88] 马斌, 张丽艳, 郭成. 一种变权重风电功率最优组合预测模型[J]. 电力系统保护与控制, 2016, 44(5): 117-121.
MA Bin, ZHANG Liyan, GUO Cheng. An optimal combination forecasting model with variable weight for wind power[J]. Power System Protection and Control, 2016, 44(5): 117-121(in Chinese).
- [89] 孟安波, 许炫淙, 陈嘉铭, 等. 基于强化学习和组合式深度学习模型的超短期光伏功率预测[J]. 电网技术, 2021, 45(12): 4721-4728.
MENG Anbo, XU Xuancong, CHEN Jiaming, et al. Ultra short term photovoltaic power prediction based on reinforcement learning and combined deep learning model[J]. Power System Technology, 2021, 45(12): 4721-4728(in Chinese).
- [90] HONG Tao, PINSON P, FAN Shu. Global energy forecasting competition 2012[J]. International Journal of Forecasting, 2014, 30(2): 357-363.
- [91] HONG Tao, PINSON P, FAN Shu, et al. Probabilistic energy forecasting: Global energy forecasting competition 2014 and beyond[J]. International Journal of Forecasting, 2016, 32(3): 896-913.
- [92] HONG Tao, XIE Jingrui, BLACK J. Global energy forecasting competition 2017: Hierarchical probabilistic load forecasting[J]. International Journal of Forecasting, 2019, 35(4): 1389-1399.
- [93] 王伟胜, 车建峰, 王勃, 等. 光伏发电功率预测技术及应用[M]. 北京: 中国电力出版社, 2019.
WHANG Weisheng, CHE Jianfeng, WANG Bo, et al. Power prediction technology and application of photovoltaic power generation[M]. Beijing: China Electric Power Press, 2019(in Chinese).
- [94] 孙荣富, 张涛, 和青, 等. 风电功率预测关键技术及应用综述[J]. 高电压技术, 2021, 47(4): 1129-1143.
SUN Rongfu, ZHANG Tao, HE Qing, et al. Review on key technologies and applications in wind power forecasting[J]. High Voltage Engineering, 2021, 47(4): 1129-1143(in Chinese).



朱琼锋

在线出版日期: 2022-04-26。

收稿日期: 2021-12-01。

作者简介:

朱琼锋(1987), 男, 工学硕士, 高级工程师, 从事新能源功率预测、人工智能应用等研究工作, zhuqiongfeng@epri.sgcc.com.cn;

*通信作者: 李家腾(1996), 女, 工学硕士, 助理工程师, 从事新能源功率预测、人工智能应用等研究工作, lijiateng@epri.sgcc.com.cn。

(责任编辑 乔宝榆)

Application and Prospect of Artificial Intelligence Technology in Renewable Energy Forecasting

ZHU Qiongfeng¹, LI Jiateng^{1*}, QIAO Ji¹, SHI Mengjie¹, WANG Chaoliang²

(1. China Electric Power Research Institute; 2. State Grid Zhejiang Marketing Service Centre)

KEY WORDS: wind power generation; photovoltaic power generation; power prediction; artificial intelligence (AI) technology

The volatility and randomness of renewable energy power generation have brought major challenges to grid security and renewable energy consumption. Renewable energy power prediction is the key technology to reduce its random impact. Renewable energy power prediction is generally based on meteorological forecasting data, power data and meteorological monitoring data, and combined with renewable energy station location, equipment parameters and other information for modeling to predict the output trend of renewable energy in the future period of time.

Renewable energy power forecasting can be classified according to different dimensions, and it also can be divided into ultra short-term, short-term, medium and long-term forecasting according to time scale. According to the spatial scale, it can be divided into single machine prediction, single station prediction and regional prediction. According to the prediction results, it can be divided into deterministic prediction, probability prediction and events prediction. According to the modeling method, it can be divided into physical modeling method, time series modeling method, modeling method based on artificial intelligence technology such as machine learning and deep learning. The renewable energy power prediction technology framework diagram based on artificial intelligence (AI) technology is shown in Fig. 1, which includes four layers, namely the data layer,

the model layer, the scene layer and the application layer.

This paper first briefly discusses the theoretical basis of AI technology in the application of renewable energy power forecasting, and systematically summarizes the application of AI technology in wind power and photovoltaic power forecasting, including the application of various data processing technologies such as data enhancement and feature construction, application of traditional machine learning, deep learning, and combined algorithms in model construction, and the application of evolutionary algorithm, swarm intelligence optimization, reinforcement learning and other intelligent optimization algorithms in model training and hyperparameter optimization. Then the current related literature is statistically analyzed, and based on the results of the renewable energy forecasting contest as well as the actual forecasting system research situation, the current academic research hotspots and trends, and the application of industrial models are compared and analyzed. Finally, some problems existing in the current renewable energy power forecasting in scene adaptation, few-shot learning, numerical weather prediction (NWP) data spatio-temporal resolution, distributed renewable energy prediction, etc. are analyzed, and the prospects of a variety of AI technologies such as reinforcement learning, meta-learning, graph neural network, to solve related problems are prospected.




Fig. 1 Renewable energy power prediction technology framework diagram based on AI technology