

基于 RTSGAN 样本扩充和注意力动态权重集成的 寒潮极端天气条件下风电功率预测方法

宋嘉炯^{1,2}, 彭小圣¹, 覃国元¹

(1. 强电磁技术全国重点实验室(华中科技大学), 湖北省 武汉市 430074;

2. 华中科技大学人工智能研究院, 湖北省 武汉市 430074)

Wind Power Prediction Method Under Cold Wave Weather Conditions Based on RTSGAN Sample Data Expansion and Attention Dynamic Weight Integration

SONG Jiajiong^{1,2}, PENG Xiaosheng¹, QIN Guoyuan¹

(1. State Key Laboratory of Advanced Electromagnetic Technology (Huazhong University of Science and Technology),
Wuhan 430074, Hubei Province, China;

2. Institute of Artificial Intelligence, Huazhong University of Science and Technology, Wuhan 430074, Hubei Province, China)

ABSTRACT: Wind power output is closely related to operational conditions. As an extreme weather event, the cold wave often leads to a sharp increase in electricity load. In this scenario, the wind power prediction results may deviate significantly from actual output, posing challenges to the safe operation of the power system. This paper proposes a wind power prediction method for extreme cold wave weather conditions, utilizing RTSGAN sample expansion and attention dynamic weight integration. Firstly, to address the issue of scarce wind power samples during cold wave conditions, RTSGAN is used to expand the original sample data for the cold wave period. Then, the basic prediction models and attention network are constructed based on the expanded sample dataset. Finally, the wind power prediction is carried out by the attention dynamic weight integration method. Experimental results show that the proposed method can address the scarcity of wind power samples during cold wave extreme weather and effectively improve the accuracy of wind power prediction under these conditions.

KEY WORDS: wind power prediction; cold wave weather; RTSGAN; attention mechanism; integrated prediction

摘要: 风电出力与运行条件密切相关, 寒潮作为一种极端天气事件, 往往会导致电力负荷激增。该场景下的风电功率预测结果与实际出力存在较大偏差, 从而对电力系统的安全稳定运行带来了挑战。文章提出了一种基于现实时间序列生成对抗网络(real-world time series generative adversarial

network, RTSGAN)样本扩充和注意力动态权重集成的寒潮极端天气条件下风电功率预测方法。首先针对寒潮天气下风电样本稀缺的问题, 采用 RTSGAN 对寒潮事件原始数据进行样本扩充; 然后基于扩充得到的样本数据集分别构建基础预测模型和注意力网络; 最后通过注意力动态权重集成方法进行风电功率预测。算例结果表明, 所提方法能够解决寒潮极端天气风电样本稀缺的问题, 可有效提升寒潮极端天气条件下的风电功率预测精度。

关键词: 风电功率预测; 寒潮天气; 现实时间序列生成对抗网络; 注意力机制; 集成预测

DOI: 10.13335/j.1000-3673.pst.2025.0561

0 引言

随着我国风电装机容量的增加, 寒潮极端天气场景导致的风电出力受限对电网电力电量平衡带来了挑战^[1-3], 寒潮天气已经成为威胁电力系统安全稳定运行的高风险场景^[4-6]。因此需要针对寒潮极端天气条件下风电功率预测开展研究。

寒潮是一种极端转折性天气, 该场景下的风电出力样本稀缺, 风电功率预测建模难度大。使用生成对抗网络(generative adversarial networks, GAN)进行数据增强是小样本建模的有效方法^[7-9], 现有文献已经对基于 GAN 样本扩充的风电功率预测方法展开初步研究。文献[10]提出了一种基于半监督 GAN 的混合预测模型, 用于风电功率及爬坡事件的短期预测。文献[11]提出一种基于生成对抗网络的转折性天气日前风电功率预测方法, 对多场景气象敏感特征小样本集进行有效扩充并建模。文献[12]提出一种基于生成对抗网络的小样本条件风

基金项目: 智能电网重大专项(2030): “美丽乡村分布式智慧能源系统示范工程”(2024ZD0800500)。

Project Supported by Smart Grid - National Science and Technology Major Project (2024ZD0800500).

电功率预测方法,有效提升了极端天气下的风电功率预测精度。上述研究有效解决了风电样本稀缺导致预测建模困难的问题,但不足之处在于采用的生成对抗网络模型较少考虑时间序列数据的动态特征,难以有效学习寒潮天气下风电出力样本特性。相较于上述模型,现实时间序列生成对抗网络(real-world time series generative adversarial network, RTSGAN)采用固定维度潜在空间和改进 Wasserstein 生成对抗网络(Wasserstein generative adversarial network, WGAN)框架^[13],在捕获时间序列样本特性方面能够取得更好的结果,近年来已经在多个领域得到验证应用^[14-16]。因此将 RTSGAN 运用到寒潮小样本条件下的时间序列样本扩充,有望解决风电出力样本稀缺的难题。

寒潮天气对风电出力的影响主要包括风机覆冰脱网、低温脱网、大风切机等^[17],温度、湿度、风速等多种气象要素共同作用导致风电出力受限,预测结果与实际功率产生较大偏差。与此同时,寒潮过境引发电网负荷骤增,进一步影响电网安全稳定运行。以东北地区某风电场 2019 年 1 月的一次寒潮事件为例,寒潮过程风电功率预测结果与实际出力结果如图 1 所示。可以看出随着寒潮过程气象要素的变化,风电出力表现出动态演变特性。寒潮演化过程主要分为 3 种阶段:1)寒潮前期,受到强冷空气抬升作用影响,风速逐步增大,风功率密度得到增强,但风速过快可能导致大风切机^[12]。2)寒潮中期,由于存在极端低温、风机覆冰等问题,风电机组出力出现大幅度下降,严重时甚至触发保护系统发生切机脱网^[18]。3)寒潮后期,随着温度逐步回升,覆冰消融过程加速,风电机组输出功率逐渐恢复正常。

由图 1 可知,传统风电功率预测方法在寒潮过程不同阶段的预测性能存在差异。以此次寒潮事件为例,反向传播神经网络(back propagation neural network, BPNN)在寒潮过程前期和后期的预测精度较高,但在寒潮中期的精度较低,部分时刻预测偏差可达到 40%以上,而长短期记忆网络(long short-term memory, LSTM)虽然在前期和后期阶段的预测精度相较 BPNN 偏低,但在寒潮中期阶段取得了较好的预测性能。综上所述寒潮天气条件下单一预测模型泛化能力差,难以同时满足寒潮过程不同阶段的预测精度需求。集成预测能够综合考虑多种模型的预测结果,是一种可以降低单一模型预测误差的方法^[19-22],现有文献已经对风电功率集成预测方法展开研究。文献^[23]

提出一种多算法融合的风电功率集成预测方法,通过风速修正和集成预测提升风电功率短期预测精度。文献^[24]提出一种基于贝叶斯平均组合策略的集成预测模型,能够预测不同天气条件下的风电功率。文献^[25]提出一种考虑时域信息的风电功率集成预测方法,通过算例证明所提方法的有效性。上述研究验证了集成预测方法能够弥补单一预测模型的缺陷,提升模型泛化能力,但不足之处在于其通常采用简单加权平均的策略,各个子模型的权重固定,难以适用于气象条件复杂的寒潮天气风电功率预测。注意力机制通过赋予输入数据不同的权重使得模型具备高效捕捉重要信息的能力,近年在时间序列预测领域得到广泛应用^[26-28]。因此,本文借鉴注意力机制的权重调整思路,根据寒潮天气过程气象条件实时动态调整各风电功率基础预测模型权重,有望提升寒潮天气条件风电功率预测精度。




图 1 寒潮事件风电出力动态演变特性
Fig. 1 Dynamic evolution characteristics of wind power output during cold wave events

综上所述,为了实现寒潮天气小样本条件下风电功率预测,本文提出一种基于 RTSGAN 样本扩充和注意力动态权重集成的寒潮极端天气风电功率预测方法。首先采用 RTSGAN 对寒潮天气风电出力数据进行样本扩充,再通过注意力动态权重集成方法进行寒潮天气条件风电功率预测建模,最后通过算例验证了所提方法的有效性,提升了寒潮极端天气条件下的风电功率预测精度。

1 基于 RTSGAN 样本扩充和注意力动态权重集成的寒潮极端天气风电功率预测方法

1.1 总体框架

本文提出基于 RTSGAN 样本扩充和注意力动态权重集成的寒潮极端天气风电功率预测方法,整体框架如图2所示。图2中:CNN为卷积神经网络(convolutional neural networks);SDAE为堆叠去噪自动编码器(stacked denoising autoencoders)。该方法包含如下5个步骤。

步骤1:样本筛选。基于寒潮天气的定义指标进行样本筛选,得到寒潮天气事件样本数据集。

步骤2:RTSGAN样本扩充。采用滑动时间窗口的方式进行移位采样,划分得到一系列时间序列片段。将样本片段输入RTSGAN,通过生成器和解码器合成高质量的时间序列样本片段。

步骤3:基础预测模型训练。构建风电功率预测方法库,采用训练集数据对风电功率基础预测模型进行训练,为注意力网络的训练提供模型基础。

步骤4:注意力网络训练。将验证集数值天气预报(numerical weather prediction, NWP)数据输入基础预测模型进行预测得到初步预测结果,再将验证集 NWP 数据和初步预测结果用于注意力网络的训练,构建注意力动态权重网络。

步骤5:动态权重集成预测。首先基于测试集 NWP 得到初步风电功率预测值;再将 NWP 数据和初步风电功率预测值输入到注意力动态权重网络,分别输出不同时刻各个模型对应的权重系数;最后将各个初步风电功率预测结果乘以对应的动态权重系数进行集成,得到最终风电集成预测结果。




图2 基于 RTSGAN 样本扩充和注意力动态权重集成的寒潮极端天气条件风电功率预测方法
Fig. 2 Wind power prediction method under cold wave weather conditions based on RTSGAN sample expansion and attention dynamic weight integration

1.2 基于 RTSGAN 的寒潮风电样本扩充

寒潮天气是典型的小样本场景，样本数量不足导致风电功率预测模型难以充分训练，因此需要进行样本数据扩充。文献[13]对时间序列生成对抗网络(time-series generative adversarial networks, TimeGAN)进行改进，提出 RTSGAN 用来解决数据稀缺的难题，生成符合真实样本特性的新样本。

RTSGAN 由自编码器模块和生成模块两个部分组成。自编码器模块由编码器和解码器组成。编码器对原始序列片段进行特征降维和序列压缩，得到固定长度的低维特征序列，解码器再将低维特征序列重构成完整的时间序列片段。相较于 TimeGAN 模型，RTSGAN 从特征维度和序列长度两个方面对原始特征序列片段进行降维压缩，有效简化了 RTSGAN 学习长序列复杂样本特征的过程。由于压缩得到的低维特征序列长度固定，不随原始序列长度变化而改变，使得 RTSGAN 能够更加高效地生成低维特征序列，因此在面对复杂的长序列寒潮风电样本时，RTSGAN 能够有效学习寒潮天气条件下风电出力样本特性，生成符合真实样本分布的新样本，有效解决样本稀缺的难题。

同时，针对传统 GAN 存在的训练不稳定、生成样本单一问题，RTSGAN 基于改进 WGAN 框架构建生成模块。该模块由生成器和判别器组成，生成器将随机序列片段作为输入，合成与真实数据相似的样本，判别器用于区分真实数据和生成数据。生成模块采用 Wasserstein 距离作为损失函数用于衡量真实数据和生成数据的分布差异。由于 Wasserstein 距离能够提供稳定的梯度信号，避免梯度消失问题，使得生成模块能够有效学习数据分布，从而提升了生成模块的收敛性和鲁棒性。

针对上述两个模块，RTSGAN 分别构建不同的损失函数用于模块训练。自编码器模块训练目标是 최소화输入特征序列与输出重构序列的重构误差，生成模块训练目标是 최소화生成样本与真实样本的 Wasserstein 距离，损失函数分别如式(1)(2)所示。

$$\min_{\text{encoder, decoder}} L(\hat{X}, X) \quad (1)$$

$$\min_G \max_D E_{r \sim \text{encoder}}[D(r)] - E_{z \sim p(z)}[D(G(z))] \quad (2)$$

式中： X 表示原始特征序列； $\hat{X}$ 表示重构序列； G 表示生成器； D 表示判别器； encoder 表示编码器， decoder 表示解码器； r 表示低维特征序列； z 表示随机特征序列。

本文采用 RTSGAN 对寒潮事件的 NWP 数据和风电功率数据同时进行扩充，RTSGAN 样本扩充流

程如图 3 所示。首先将各个 NWP 气象参数序列和风电功率序列按照对应时刻进行合并得到气象-功率序列，采用滑动时间窗口进行移位采样，将气象-功率序列划分为一系列特征序列片段；然后基于重构损失函数对编码器和解码器进行参数更新；接着基于训练得到的解码器，将 Wasserstein 距离作为损失函数对生成器和判别器进行参数更新；最后从高斯分布中进行采样得到随机序列，依次通过生成器和解码器进行样本扩充，得到生成样本序列片段。




图 3 RTSGAN 样本扩充流程图

Fig. 3 Flowchart of RTSGAN sample expansion

1.3 基于注意力机制的动态权重集成预测方法

本文提出的基于注意力机制的动态权重集成预测模型结构如图 4 所示。采用多任务 Attention-双向门控循环单元(bidirectional gated recurrent unit, BiGRU)框架构建注意力网络模型。将风速、风向、温度、湿度等寒潮过程气象特征和各模型风电功率初步预测结果共同输入到注意力网络中。在隐藏层中，通过多头自注意力机制挖掘寒潮天气过程风电出力数据在时间维度上的特征信息，再将得到的特征作为 BiGRU 网络的输入，通过 BiGRU 双向结构，进一步捕捉时间序列数据的动态信息。在输出层中，引入 Softmax 函数使得注意力网络模型各个输出值均在[0,1]区间内，且各输出值总和为 1，因此可以将注意力网络输出视为各个基础预测模

型的权重系数。其中第 k 个基础预测模型的权重系数计算公式如式(3)所示。

$$\omega_k = \frac{e^{Z_k}}{\sum_{n=1}^N e^{Z_n}} \quad (3)$$

式中: ω_k 表示第 k 个基础预测模型的权重系数; Z_k 表示注意力网络第 k 个输出; Z_n 表示注意力网络第 n 个输出; N 表示基础预测模型的总数。




图4 动态权重集成预测模型结构图

Fig. 4 Sketch diagram of integrated prediction model with dynamic weights

在注意力网络训练过程中,基于验证集数据计算注意力网络损失值,作为更新网络参数的参考依据。本文采用多模型预测结果的加权均方误差(mean squared error, MSE)构建损失函数,结合注意力网络输出的动态权重进行整体优化,具体损失函数如式(4)(5)所示。注意力网络模型训练目标是 minimized 动态加权集成预测结果与实际功率的误差,由于 MSE 具有良好的凸性和稳定性,能够确保集成预测误差的稳定优化。同时,在训练过程中,随着网络参数的更新,注意力网络不同时刻的输出趋于稳定,各预测模型的动态权重也将逐步收敛。

$$P_{\text{Predict},t} = \sum_{n=1}^N \omega_{n,t} P_{n,t} \quad (4)$$

$$\mathcal{L} = \frac{1}{T} \sum_{t=1}^T (P_{\text{Actual},t} - P_{\text{Predict},t})^2 \quad (5)$$

式中: $P_{\text{Predict},t}$ 表示 t 时刻注意力动态加权集成预测结果; $\omega_{n,t}$ 表示 t 时刻第 n 个基础预测模型的权重; $P_{n,t}$ 表示 t 时刻第 n 个基础预测模型的权重; N 表示基础预测模型的总数; T 表示预测总时刻数; $\mathcal{L}$ 表示预测误差; $P_{\text{Actual},t}$ 表示 t 时刻注意力动态加权集成预测结果。

考虑到同一模型在寒潮演化过程不同阶段的预测性能存在差异,本文所提方法能够动态实时调整各个基础预测模型集成权重以快速适应寒潮过程中风电运行条件变化。因此相较于传统集成预测方法,所提方法能够提升寒潮过程不同阶段的风电功率预测精度,具有较高的泛化性。

2 算例分析

本文以我国东北地区某风电场为研究对象进行算例分析。风电场数据包括 NWP 和实际功率,数据长度从 2017 年 1 月 1 日到 2019 年 12 月 31 日,其中 NWP 数据每 12h 预报更新一次。将数据集划分为训练集、验证集、测试集,具体划分流程如图 5 所示,训练集包含 2017 年真实寒潮样本和扩充样本,验证集包含 2018 年真实寒潮样本和扩充样本,测试集包含 2019 年真实寒潮样本。




图5 数据集划分流程示意图

Fig. 5 Diagram of the dataset partitioning process

本节算例中预测风电预测模型性能指标采用均方根误差(root mean square error, RMSE)和平均绝对误差(mean absolute error, MAE),计算公式如式(6)(7)所示。

$$e_{\text{RMSE}} = \sqrt{\frac{1}{N} \sum_{t=1}^N (P_{\text{Actual},t} - P_{\text{Predict},t})^2} \quad (6)$$

$$e_{\text{MAE}} = \frac{1}{N} \sum_{t=1}^N |P_{\text{Actual},t} - P_{\text{Predict},t}| \quad (7)$$

式中： $P_{Actual,t}$ 表示 t 时刻的实际风电功率值； $P_{Predict,t}$ 表示 t 时刻的预测风电功率值； N 表示数据样本的数量。

本文选择 BPNN、CNN、LSTM、CNN-LSTM、SDAE 这 5 个神经网络作为基础预测模型，构建风电功率预测模型库用于后续验证本文所提风电功率预测方法的有效性。BPNN 是一种基础的神经网络，通过反向传播算法调整权重和偏差；CNN 是一种卷积神经网络^[29]，通过稀疏连接和共享权值的方式能够有效挖掘时间序列数据特征；LSTM 是一种循环神经网络^[30]，能够有效学习长时间序列数据信息；CNN-LSTM 能够充分利用 CNN 和 LSTM 的模型优势^[31]；SDAE 是一种无监督深度学习网络，通过特征融合有效提升预测模型的泛化能力。

2.1 样本筛选

寒潮天气是一种由高纬度地区冷空气大规模向中低纬度地区侵袭而造成气温剧烈下降的天气活动。根据国家现行标准^[32]，选取日最低气温和日最低温度降幅作为寒潮天气定义指标，具体为：“日最低温度在一天内降温幅度超过 8℃，或两天内降温幅度超过 10℃，或 3 天内降温幅度超过 12℃，同时该地日最低气温低于 4℃，且日最低气温连续下降”^[33-34]。

本节基于寒潮天气的定义指标，对原始 NWP 数据和风电功率数据集进行筛选，构建得到寒潮天气风电样本数据集。原始样本共包含 7 次寒潮事件，累计持续时间 368h，共计 1472 条样本，每条样本包含温度、气压、湿度、大尺度降水、4 个高度的风速和风向、风电功率。

2.2 样本扩充效果分析

本节采用 RTSGAN 对 2017 年和 2018 年寒潮事件的 NWP 数据和风电功率数据进行扩充，原始气象-功率序列数据集分别共计样本 352 条和 464 条。设置滑动时间窗口长度为 48，移动步长为 1，采用滑动时间窗口分别对 2017 年和 2018 年气象-功率序列进行移位采样，得到时间序列片段 258 个和 370 个。基于时间序列片段训练 RTSGAN 网络并进行样本扩充，对扩充样本进行异常数据筛选后分别累计得到生成样本 15811 条和 19804 条。

为了评估本文所提 RTSGAN 方法得到的扩充样本在小样本条件风电功率预测建模的有效性，将所提模型与常见的生成对抗网络模型进行对比，包括 TimeGAN、WGAN、GAN。采用本文所提风电功率预测建模方法，分别基于原始数据和各类生成对抗网络扩充数据训练对应的风电功率预测模型，

采用 RMSE 和 MAE 作为预测分数评价指标，预测分数越小表明训练得到的模型预测精度越高。

不同样本扩充方法的预测分数对比结果如表 1 所示。RTSGAN 扩充样本数据集构建的风电功率模型取得了最优预测性能，相较于由其他扩充数据训练得到的风电功率预测模型 RMSE 降低了 1.32%~4.41%，MAE 降低了 1.11%~4.33%，这表明由于 RTSGAN 在样本扩充过程中额外学习了风电出力样本的时序特性，因此生成的时间序列数据在风电功率预测建模方面的有效性更高，最终取得了比原始数据和其他类型扩充数据更优的预测性能。

表 1 不同样本扩充方法的预测结果对比
Table 1 Comparison of discriminant scores and predictive scores among different sample expansion methods

样本扩充方法	RMSE	MAE
GAN	0.1859	0.1454
WGAN	0.1762	0.1367
TimeGAN	0.1550	0.1132
RTSGAN	0.1418	0.1021
原始数据	0.1901	0.1574

图 6 展示了不同样本扩充方法评估对比结果，证实了 RTSGAN 样本扩充方法在小样本条件风电功率预测建模的有效性。算例表明 RTSGAN 样本扩充方法能够有效解决寒潮天气条件下风电功率预测建模困难的问题。




图 6 不同样本扩充方法评估对比结果

Fig. 6 Result of different sample expansion methods

2.3 注意力动态权重集成预测建模效果分析

为了验证本文所提注意力动态权重集成预测方法的有效性，本节分别设置两个对照组进行对比分析。对照组 1 为单一预测方法，即采用本文选择的 5 个基础预测模型；对照组 2 为常用的集成预测方法，即在 5 个预测模型的基础上进行集成功率预测。将本文所提方法分别同两个对照组进行对比。

2.3.1 所提方法对比单一预测方法

本节将所提动态权重集成预测方法与单一预

测方法进行对比,包括 BPNN、CNN、LSTM、SDAE、CNN-LSTM。寒潮天气条件下不同预测方法的风电功率预测误差对比结果如表 2 所示。从表 2 中数据可以看出,本文所提的注意力动态权重集成预测方法取得的预测误差低于单一预测方法,相较于单一预测方法取得的 RMSE 降低了 1.71%~3.68%,MAE 降低了 1.78%~3.55%。结果表明本文提出的动态权重集成预测方法在寒潮条件风电功率预测上相较于单一预测方法更有优势。

为了进一步验证所提方法在寒潮过程不同阶段的预测性能,以该风电场 2019 年 1 月的同一次寒潮事件为例,不同方法的预测风电功率曲线及实际功率如图 7 所示。图 7(a)为完整的寒潮过程,

图 7(b)~(e)为本次寒潮过程中 4 个时段的详细结果。从图 7 中可以看出,本文所提方法取得的预测功率相较于其他单一预测方法在总体上更加接近实测功率,证实了本文所提方法能有效提升预测精度。

表 2 所提方法与单一预测方法预测误差对比
Table 2 Comparison of prediction error among the proposed method and single prediction methods

预测方法	RMSE	MAE
BPNN	0.1786	0.1376
CNN	0.1732	0.1354
LSTM	0.1679	0.1261
SDAE	0.1621	0.1237
CNN-LSTM	0.1589	0.1199
所提方法	0.1418	0.1021




图 7 所提方法与单一预测方法预测功率曲线对比
Fig. 7 Prediction power curves comparison of the proposed method and single prediction methods

对测试集的所有寒潮事件进行风电功率预测,分别统计所提预测方法和单一预测方法在寒潮过程不同阶段的风电功率预测误差,结果如表 3 所示。从表 3 中数据可以看出,同一预测模型在寒潮天气过程的不同阶段取得的预测功率精度存在差异。而本文所提方法基于寒潮气象要素和风电功率初步预测结果动态调整各个基础预测模型的权重,在寒潮过程各个阶段均能取得较高的预测精度,整体上更加接近实测功率。算例表明本文提出的动态权重集成预测方法相较于单一预测方法能够取得了最优预测性能,证实了该方法的有效性。

表 3 所提方法与单一预测方法不同阶段的预测误差对比
Table 3 Comparison of prediction error at different stages between the proposed method and single prediction methods

预测方法	寒潮前期		寒潮中期		寒潮后期	
	RMSE	MAE	RMSE	MAE	RMSE	MAE
BPNN	0.1293	0.0991	0.2090	0.1698	0.1372	0.0966
CNN	0.1455	0.1029	0.1959	0.1637	0.1313	0.0970
LSTM	0.1614	0.1214	0.1725	0.1351	0.1633	0.1040
SDAE	0.1383	0.0919	0.1807	0.1499	0.1316	0.0912
CNN-LSTM	0.1417	0.1022	0.1715	0.1344	0.1424	0.1021
所提方法	0.1065	0.0728	0.1660	0.1281	0.1026	0.0670

寒潮极端天气对风力发电和负荷需求均会产生影响,给电网安全稳定运行带来了冲击,提前感知电源侧势态并制定相应预案是应对该风险的有

力措施。考虑到电网调度机构对寒潮天气过程风电出力事前预测的迫切需求，本节针对测试集数据中的寒潮事件，采用寒潮发生时刻及提前 12、24、36、48、60、72h 预报的 NWP 数据进行风电功率预测，分别统计所提方法与单一预测方法在不同起报时间 NWP 取得的风电功率预测误差。

图 8 展示了所提方法和单一预测方法在不同起报时间 NWP 下的预测误差曲线，由图 8 可知，本文提出的动态权重集成预测方法的预测误差在总体上低于单一预测方法，同样证实了本文所提动态权重集成预测建模方法的有效性。




图 8 所提方法与单一预测方法的预测误差曲线
Fig. 8 Predicted error curves of proposed method and single prediction methods

2.3.2 所提方法对比传统集成预测方法

本节将所提动态权重集成预测方法与传统集成预测方法进行对比，包括简单平均集成、Voting、Stacking、Blending。图 9 展示了不同集成预测方法训练过程损失曲线与准确率曲线结果对比，由图可知在训练过程中所提方法的损失函数收敛速度更快，取得的精度高于其他传统集成预测方法。

寒潮天气条件下不同集成预测方法的风电功率预测误差对比结果如表 4 所示。从表 4 中数据可见，本文所提的动态权重集成预测方法相较于传统集成预测方法 RMSE 降低了 0.37%~1.39%，MAE 降低了 0.48%~1.24%。结果表明本文提出的动态权重集成预测方法在寒潮天气条件下取得的风电功率预测精度更高，相较于传统集成预测方法更有优势。




图 9 不同集成预测方法训练过程损失曲线与准确率曲线
Fig. 9 Loss curves and accuracy curves during the training process of different integrated prediction methods

表 4 不同集成预测方法的预测误差对比 Table 4 Prediction error comparison of different integrated prediction methods		
预测方法	RMSE	MAE
简单平均集成	0.1557	0.1145
Voting	0.1513	0.1114
Stacking	0.1480	0.1092
Blending	0.1455	0.1069
所提方法	0.1418	0.1021

图 10 展示了各个集成预测方法在不同起报时间 NWP 下的预测误差曲线，由图 10 可知，本文提出的动态权重集成预测方法取得的预测误差在总体上低于传统集成预测方法，同样证实了本文所提方法的有效性。算例表明本文提出的动态权重集成预测方法通过考虑寒潮气象信息以动态调整各基础预测模型权重，能够提升寒潮极端天气风电功率预测精度。




图 10 不同集成预测方法的预测误差曲线
Fig. 10 Predicted error curves of different integrated prediction methods

2.4 注意力网络预测结果分析

为了验证本文所提多任务 Attention-BiGRU 注意力网络的有效性,本节分别将双向长短期记忆网络(bidirectional long short-term memory, BiLSTM)、BiGRU、CNN-BiLSTM、Attention-BiLSTM 作为注意力网络候选模型,分别构建多任务注意力网络进行动态权重集成预测,将所提 Attention-BiGRU 注意力网络与候选模型进行对比。不同候选模型动态权重集成预测误差对比结果如表 5 所示。从表 5 中数据可以看出,基于 Attention-BiGRU 注意力网络的动态权重集成预测方法取得的预测误差低于其他候选模型,相较于其他候选模型取得的 RMSE 降低了 0.45%~1.53%, MAE 降低了 0.66%~1.70%。结果表明 Attention-BiGRU 在动态调整基础预测模型集成权重方面相比其他候选模型更具优势,能够在风电功率动态权重集成预测取得最优的预测性能。

表 5 不同候选模型动态权重集成预测误差对比
Table 5 Prediction error comparison of different candidate models for dynamic weight integration

预测方法	RMSE	MAE
BiLSTM	0.1571	0.1191
BiGRU	0.1531	0.1174
CNN-BiLSTM	0.1482	0.1148
Attention-BiLSTM	0.1463	0.1087
Attention-BiGRU	0.1418	0.1021

图 11 展示了不同候选模型动态权重集成预测结果对比。由图 11 可知,所提 Attention-BiGRU 注意力网络在 RMSE 和 MAE 方面相较于其他候选模型均取得了最优结果,证实了本文所提多任务 Attention-BiGRU 注意力网络架构的有效性。




图 11 不同候选模型动态权重集成预测结果对比

Fig. 11 Dynamic weight integration prediction results comparison of different candidate models

3 结论

针对寒潮极端天气风电出力样本稀缺、单一预测模型泛化能力差的问题,本文提出了一种基于 RTSGAN 样本扩充和注意力动态权重集成的寒潮极端天气条件风电功率预测方法,通过算例分析验证了所提出方法的有效性。本文的主要结论如下:

1) RTSGAN 采用固定维度潜在空间和改进 WGAN 框架,能够有效地学习寒潮条件下风电出力样本特性,生成更加符合真实样本分布的新样本。相较于传统的样本扩充方法,本文所提的 RTSGAN 样本扩充方法 RMSE 降低了 1.32%~4.41%, MAE 降低了 1.11%~4.33%。所提方法有效解决了寒潮极端天气风电出力样本稀缺导致建模困难的问题。

2) 注意力动态权重集成预测方法考虑了寒潮天气条件下风电运行条件的动态演变特性,能够跟踪各个基础预测模型损失并动态调整对应权重。相较于单一预测方法,所提方法取得的 RMSE 降低了 1.71%~3.68%, MAE 降低了 1.78%~3.55%。相较于传统集成预测方法,所提方法取得的 RMSE 降低了 0.37%~1.39%, MAE 降低了 0.48%~1.24%。所提方法有效解决了寒潮极端天气单一预测模型泛化能力差的问题。

3) 采用 Attention-BiGRU 构建多任务注意力网络,能够取得更好的集成预测效果。相较于 BiLSTM、BiGRU、CNN-BiLSTM、Attention-BiLSTM 候选模型,本文所提多任务 Attention-BiGRU 注意力网络取得的 RMSE 降低了 0.45%~1.53%, MAE 降低了 0.66%~1.70%。

综上所述,本文所提方法能够有效提升寒潮极端天气条件下的风电功率预测精度,可以为寒潮事件发生前电网势态的预判、调度方案的制定提供预先信息参考,助力供电安全,也可为其他极端天气下新能源功率预测小样本建模研究提供参考。

参考文献

- [1] 卢雪平,董存,王铮,等. 低温寒潮天气下的风电短期功率预测技术研究[J]. 电网技术, 2024, 48(12): 4833-4843.
LU Xueping, DONG Cun, WANG Zheng, et al. Research on short-term wind power forecasting technology under low temperature and cold wave weather[J]. Power System Technology, 2024, 48(12): 4833-4843(in Chinese).
- [2] 余建明,庞传军. 考虑数据和模型不确定性的短期风电功率概率预测[J]. 电网技术, 2022, 46(5): 1926-1933.
YU Jianming, PANG Chuanjun. Short-term wind power probabilistic prediction considering data and model uncertainties[J]. Power System Technology, 2022, 46(5): 1926-1933(in Chinese).
- [3] FAKOREDE O, FEGER Z, IBRAHIM H, et al. Ice protection systems for wind turbines in cold climate: characteristics, comparisons

- and analysis[J]. *Renewable and Sustainable Energy Reviews*, 2016, 65: 662-675.
- [4] 王伟胜, 林伟芳, 何国庆, 等. 美国得州 2021 年大停电事故对我国新能源发展的启示[J]. *中国电机工程学报*, 2021, 41(12): 4033-4042.
WANG Weisheng, LIN Weifang, HE Guoqing, et al. Enlightenment of 2021 Texas blackout to the renewable energy development in China[J]. *Proceedings of the CSEE*, 2021, 41(12): 4033-4042(in Chinese).
- [5] KNOLL M, OFFENZELLER C, JAKOBY B, et al. Embedded temperature and anti-icing monitoring systems directly printed on 3D shaped substrates[J]. *IEEE Sensors Journal*, 2020, 20(10): 5314-5321.
- [6] GROCH M, VERMEULEN H J. Modeling high wind speed shut-down events using meso-scale wind profiles and survival analysis[J]. *IEEE Transactions on Power Systems*, 2019, 34(6): 4955-4963.
- [7] 黄越辉, 孙亚南, 李驰, 等. 基于条件生成对抗网络的多区域风电短期出力场景生成方法[J]. *电网技术*, 2023, 47(1): 63-72.
HUANG Yuehui, SUN Yanan, LI Chi, et al. Constructing method of short-term output scenarios for multi-regional wind power based on conditional generative adversarial network[J]. *Power System Technology*, 2023, 47(1): 63-72(in Chinese).
- [8] 米阳, 卢长坤, 申杰, 等. 基于条件生成对抗网络的风电功率极端场景生成[J]. *高电压技术*, 2023, 49(6): 2253-2263.
MI Yang, LU Changkun, SHEN Jie, et al. Wind power extreme scenario generation based on conditional generative adversarial network[J]. *High Voltage Engineering*, 2023, 49(6): 2253-2263(in Chinese).
- [9] YUAN Ran, WANG Bo, SUN Yeqi, et al. Conditional style-based generative adversarial networks for renewable scenario generation[J]. *IEEE Transactions on Power Systems*, 2023, 38(2): 1281-1296.
- [10] ZHOU Bin, DUAN Haoran, WU Qiuwei, et al. Short-term prediction of wind power and its ramp events based on semi-supervised generative adversarial network[J]. *International Journal of Electrical Power & Energy Systems*, 2021, 125: 106411.
- [11] 刘雅婷, 杨明, 于一潇, 等. 基于多场景敏感气象因子优选及小样本学习与扩充的转折性天气日前风电功率预测[J]. *高电压技术*, 2023, 49(7): 2972-2982.
LIU Yating, YANG Ming, YU Yixiao, et al. Transitional-weather-considered day-ahead wind power forecasting based on multi-scene sensitive meteorological factor optimization and few-shot learning[J]. *High Voltage Engineering*, 2023, 49(7): 2972-2982(in Chinese).
- [12] 叶林, 李奕霖, 裴铭, 等. 寒潮天气小样本条件下的短期风电功率组合预测[J]. *中国电机工程学报*, 2023, 43(2): 543-554.
YE Ling, LI Yilin, PEI Ming, et al. Combined approach for short-term wind power forecasting under cold weather with small sample[J]. *Proceedings of the CSEE*, 2023, 43(2): 543-554(in Chinese).
- [13] PEI Hengzhi, REN Kan, YANG Yuqing, et al. Towards generating real-world time series data[C]//2021 IEEE International Conference on Data Mining (ICDM). Auckland: IEEE, 2021: 469-478.
- [14] WENG Peiyao, TIAN Yu, LIU Yingfei, et al. Time-series generative adversarial networks for flood forecasting[J]. *Journal of Hydrology*, 2023, 622: 129702.
- [15] ATES C, KARWAN F, OKRASCHEVSKI M, et al. Conditional generative adversarial networks for modelling fuel sprays[J]. *Energy and AI*, 2023, 12: 100216.
- [16] WAN Y, LUO S, CHENG Y, et al. Diffusion models for multivariate time series generation with missing values[J]. *Authorea Preprints*, 2023. DOI: 10.36227/techrxiv.23674863
- [17] ORLOV A, SILLMANN J, VIGO I. Better seasonal forecasts for the renewable energy industry[J]. *Nature Energy*, 2020, 5(2): 108-110.
- [18] BATTISTI L. Wind turbines in cold climates: icing impacts and mitigation systems[M]. Cham: Springer, 2015.
- [19] 杨子民, 彭小圣, 郎建勋, 等. 基于集群动态划分与 BLSTM 深度学习的风电集群短期功率预测[J]. *高电压技术*, 2021, 47(4): 1195-1203.
YANG Zimin, PENG Xiaosheng, LANG Jianxun, et al. Short-term wind power prediction based on dynamic cluster division and BLSTM deep learning method[J]. *High Voltage Engineering*, 2021, 47(4): 1195-1203(in Chinese).
- [20] 丁婷婷, 杨明, 于一潇, 等. 基于误差修正的短期风电功率集成预测方法[J]. *高电压技术*, 2022, 48(2): 488-496.
DING Tingting, YANG Ming, YU Yixiao, et al. Short-term wind power integration prediction method based on error correction[J]. *High Voltage Engineering*, 2022, 48(2): 488-496(in Chinese).
- [21] 李聪, 彭小圣, 王皓怀, 等. 基于 SDAE 深度学习与多重集成的风电集群短期功率预测[J]. *高电压技术*, 2022, 48(2): 504-512.
LI Cong, PENG Xiaosheng, WANG Haohuai, et al. Short-term power prediction of wind power cluster based on SDAE deep learning and multiple integration[J]. *High Voltage Engineering*, 2022, 48(2): 504-512(in Chinese).
- [22] 宋技峰, 彭小圣, 杨子民, 等. 基于偏差补偿 TCN-LSTM 和梯级迁移策略的短期风电功率预测[J]. *南方电网技术*, 2023, 17(12): 71-79.
SONG Jifeng, PENG Xiaosheng, YANG Zimin, et al. Short-Term wind power prediction based on deviation compensation TCN-LSTM and step transfer strategy[J]. *Southern Power System Technology*, 2023, 17(12): 71-79(in Chinese).
- [23] 石立贤, 金怀平, 杨彪, 等. 基于局部学习和多目标优化的选择性异质集成超短期风电功率预测方法[J]. *电网技术*, 2022, 46(2): 568-577.
SHI Lixian, JIN Huaiping, YANG Biao, et al. Selective heterogeneous ensemble for ultra-short-term wind power forecasting based on local learning and multi-objective optimization[J]. *Power System Technology*, 2022, 46(2): 568-577(in Chinese).
- [24] WANG Gang, JIA Ru, LIU Jinhai, et al. A hybrid wind power forecasting approach based on Bayesian model averaging and ensemble learning[J]. *Renewable Energy*, 2020, 145: 2426-2434.
- [25] LEE J, WANG Wu, HARROU F, et al. Wind power prediction using ensemble learning-based models[J]. *IEEE Access*, 2020, 8: 61517-61527.
- [26] 吕云龙, 胡琴, 熊俊杰, 等. 基于时空注意力卷积模型的超短期风电功率预测[J]. *电网技术*, 2024, 48(5): 2064-2073.
LÜ Yunlong, HU Qin, XIONG Junjie, et al. Ultra-short-term wind power prediction based on spatiotemporal attention convolution model[J]. *Power System Technology*, 2024, 48(5): 2064-2073(in Chinese).
- [27] MA Zhengwei, GUO Sensen, XU Gang, et al. Meta learning-based hybrid ensemble approach for short-term wind speed forecasting[J]. *IEEE Access*, 2020, 8: 172859-172868.
- [28] ZANG Haixiang, CHENG Lilin, DING Tao, et al. Day-ahead photovoltaic power forecasting approach based on deep convolutional neural networks and meta learning[J]. *International Journal of Electrical Power & Energy Systems*, 2020, 118: 105790.
- [29] 邹智, 吴铁洲, 张晓星, 等. 基于贝叶斯优化 CNN-BiGRU 混合神经网络的短期负荷预测[J]. *高电压技术*, 2022, 48(10): 3935-3945.
ZOU Zhi, WU Tiezhou, ZHANG Xiaoxing, et al. Short-term load forecast based on Bayesian optimized CNN-BiGRU hybrid neural

- networks[J]. High Voltage Engineering, 2022, 48(10): 3935-3945(in Chinese).
- [30] RUAN Guangchun, KIRSCHEN D S, ZHONG Haiwang, et al. Estimating demand flexibility using Siamese LSTM neural networks[J]. IEEE Transactions on Power Systems, 2022, 37(3): 2360-2370.
- [31] 陈海鹏, 周越豪, 王趁录, 等. 基于改进的 CNN-LSTM 短期风功率预测的系统旋转备用经济性分析[J]. 高电压技术, 2022, 48(2): 439-446.
CHEN Haipeng, ZHOU Yuehao, WANG Chenlu, et al. Economic analysis of system spinning reserve based on improved CNN-LSTM short term wind power prediction[J]. High Voltage Engineering, 2022, 48(2): 439-446(in Chinese).
- [32] 中华人民共和国国家质量监督检验检疫总局, 中国国家标准化管理委员会. 寒潮等级: GB/T 21987—2017[S]. 北京: 中国标准出版社, 2017.
- [33] 马力, 韦志刚, 李娴茹, 等. 2000 年前后我国寒潮活动特征的比较分析[J]. 冰川冻土, 2022, 44(6): 1757-1772.
MA Li, WEI Zhigang, LI Xianru, et al. Comparative analysis of the cold surge characteristics over China before and after 2000[J]. Journal of Glaciology and Geocryology, 2022, 44(6): 1757-1772(in Chinese).
- [34] 黄丹, 耿焕同, 谢佩妍. 欧亚遥相关型位相变化对我国寒潮路径的影响[J]. 大气科学学报, 2021, 44(6): 888-897.
HUANG Dan, GENG Huantong, XIE Peiyan. The effects of phase changes in Eurasian teleconnections on the tracks of the cold wave in China[J]. Transactions of Atmospheric Sciences, 2021, 44(6): 888-897(in Chinese).



宋嘉炯

在线出版日期: 2025-12-02。

收稿日期: 2025-04-24。

作者简介:

宋嘉炯(2000), 男, 博士研究生, 主要研究方向为人工智能与新能源功率预测, E-mail: songjiajiong0713@163.com;

彭小圣(1983), 男, 通信作者, 博士, 副教授, 主要研究方向为电力系统主设备智能监测、局部放电在线监测与模式识别、综合能源能效提升与新能源预测优化, E-mail: XiaoshengPeng@hust.edu.cn。

(责任编辑 王金芝)