

风电和光伏随机场景生成的 条件变分自动编码器方法

王守相¹, 陈海文¹, 李小平², 舒欣²

- (1. 智能电网教育部重点实验室(天津大学), 天津市 南开区 300072;
2. 国网湖北省电力有限公司电力科学研究院, 湖北省 武汉市 430077)

Conditional Variational Automatic Encoder Method for Stochastic Scenario Generation of Wind Power and Photovoltaic System

WANG Shouxiang¹, CHEN Haiwen¹, LI Xiaoping², SHU Xin²

- (1. Key Laboratory of Smart Grid (Tianjin University), Ministry of Education, Nankai District, Tianjin 300072, China;
2. State Grid Hubei Electric Power Research Institute, Wuhan 430077, Hubei Province, China)

ABSTRACT: Along with increasing penetration of renewable energy sources, such as wind power and photovoltaics, their volatility has a adverse influence on stable and economic operation of power grids, so it is more important to model uncertainty of renewable energy. Random scenario analysis is a major method to solve the problem. Existing methods build probability model and generate scenarios based on sampled historical data. But major obstacles remain, such as low model accuracy and high computational complexity. This paper proposes a stochastic scenario generation method based on conditional variational autoencoder (VAE). Compared with existing methods, the proposed method can carry out unsupervised learning for temporal, spatial, and fluctuant characteristics of training data, and generate scenarios efficiently matching characteristics of observation data according to the given condition without scenario reduction. Effectiveness of the proposed algorithm is verified for three testing scenarios: single unit, multiple units and designated tag scene.

KEY WORDS: stochastic scenario analysis; conditional variational automatic encoder; deep learning; stochastic scenario generation

摘要: 随着风电、光伏等可再生能源渗透率的不断提高,其运行波动性及随机性对电网稳定运行、经济调度等方面带来不良影响,对可再生能源的不确定性进行建模愈加重要。随机场景分析法是解决该问题的主要方法之一,现有随机场景生成方法基于历史数据对风电、光伏出力进行概率建模,进而进行抽样生成场景,模型准确性差、计算复杂度高。为简

化随机场景生成步骤,提高生成效率及精度,提出了一种基于条件变分自动编码器(variational autoencoder, VAE)的风电光伏出力随机场景生成方法,较已有概率方法,所提方法可无监督地学习风电、光伏训练数据的时间、空间及波动性特点,并按条件高效地生成符合观测特点的数据,无需场景约简。通过在单一发电单元、多发电单元、指定标签场景3个场景的成功应用,验证了所提算法的有效性。

关键词: 随机场景分析; 条件变分自动编码器; 深度学习; 场景生成

DOI: 10.13335/j.1000-3673.pst.2018.0291

0 引言

近年来随着风电和光伏等可再生能源发电渗透率的不断提高,其出力不确定性对电力系统的稳定运行和经济调度产生严重影响,由于热备用机组运行成本高、系统调峰能力有限、存在输电阻塞等原因,导致我国电力系统弃风弃光问题突出。

在含可再生能源的电力系统分析中,对可再生能源的不确定性进行建模已经成为一个热点问题^[1]。场景分析法能反映不确定变量的概率特征,是处理电力系统中可再生能源不确定性问题的主要方法,在此方法基础上,可以针对经济调度、机组组合、风光储优化运行等目标建立随机规划模型^[2-5]。场景分析法的基本思想是通过将具有连续概率分布的随机向量离散成场景集合,将随机优化问题转换为确定性问题处理。场景集的构建是场景分析法的基本问题。现有方法大多采用基于概率模型的场景生成方法,首先通过历史数据建立符合可再生能源发电出力分布规律的概率模型,然后通过抽样的方法

基金项目: 国家电网公司科技项目(52153217000F)。

Project Supported by Science and Technology Project of State Grid Corporation of China (52153217000F).

产生用于分析的新场景。目前已经研究过的概率模型包括正态分布、截尾正态分布、贝塔分布、非参数经验分布、通用分布、混合模型分布^[6-10]。文献[11]假设风功率预测误差分布服从联合正态分布,求得分布参数后,通过抽样的方法得到各场景。文献[12]将预测误差分段处理,仍通过联合正态分布建模并抽样生成场景。然而,单个集中接入的风电场及风电场集群的误差分布不服从正态分布^[8]。概率模型的假设是否合理直接关乎所生成的场景的可用性,由于实际现场环境复杂多样,找到一个具有广泛适用性并且易于求解参数的概率模型十分困难。文献[13]中提出了一种无需基于已知概率分布函数,自动生成场景的方法,但其本质上是通过禁忌搜索算法求解场景表示的最优函数实现的,仍涉及到建模求解的过程。文献[14]提出了基于实测数据,利用非参数估计及区间估计对概率密度函数进行回归拟合的方法,虽能避免概率模型假设不合理的问题,但回归模型的核函数选择、参数求解仍是个难题。

基于场景分析法建立可再生能源的随机优化模型的难点在于,如何通过建立合适的概率模型,提高场景集与待解决问题的相似度,如何简化建模步骤,提高场景集的生成效率。现实中由于气候的时变性,发电机能量转换时的非线性,以及机组之间复杂的时间空间关系,导致传统概率模型建立困难。现有场景生成方法仅适用于单地点或系统聚合后总出力场景的生成,多区域可再生能源的场景生成问题由于涉及到时空分布特点,是目前有待深入研究的难题^[2]。

概率模型建立后,需要依靠抽样来产生场景集,如蒙特卡洛抽样^[14]、拉丁超立方抽样^[15]。足够大的初始数据才有可能得到高精度的计算结果,然而抽样场景集规模过大会影响计算效率,为此,人们又提出了包括后向消除、前向选择、场景树构建^[16]在内的场景消减算法,但这些方法不仅加剧了生成模型的复杂度,同时还限制了生成场景的多样性。

随着深度学习在各行各业的应用和发展,其在电力系统中的应用越来越受到重视。条件变分编码器^[17]作为一种新型的深度生成模型,在机器学习领域得到了广泛应用。利用深度神经网络强大的表达能力,可以找出给定观测数据内部的统计规律,进而基于无监督训练所得到的概率分布模型,产生符合数据分布规律的新样本。本文提出了一种基于条件变分编码器的场景生成方法,其优势在于生成过程完全依靠数据驱动,无需概率建模,生成的数据

在保证多样性的同时能很好地反映实际发电单元的时空特性,并且无需场景约简,同时通过 GPU 并行计算,大大提高了场景生成效率。本文通过实际算例从单一发电单元、区域多发电单元、指定标签场景 3 方面验证了算法的有效性。

1 变分自动编码器

图 1 是变分自动编码器(variational autoencoder, VAE)的图模型,观测数据 x 由一系列隐变量 z 产生,记为生成模型 $p_\theta(x|z)$, 解码器,反之对应识别模型(编码器) $q_\phi(z|x)$ 。对 VAE 及传统方法而言,场景生成的关键即获得概率分布 $p_\theta(x|z)$ 。在 Z 独立同分布的假设下,通过对数最大似然估计 $p_\theta(x|z)$ 的参数,即最大化下式:

$$\log P_\theta(x^{(1)}, x^{(2)}, \dots, x^{(N)}) = \sum_{i=1}^N \log P_\theta(x^{(i)}) \quad (1)$$




图 1 VAE 图模型

Fig. 1 VAE graph model

VAE 中通过识别模型 $q_\phi(z|x)$ 逼近观测数据后验概率 $p_\theta(z|x)$, 采用 KL 散度 div_{KL} 衡量这 2 个分布的相似程度。则有:

$$\log p_\theta(x^{(i)}) = \text{div}_{\text{KL}}(q_\phi(z|x^{(i)}), p_\theta(z|x^{(i)})) + L(\theta, \phi; x^{(i)}) \quad (2)$$

直接优化 $\log p_\theta(x^{(i)})$ 是不可行的, 使用变分的思想优化下界 $L(\theta, \phi; x^{(i)})$, 由概率乘法 $L(\theta, \phi; x^{(i)})$ 可写作:

$$L(\theta, \phi; x^{(i)}) = -\text{div}_{\text{KL}}(q_\phi(z|x^{(i)}), p_\theta(z|x^{(i)})) + E_{q_\phi(z|x)}[\log p_\theta(x^{(i)}|z)] \quad (3)$$

第 1 项中, 令 $q_\phi(z|x)$ 取独立高斯分布, $p_\theta(z|x)$ 取标准正态分布, 则由 KL 散度可计算如下:

$$\begin{aligned} \text{div}_{\text{KL}}(q_\phi(z|x^{(i)}), p_\theta(z|x^{(i)})) &= \\ 0.5 \times (1 + \log \sigma_i^2 - \mu_i^2 - \sigma_i^2) &= \\ 0.5 \times (1 + \log \sigma_i^2 - \mu_i^2 - \exp(\log \sigma_i^2)) & \end{aligned} \quad (4)$$

第 2 项 $E_{q_\phi(z|x)}[\log p_\theta(x^{(i)}|z)]$ 是关于 $x^{(i)}$ 后验概率的对数似然, 该项不能求得解析解, 通过蒙特卡洛抽样的方式可得:

$$E_{q_\phi(z|x)}[\log p_\theta(x^{(i)}|z)] \approx \frac{1}{L} \sum_{j=1}^L \log p_\theta(x^{(i)}|\tilde{z}) \quad (5)$$

如果每次只采样一个点, 则有:

$$E_{q_{\phi}(z|x)}[\log p_{\theta}(x^{(i)}|z)] \approx \log p_{\theta}(x^{(i)}|\tilde{z}) \quad (6)$$

该式形式与神经网络损失函数一致, 假设 $p_{\theta}(x|z)$ 服从伯努利分布, 则对应损失函数 f_{loss} 为互熵损失:

$$f_{\text{loss}} = x \log(\tilde{x}) + (1-x) \log(1-\tilde{x}) \quad (7)$$

通过上述推导可知, 在本文所述的可再生能源场景生成中, 可利用深度神经网络来逼近训练数据的概率分布, $L(\theta, \phi; x^{(i)})$ 即网络的损失函数。在网络训练阶段涉及到梯度反向传播^[18]及再参数化等技巧, 本文不再详述, 详细流程可参考文献^[19]。

2 基于 VAE 的随机场景生成

2.1 传统 VAE 算法的条件化改进

利用深度生成模型 VAE, 能以无监督的形式实现对训练数据分布的拟合。但在风电、光伏的场景生成中, 希望生成一些带有特定标签的场景, 比如强光照日的光伏场景、大风日的风电场景, 为此要对变分自动编码器进行条件化改进。这意味着在深度生成模型的训练阶段需要加入标签信息, 与监督学习类似, 给每个训练样本添加标签数据, 采用 one-hot 编码的形式。采用条件概率分布 $p_{\theta}(x^{(i)}|y)$ 代替原有模型中的 $p_{\theta}(x^{(i)})$, 可得:

$$\begin{aligned} \log p_{\theta}(x^{(i)}|y) &= \text{div}_{\text{KL}}(q_{\phi}(z|x^{(i)}, y), \\ &p_{\theta}(z|x^{(i)}, y)) + L(\theta, \phi; x^{(i)}, y) \end{aligned} \quad (8)$$

以深度神经网络拟合式(8), 同样利用再参数化与梯度反向传播等技术进行训练即可得到条件 VAE 模型。提取解码器作为数据生成器, 将代表类别的 one-hot 编码同特征向量一同输入, 即可生成相应类别的数据, 如图 2 所示。




图 2 条件 VAE 场景生成过程

Fig. 2 Generation process of conditional VAE scenario

2.2 生成模型建立流程

在用于可再生能源不确定性分析的场景生成中, 变分自动编码器所学习的概率分布模型是受气

象、发电单元、时空关系等物理过程影响的, 这与图像生成有所差别, 但算法流程一致, 输入历史数据, VAE 无监督(自监督)地学习数据的统计规律, 并基于得到的分布模型生成全新且符合统计特点的数据。生成模型建立流程如下。

步骤 1: 数据编码。其基本思想是利用深度神经网络的拟合能力, 通过编码器(encoder)将输入数据降维成一组特征向量。

步骤 2: 数据解码。利用解码器(decoder)将这组特征向量还原成输入数据。

步骤 3: 梯度反向传播。通过解码输出数据与输入原始数据计算损失函数, 通过反向传播更新网络权重, 反复训练后解码器学习到了数据的映射规律。

步骤 4: 数据生成。提取解码器作为 VAE 生成模型, 从 Gaussian 分布中抽取一组特征向量作为模型输入, 就能输出符合训练数据集概率分布的全新数据, 整个过程无显式建模, 无需人为干预。

VAE 模型训练的基本流程如图 3 所示。




图 3 VAE 训练流程示意图

Fig. 3 Schematic diagram of VAE training process

3 算例分析

3.1 数据来源

本文采用美国国家可再生能源实验室(NREL)的风电光伏数据集进行训练及验证, 由于风电光伏场景生成流程一致, 并且风电波动性更强, 因此更具代表性, 算例主要以风电场景生成为例进行分析, 光伏场景分析结果将在附录 A 中给出。

将功率预测误差的历史数据作为输入, 本方法可生成相应的预测误差序列, 直接将功率作为输入, 则可生成相应的功率序列, 二者分析流程及效果上并无差别, 生成数据均能良好地反映历史数据

特点及统计规律,虽然对生成功率预测误差数据比直接生成功率数据更具代表性^[20],但考虑到直接生成功率序列能更直观地体现本方法对功率波动性、相关性问题的处理能力,因而本算例以直接生成功率数据为例进行介绍。

从美国华盛顿州选择一个 52 机组的风电场及 20 发电单元的光伏电站 6 年功率数据作为样本,数据采样间隔为 5min。机组间地理位置接近,各机组出力之间具有一定相关性,本文所提算法训练时能自主学习到这种相关性特征,并生成符合历史数据特点的场景。

本文在 Keras 上搭建了所述模型,相关代码见(<https://github.com/chwneo7/VAE-code>),Keras 是一个高层神经网络 API,可支持 TensorFlow、Theano、CNTK 作为后端,具有模块化、扩展容易等优点。对于深度学习而言,使用 GPU 进行训练可极大地提高训练速度,本文所用 GPU 为英伟达 GTX1060。

3.2 VAE 模型网络结构

本文针对风电光伏出力数据特点分别设计了 VAE 中编码器及解码器的深度神经网络。

编码器包含 4 个卷积层,首个卷积层有一个卷积核,核大小为 2×2,滑动步长为 1;第 2 个卷积层有 64 个卷积核,核大小为 2×2,滑动步长为 2;第 3 和第 4 个卷积层各有 64 个卷积核,核大小为 3×3,滑动步长为 1。4 个卷积层后连接一 256 个神经元的全连接层。经多次试验,对于可再生能源能生成场景隐向量维数为 10 时(核实表达),对历史数据概率分布拟合最佳,因此均值、方差对数所对应的全连接层神经元个数均为 10。

解码器输入维数为 10,首先包含一个 256 个神经元的全连接层,后连接 9216 个神经元的全连接层。为与编码器相对应,本文设计了 4 个反卷积层,反卷积层参数与编码器完全一致。关键层次如表 1 所示。具体数据维度及深度网络结构可见附录图 A1。

表 1 深度神经网络关键层次结构 Tab. 1 Critical hierarchy of deep neural networks		
层次结构	编码器	解码器
input layer	24×24	10
layer1	卷积层,1	全连接层,256
layer2	卷积层,64	全连接层,9216
layer3	卷积层,64	反卷积层,64
layer4	卷积层,64	反卷积层,64
layer5	全连接层,256	反卷积层,64
layer6	全连接层,10	卷积层,1

网络权重采用 Glorot 均匀分布初始化方法,训练的批梯度下降(mini-batch)大小为 32,使用 Adam

作为优化器^[21]。除输出层使用 Sigmoid 外,其他激活函数全部采用 ReLu。为了防止过拟合,提高训练效率,深度神经网络往往需要在各层输入前添加分批标准化层(BatchNomalization)。但在本文所述模型中添加分批标准化实测反而会使性能变差,原因是分批标准化限制了 VAE 对训练集的拟合,所以本文没有添加分批标准化层。

3.3 单一发电单元场景生成

对风电场而言,设有 N 个风电机组,对于机组 i , $\mathbf{X}_i$ 表示功率时间序列数据, $t=1,\dots,T$ 。目的是使用功率时间序列的历史数据 $\{\mathbf{X}_i\}$, $i=1,\dots,N$ 作为训练集,建立基于 VAE 的深度生成模型,模型产生的场景具有和训练集相同的随机过程及概率分布,同时还能体现数据所有可能的变化。

NREL 的功率数据每天 288 个点,将 2 d 的数据 576 个点重塑为 24×24 的矩阵作为训练集。损失值随 epoch 变化如图 4 所示,一个 epoch 表示所有训练数据都已被训练一次。




图 4 损失值随 epoch 变化
Fig. 4 Loss value curve

得到训练好的模型后,截取解码器部分作为生成模型。构造 20 000 个维度为 10 的向量 $\mathbf{Z}_m=\{z_{1m}, z_{2m},\dots,z_{9m},z_{10m}\}$, $m=1,\dots,20\ 000$,其中 $z_1\sim z_{10}$ 均满足标准正态分布,将其作为输入送入生成模型中,即可得到 20000 组生成场景。

下面从测试集里选择部分曲线,验证生成场景的有效性。测试集中的曲线并没有被模型学习过,而由图 5 可见,模型自动产生了一些和测试集非常接近的曲线,生成的数据与实际数据契合度很高,甚至连风电出力的快速波动、大风时段长时间维持最大出力以及峰谷的周期变化都“模仿”得很精确。这证明所提模型并不是简单地重复生成训练集中的数据,而是以所学习到的特征创造全新的数据。测试集中的数据是真实发生的,生成模型未使用这些数据进行训练,但是在生成器生成的数据中却可以发现一些曲线和测试集中的曲线高度相似,这也证明了生成器生成的数据是非常符合实际情景的,

而且具备很强的泛化能力，这是传统场景生成方法不可能做到的。

除直接观察曲线形状以外，可从统计学特征上对生成数据的有效性进行验证。下面给出了历史数据及生成数据的自相关系数及偏自相关系数计算公式：

$$R(\tau) = \frac{E[(S_t - \mu)(S_{t+\tau} - \mu)]}{\sigma^2} \quad (9)$$




图5 测试集与生成数据自相关性对比

Fig. 5 Correlation comparison between the test set and the generated data

$$\rho(\tau) = \frac{E[(S_t - E(S_t))(S_{t-\tau} - E(S_{t-\tau}))]}{\sigma^2} \quad (10)$$

式中： S_t 表示历史数据或生成数据的时间序列； μ 为中值； σ 为标准差； τ 为时间间隔。自相关系数及偏自相关系数直观反映了分布式发电出力在时序上的相关性。

日功率曲线如图 5(a1)—(d1)所示，主要反映了功率数据的短期特性。根据式(9)和式(10)计算得到历史数据及生成数据的自相关系数及偏自相关系数，如图 5(a2)—(d2)，(a3)—(d3)所示，可以看出，生成器生成的数据在自相关特性上与真实数据保持了较高的一致性。

在日功率曲线分析的基础上，分析机组出力的长期特性，对 20 000 组生成数据及 9000 组历史数据的功率概率分布及积累概率分布进行统计分析，得到如图 6 所示的概率分布及图 7 所示的积累概率分布。




图6 历史数据、生成数据概率分布

Fig. 6 Probability distribution of historical data and generation data




图7 历史数据、生成数据积累概率分布

Fig. 7 Cumulative probability curve of historical data and generation data

由图 6、图 7 可见，生成数据的概率分布以一条平滑的曲线对训练集的历史数据进行了拟合，二者在概率分布及积累概率分布上非常接近。这表明生成模型除了学习到了曲线的形状细节以外，还学习到了历史数据的分布规律，以无监督的形式实现了传统场景生成方法中概率建模的效果。光伏电站

的场景生成结果如附录图 A3—A5 所示, 与风电场分析结果相似。由于光伏波动性弱于风电, 并且发电时段相对固定, 光伏场景生成的数据概率分布拟合更为准确。

3.4 多发电单元场景生成及相关性分析

在大型风电场或光伏电站内存在多个发电单元, 这些发电单元在地理位置上比较接近, 在生成场景时, 除了需要同上文类似地考虑数据的概率分布以外, 还需要考虑这些发电单元之间的相关性。

传统方法在考虑相关性时非常繁琐, 需要先对各个发电单元之间的相关性进行假设, 然后再根据置信度肯定或否定假设。本文所述方法不需要任何明确假设, 生成的场景和训练集数据在相关性上具有相似的统计规律。

目前已有的场景生成方法往往仅适用于单机组或者某系统聚合后的总风电出力的场景生成, 研究领域局限在时间尺度上, 当考虑多地点风电场的场景生成时, 需要进一步考虑风电的时空分布特性, 这种多相关性建模非常复杂。而对于深度生成模型而言, 深度神经网络能够学习这种相关性, 并体现在生成的数据中。下面对此进行验证。

使用单机组生成模型所建立的 VAE 网络结构, 重新对该网络进行训练。为保证网络输入数据维度不变, 将每个机组采样间隔由 5 min 提高到 1 h, 从同一风电场内选择 24 个风电机组, 每天采集的数据量为 2×24 , 选择 6a 的历史数据对网络进行训练, 输入数据维度为 (2190, 24, 24), 与单机组训练时保持一致。由于光伏电站发电单元数量不足 24, 对缺失维度以 0 作为填充, 场景生成后删除填充的发电单元。

由于单机组生成数据的有效性前一节已做论证, 本节只对生成的数据能否体现机组之间相关性进行分析。分别计算历史数据及生成数据两两机组之间的相关性系数:

$$\rho = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_{i=1}^n (x_i - \bar{x})^2 \sum_{i=1}^n (y_i - \bar{y})^2}} \quad (11)$$

风电场相关性系数的可视化计算结果如图 8 所示, 光伏电站结果如附录图 A6 所示。由图 8、图 A6 可见, 虽然相较历史数据, 生成数据的部分机组之间相关性有所降低, 但整体符合历史数据的相关性规律。这表明 VAE 模型训练时能同时捕获历史数据的短期特征(波动频繁、峰谷变化)、长期特征

(功率概率分布)以及相关性特征(多机组之间), 并且无需修改网络结构, 所生成的场景在保持多样性的同时几乎完美复现了历史数据的上述特点, 与传统方法相比, 更能代表机组的实际运行状况(事实上传统方法很难同时兼顾单机组的运行特点及多机组的相关关系)。




图 8 历史数据、生成数据机组相关性对比

Fig. 8 Unit comparative analysis of historical data and generating data

3.5 指定标签下的场景生成

在进行场景分析时, 需要生成某些特殊条件下的场景数据。例如, 特定月份的光伏风电数据, 或者特定天气下的光伏风电数据。为此, 可以将这些条件作为标签赋给训练集, 即 $\{X_i|y_i\}, i=1, \dots, N$, 通过上文所述的条件 VAE 得到生成模型, 生成的场景数据将具有与带有标签的训练集相似的统计特性。

通过条件化改进的 VAE 模型, 可以生成指定标签下的场景。这需要在训练时对各个训练样本添加一个 One-Hot 编码来表示标签信息。例如给训练样本添加月份编码, 训练后即可生成指定月份的场景数据。

以风电场、光伏电站当日出力均值大小指定所属标签, 如表 2、表 3 所示。

条件化 VAE 的模型结构也需要做相应的改动, 即分别在编码器与解码器输入增加 One-Hot 编码。

表 2 风电机组日出力均值区间及其对应标签
Tab. 2 Mean daily output interval of unit and its corresponding label

均值区间/MW	物理含义	One-Hot 编码
[0, 0.5)	无风日机组出力	[0,0,0,1]
[0.5, 2)	微风日机组出力	[0,0,0,1,0]
[2, 4)	和风日机组出力	[0,0,1,0,0]
[4, 8)	强风日机组出力	[0,1,0,0,0]
[8, 16)	大风日机组出力	[1,0,0,0,0]

表 3 光伏单元日出力均值区间及其对应标签
Tab. 3 Mean daily output interval of unit and its corresponding label

均值区间/MW	物理含义	One-Hot 编码
[0, 0.5)	低照度日发电单元出力	[0,0,0,1]
[0.5, 1)	中低照度日发电单元出力	[0,0,1,0]
[1, 1.5)	中照度日发电单元出力	[0,1,0,0]
[1.5, 4)	高照度日发电单元出力	[1,0,0,0]

为避免输入维数改变影响卷积操作，将卷积层(反卷积层)统一替换为全连接层。具体数据维度及深度神经网络结构见附录图 A2。

对风电场分别指定上文所述的 5 类标签对应的 One-Hot 编码，并输入 20000 个维度为 10 的向量 Z_m ，这样对于每个标签均能产生 20000 组数据。将机组的出力区间 0~16 MW 划分为 10 个区间，作出生成数据及训练集中对应标签数据的概率分布，如图 9 所示。同样对光伏电站指定 4 类标签对应的 One-Hot 编码，并将处理区间 0~8 MW 划分为 10 个区间，结果如附录图 A7 所示。

从图 9、图 A7 可见，由条件 VAE 模型所产生




图 9 不同标签下生成数据与历史数据概率密度分布
Fig. 9 Probability density distribution of generated data and historical data under different labels

的数据，实现了对训练集中每一类标签数据概率分布的良好拟合。例如，对于无风、微风日，机组出力低于 2 MW 的概率达到了 80%以上，而随着风力增大，概率分布“重心”也逐渐右移，这与历史数据反映的规律一致。值得注意的是，仅通过一个条件 VAE 模型，实际上同时实现了对多类数据分布的拟合，这充分反映了深度神经网络强大的学习及表征能力，也说明了利用条件 VAE 模型同时生成几种不同类型的风电、光伏场景数据是完全可行的。

4 结论

本文提出了一种利用变分自动编码器进行随机场景生成的方法，并从单一发电单元、多发电单元、指定标签场景 3 方面验证了该方法的有效性。

研究表明，所提方法具有以下突出优点：

1) 在特征表达方面，无论是短期分布式电源出力波动、峰谷变化，还是长期出力的概率分布，生成数据都与真实数据高度一致，这是传统概率方法无法做到的。

2) 在创造性方面，所提模型能以所学习到的特征创造全新的数据，而且具备很强的泛化能力。通过输入满足正态分布的隐向量，可以产生无穷多的场景数据，为随机场景分析提供了极大的便利。

3) 在自主学习方面，所提方法不涉及概率建模、显式特征提取、概率抽样等繁琐步骤，只通过历史数据训练，生成模型中的深度神经网络就能自主实现特征的提取与学习，具有无监督、自学习、数据驱动等优点，从而大幅简化场景生成步骤。

附录见本刊网络版(<http://www.dwjs.com.cn/CN/volumn/current.shtml>)。

参考文献

[1] 王群, 董文略, 杨莉. 基于 Wasserstein 距离和改进 K-medoids 聚类的风电/光伏经典场景集生成算法[J]. 中国电机工程学报, 2015, 35(11): 2654-2661.
Wang Qun, Dong Wenlue, Yang Li. A wind power/photovoltaic typical scenario set generation algorithm based on Wasserstein distance metric and revised K-medoids cluster[J]. Proceedings of the CSEE, 2015, 35(11): 2654-2661(in Chinese).

[2] 马溪原. 含风电电力系统的场景分析方法及其在随机优化中的应用[D]. 武汉: 武汉大学, 2014.

[3] 雷宇. 基于场景分析的含风电场电力系统机组组合问题的研究[D]. 济南: 山东大学, 2013.

[4] 黄大为, 张伟, 韩学山. 基于自适应风电功率场景选取的有功调度模型[J]. 电力系统自动化, 2013, 37(19): 68-73.
Huang Dawei, Zhang Wei, Han Xueshan. Active power dispatch based on self-adaptive wind power scenario selection[J]. Automation of Electric Power Systems, 2013, 37(19): 68-73(in Chinese).

[5] 赵波, 韦立坤, 徐志成, 等. 计及储能系统的馈线光伏消纳能力随机场景分析[J]. 电力系统自动化, 2015, 39(9): 34-40.

- Zhao Bo, Wei Likun, Xu Zhicheng, et al. Photovoltaic accommodation capacity determination of actual feeder based on stochastic scenarios analysis with storage system considered [J]. Automation of Electric Power Systems, 2015, 39(9): 34-40(in Chinese).
- [6] Makarov Y V, Etingov P V, Ma J, et al. Incorporating uncertainty of wind power generation forecast into power system operation, dispatch, and unit commitment procedures[J]. IEEE Transactions on Sustainable Energy, 2011, 2(4): 433-442.
- [7] Tewari S, Geyer C J, Mohan N. A statistical model for wind power forecast error and its application to the estimation of penalties in liberalized markets[J]. IEEE Transactions on Power Systems, 2011, 26(4): 2031-2039.
- [8] Bludszuweit H, Dominguez-Navarro J A, Llombart A. Statistical analysis of wind power forecast error[J]. IEEE Transactions on Power Systems, 2008, 23(3): 983-991.
- [9] Ma X Y, Sun Y Z, Fang H L. Scenario generation of wind power based on statistical uncertainty and variability[J]. IEEE Transactions on Sustainable Energy, 2013, 4(4): 894-904.
- [10] Zhang Z S, Sun Y Z, Gao D W, et al. A versatile probability distribution model for wind power forecast errors and its application in economic dispatch[J]. IEEE Transactions on Power Systems, 2013, 28(3): 3114-3125.
- [11] Álvaro Jaramillo Duque, Castronuovo E D, Sánchez I, et al. Optimal operation of a pumped-storage hydro plant that compensates the imbalances of a wind power producer[J]. Electric Power Systems Research, 2011, 81(9): 1767-1777.
- [12] Pierre P, Henrik M, Aa N H, et al. From probabilistic forecasts to statistical scenarios of short-term wind power production[J]. Wind Energy, 2010, 12(1): 51-62.
- [13] 黎静华, 孙海顺, 文劲宇, 等. 生成风电功率时间序列场景的双向优化技术[J]. 中国电机工程学报, 2014, 34(16): 2544-2551.
Li Jinghua, Sun Haishun, Wen Jinyu, et al. A two-dimensional optimal technology for constructing wind power time series scenarios [J]. Proceedings of the CSEE, 2014, 34(16): 2544-2551(in Chinese).
- [14] 林鹏, 赵书强, 谢宇琪, 等. 基于实测数据的风电功率曲线建模及不确定估计[J]. 电力自动化设备, 2015, 35(4): 90-95.
Lin Peng, Zhao Shuqiang, Xie Yuqi, et al. Wind power curve modeling based on measured data and uncertainty estimation [J]. Electric Power Automation Equipment, 2015, 35(4): 90-95(in Chinese).
- [15] 于晗, 钟志勇, 黄杰波, 等. 采用拉丁超立方采样的电力系统概率潮流计算方法[J]. 电力系统自动化, 2009, 33(21): 32-35+81.
Yu Han, Zhong Zhiyong, Kitpo W, et al. A probabilistic load flow calculation method with Latin hypercube sampling[J]. Automation of Electric Power Systems, 2009, 33(21): 32-35+81(in Chinese).
- [16] Dupacova J, Growe-Kuska N, Romisch W. Scenario reduction in stochastic programming: an approach using probability metrics [J]. Mathematical Programming, 2003, 95(2): 493-511.
- [17] Kingma D P, Welling M. Auto-encoding variational bayes[J]. arXiv preprint arXiv: 1312.6114, 2013.
- [18] Rezende D J, Mohamed S, Wierstra D. Stochastic backpropagation and approximate inference in deep generative models[J]. arXiv preprint arXiv: 1401.4082, 2014.
- [19] Doersch C. Tutorial on variational autoencoders[J]. arXiv preprint arXiv: 1606.05908, 2016.
- [20] Pappala V S, Erlich I, Rohrig K, et al. A stochastic model for the optimal operation of a wind-thermal power system[J]. IEEE Transactions on Power Systems, 2009, 24(2): 940-950.
- [21] Kingma D, Ba J. Adam: A method for stochastic optimization [J]. arXiv preprint arXiv: 1412.6980, 2014.



王守相

收稿日期: 2018-02-01。

作者简介:

王守相(1973), 男, 通信作者, 博士, 教授, 博士生导师, 研究方向为分布式发电与智能配电网, E-mail: sxwang@tju.edu.cn;

陈海文(1994), 男, 博士研究生, 研究方向为智能用电, E-mail: chenhaiwen@tju.edu.cn;

李小平(1969), 男, 硕士, 研究方向为电力系统运行控制;

舒欣(1983), 男, 博士, 研究方向为智能配电网。

(责任编辑 马晓华)

附录 A




图 A1 VAE 网络结构(基于 Keras 框架)
Fig. A1 VAE network structure (based on Keras framework)




图 A2 条件 VAE 网络结构(基于 Keras 框架)
Fig. A2 Conditional VAE network structure (based on Keras framework)




图 A3 历史数据、生成数据概率分布(光伏电站)
Fig. A3 Probability distribution of historical data and generation data (photovoltaic field)





图 A4 历史数据、生成数据积累概率分布(光伏电站)
Fig. A4 Cumulative probability curve of historical data and generation data (photovoltaic field)






图 A5 测试集与生成数据自相关性对比(光伏电站)
Fig. A5 Correlation comparison between the test set and the generated data (photovoltaic field)






图 A7 不同标签下生成数据与历史数据概率密度分布
Fig. A7 Probability density distribution of generated data and historical data under different labels



(a) 历史数据



(b) 生成数据

图 A6 历史数据、生成数据机组相关性对比(光伏电站)
Fig. A6 Unit comparative analysis of historical data and generating data (photovoltaic field)